

结合未知类特征生成与分类得分修正的SAR目标开集识别方法

陈健 雍奇锋 杜兰* 尹林伟

(西安电子科技大学雷达信号处理国家重点实验室 西安 710071)

摘要: 现有合成孔径雷达(SAR)目标识别方法大多局限于闭集假定,即认为训练模板库内训练目标类别包含全部待测目标类别,不适用于库内已知类和库外未知新类目标共存的真实开放识别环境。针对训练模板库目标类别非完备情况下的SAR目标识别问题,该文提出一种结合未知类特征生成与分类得分修正的SAR目标开集识别方法。该方法在利用已知类学习原型网络保证已知类识别精度的基础上结合对潜在未知类特征分布的先验认知,生成未知类特征更新网络,进一步保证特征空间中已知类、未知类特征的鉴别性。原型网络更新完成后,所提方法挑选各已知类边界特征,并计算边界特征到各自类原型的距离(极大距离),通过极值理论对各已知类极大距离进行概率拟合确定了各已知类最大分布区域。测试阶段在度量待测样本特征与各已知类原型距离预测闭集分类得分的基础上,计算了各距离在对应已知类极大距离分布上的概率,并修正闭集分类得分,实现了拒判概率的自动确定。基于MSTAR实测数据集的实验结果表明,所提方法能够有效表征真实未知类特征分布并提升网络特征空间已知类与未知类特征的鉴别性,可同时实现对库内已知类目标的准确识别和对库外未知类新目标的准确拒判。

关键词: SAR目标识别; 开集识别; 未知类特征生成; 极值理论; 分类得分修正

中图分类号: TN957

文献标识码: A

文章编号: 1009-5896(2024)10-3890-18

DOI: [10.11999/JEIT240138](https://doi.org/10.11999/JEIT240138)

An Open Set Recognition Method for SAR Targets Combining Unknown Feature Generation and Classification Score Modification

CHEN Jian YONG Qifeng DU Lan YIN Linwei

(National Key Laboratory of Radar Signal Processing, Xidian University, Xi'an 710071, China)

Abstract: The existing Synthetic Aperture Radar (SAR) target recognition methods are mostly limited to the closed-set assumption, which considers that the training target categories in training template library cover all the categories to be tested and is not suitable for the open environment with the presence of both known and unknown classes. To solve the problem of SAR target recognition in the case of incomplete target categories in the training template library, an openset SAR target recognition method that combines unknown feature generation with classification score modification is proposed in this paper. Firstly, a prototype network is exploited to get high recognition accuracy of known classes, and then potential unknown features are generated based on prior knowledge to enhance the discrimination of known and unknown classes. After the prototype network being updated, the boundary features of each known class are selected and the distance of each boundary feature to the corresponding class prototype, i.e., maximum distance, is calculated, respectively. Subsequently the maximum distribution area for each known class is determined by the probability fitting of maximum distances for each known class by using extreme value theory. In the testing phase, on the basis of predicting closed-set classification scores by measuring the distance between the testing sample features and each known class prototype, the probability of each distance in the distribution of the corresponding known class's maximum distance is calculated, and the closed-set classification scores are corrected to automatically determine the rejection probability. Experiments on measured MSTAR dataset show that the proposed method can effectively represent the distribution of unknown class features and enhance the discriminability of known

收稿日期: 2024-03-04; 改回日期: 2024-09-30; 网络出版: 2024-10-09

*通信作者: 杜兰 dulan@mail.xidian.edu.cn

基金项目: 国家自然科学基金(U21B2039, 62201433), 中央高校基本科研业务费专项资金(QTZX23067)

Foundation Items: The National Science Foundation of China (U21B2039, 62201433), The Fundamental Research Funds for the Central Universities (QTZX23067)

and unknown class features in the feature space, thus achieving accurate recognition for both known class targets and unknown class targets.

Key words: SAR target recognition; Open set recognition; Unknown feature generation; Extreme value theory; Classification score modification

1 引言

合成孔径雷达(Synthetic Aperture Radar, SAR)可对地面区域进行大面积的主动微波成像,能够实现全天时、全天候对地观测,在军事领域和民用领域得到广泛应用。近年来,随着SAR系统和成像算法逐渐成熟,越来越多高质量的SAR图像出现,也促成了SAR目标识别技术的研究与应用^[1]。SAR目标识别技术通过对SAR图像进行特征提取并训练分类器,实现对待测目标归属类别的预测,为战场环境感知、目标行为识别与解译等领域提供了不可或缺的技术支撑,具有重要的研究意义。

在SAR目标识别领域的研究中,早期学者针对SAR图像提出了利用浅层特征来描述SAR图像并进行识别的方法。文献[2]采用了尺度不变特征变化(Scale-Invariant Feature Transform, SIFT)来描述SAR图像,文献[3]对多级幅度特征和多级密集SIFT特征进行特征融合,达到了更好的识别性能。近年来,随着深度学习技术的发展,越来越多的学者将这一技术引入到SAR识别领域。文献[4]提出了一种通道级别的卷积结构用来提取SAR图像的极化特性,以达到更高的识别精度。文献[5]提出了一种新的网络结构,即信息传播网络,通过同时考虑SAR目标的方位角、散射强度等特性,并结合所提流注意力(Stream Self-Attention, SSA)机制,学习多流、多尺度的高层语义信息,提升了SAR识别模型的代表能力。

深度学习技术的发展为解决SAR目标识别问题带来了新的思路,也取得了一定的成果。然而目前现有的SAR目标识别方法大多基于闭集环境假定,即认为待测样本所属类别集合与训练样本类别集合相同。然而SAR目标识别技术通常面向非合作目标,在非合作目标识别任务中,由于目标类别众多,许多高价值目标难以提前获取,很难提前建立完备的识别模板库。面临训练阶段没有出现的未知类样本时,传统闭集识别方法会强制将其划分为某一库内已知类类别,造成严重的决策错误。

近年来,开集识别(Open Set Recognition, OSR)的提出即是为了解决在已知类、未知类共存的开放环境下的目标识别问题。相比闭集识别方法,开集识别方法需要在维持已知类别识别准确率的基础上,对潜在未知类别样本有一定的判别能力。目前

光学图像分类领域已经有很多开集识别方法,主流算法可分为基于判别模型和基于生成模型的方法两类。基于判别模型的开集识别方法^[6-10]在已知类学习识别模型的基础上,通过在所学特征空间/分类决策空间结合已知类分布特点设置/求解合适的未知类拒判阈值,来实现已知类、未知类的区分。文献[6]通过计算待测样本与已知类训练样本的最近距离和次近距离的比值,并与预设阈值作比较实现对未知样本的拒判。文献[7]利用极值理论(Extreme Value Theory, EVT)对已知类的边界样本进行概率拟合,并以此计算了最佳的概率拒判阈值。Yang等人^[8]首次将原型网络引入开集识别中,通过度量待测样本特征离最近原型的距离,并与预设阈值作比较,实现对未知类目标的拒判。文献[10]改进了文献[8]中所提原型学习方法,以获得更具类内聚合性、类间可分性的原型空间,更利于拒判阈值的准确设置。基于生成模型的开集识别方法^[11-13]利用生成模型(如生成对抗网络、变分自编码器等)生成未知类数据,并联合已知类数据共同学习各已知类、未知类的分类界面,直接实现“ $K+1$ ”类(K 表示已知类数量)识别。文献[10]利用生成对抗网络生成未知类实现未知类决策边界的学习。Moon等人^[12]提出了用于开集识别任务的困难感知模拟器以生成具有不同难度水平的未知类数据,提升了生成方法的表征能力,获得了相比传统生成方法更高的开集识别结果。文献[13]对比了特征匹配生成对抗网络(Feature-Matching Generative Adversarial Network, FM-GAN)、3元生成对抗网络(Triple Generative Adversarial Network, Triple-GAN)、对抗相反点生成对抗网络(Adversarial Reciprocal Point Generative Adversarial Network, ARP-GAN)等生成方法,分析了开集识别任务中不同生成方法的性能优劣。

SAR目标识别领域也开展了开集识别相关研究,取得了一定成果,但大多直接利用或者借鉴现有光学图像分类领域的开集识别思路。如,文献[14]提出了一种基于边界样本挑选策略的判别式SAR目标开集识别方法,其认为在特征空间中类别之间混淆严重的区域可以看成是各类别特征分布的边界,并以此确定了各已知类的决策界面;测试阶段通过计算待测样本特征与各已知类决策边界的距离并与预设阈值比较实现了对未知类的判断。文献[14]提出

了一种结合生成对抗网络生成未知类SAR目标特征的开集识别方法,直接学习了未知类决策界面。然而,与光学成像依赖于光的折射、反射等原理不同,SAR成像依赖目标散射点的电磁散射特性。由于雷达传感器本身的特殊性和目标电磁散射性的复杂性,SAR图像对目标表征的充分性往往差于光学图像,从而导致具有强表征能力的SAR目标可分特征更难提取。对于现有仅利用已知类学习的判别式开集识别方法应用于SAR图像,SAR图像已知类特征可分性的降低更容易造成已知类与未知类特征的混叠,进而更难准确设置/求解出合适的拒判阈值,从而SAR目标开集识别性能受到限制。此外,由于SAR图像成像机理的特殊性以及SAR图像样本数量难以保证,利用已知类SAR图像数据驱动式生成未知类SAR图像/特征的开集识别方法生成SAR图像/特征的质量较生成光学图像/特征的质量更难保证^[15]。因此,在光学图像上性能较优的基于生成模型的开集识别方法在SAR图像上很可能性能受限。

针对现有基于判别和生成模型的开集识别方法应用于SAR目标识别存在的问题,本文综合判别模型与生成模型思想,在闭集模型学习中结合未知类特征生成参与模型学习,从特征层面提升已知类和未知类可分性;同时在分类层面,结合极值理论确定已知类边界分布并基于此分布修正闭集分类得分,自动计算得到拒判概率。所提方法一方面通过增强已知类和未知类特征鉴别性缓解了判别式SAR目标开集识别方法存在的拒判阈值更难确定的问题,另一方面避免了生成式SAR目标开集识别方法因高质量未知类SAR图像/特征难生成而造成的未知类直接参与模型学习决策界面准确度更难保证的问题。具体来讲,该方法首先利用原型对比损失约束各已知类特征类内聚合、类间分散,保证已知类特征可分性。在原型学习结束后,结合对特征空间中已知类、未知类分布的先验认知,利用不同类别的已知类样本两两组合,生成未知类样本特征,在保证已知类类间具备良好可分性的同时,约束生成未知类特征离各已知类原型距离相等,提升特征空间中已知类、未知类鉴别性。基于极值理论,各类样本特征离类原型的极大距离服从威布尔分布,故挑选各已知类中的边界样本特征,计算其到类原型的极大距离并估计各类极值距离的威布尔分布参数。测试阶段,计算待测样本特征与各原型的距离得到闭集分类得分然后计算各距离在对应类别极大距离威布尔分布情况下的概率值,并对模型的闭集分类结果进行修正,从而自动确定待测样本属于未知类的概率得分,实现对已知、未知目标的区分。

综上所述,本文的贡献如下:

(1)基于未知类分布先验提出一种未知类特征生成策略,并结合已知类与生成未知类更新闭集模型,通过约束未知类特征与各已知类距离相同,拉大了已知类与未知类特征间隔,从特征层面提升了已知类、未知类的区分性;

(2)基于极值理论确定了已知类边界特征分布,结合边界分布修正闭集分类得分,实现了待测样本拒判概率的自动估计,避免了拒判阈值人工设置,也避免了生成模型中利用生成样本确定决策边界不准确的问题。

2 SAR开集识别问题描述及方法介绍

2.1 SAR开集识别问题描述

在SAR识别任务中,受限于类别种类多、采样过程代价高等实际因素,识别模板库中的训练样本类别是不充分的,待测样本既可能属于识别模板库中的已知类别,也可能属于模板库外的未知类别,属于典型的开集识别场景。在SAR开集识别场景下,记训练集为 $\mathbf{X}_K = \{(x_1, y_1), \dots, (x_N, y_N)\}$,其中 N 为训练样本总数, $y_i \in \{1, 2, \dots, N_k\}$, N_k 为已知类类别总数。测试集 $\mathbf{X}_U = \{t_1, t_2, \dots, t_U\}$,其中 U 为测试样本总数,对于测试样本 t_i ,其类别 $y(t_i) \in \{1, 2, \dots, N_k\} \cup \{N_k + 1, N_k + 2, \dots, N_k + N_u\}$, N_u 为未知类类别数。文献[16]指出开集识别任务不仅需要维持测试阶段库内已知类别的识别率,同时应该对未知类别样本有一定的判别能力,其分类函数 f^* 应同时最小化经验空间风险与开放空间风险,如式(1)所示

$$f^* = \arg \min_{f \in \mathcal{H}} \{R_o(f(\mathbf{X}_U)) + \lambda_r R_e(f(\mathbf{X}_K))\} \quad (1)$$

其中, $R_o(f)$ 代表分类函数 f 在未知类上的开放空间风险, $R_e(f)$ 代表分类函数 f 在已知类上的经验空间风险。开集识别方法的目标即是在保持库内已知类识别准确率的同时,实现对库外未知目标的判别。

2.2 方法介绍

图1展示了本文所提结合未知类特征生成与分类得分修正的SAR目标开集识别方法。所提方法可分为闭集训练、未知类特征生成与模型更新、极值拟合、基于分类得分修正的开集测试4个模块。闭集训练模块基于已知类训练数据学习原型网络,利用原型对比损失约束已知类类内聚合、类间分散,保证已知类类间可分性。未知类特征生成与模型更新模块在已知类学习完成后挑取已知类异类内侧边界样本特征,通过凸组合生成仿制未知类特征,并




图1 结合未知类特征生成与分类得分修正的SAR开集识别方法示意图

结合已知类损失与未知类损失更新闭集训练模型，提升特征空间中已知、未知特征的可分性。极值拟合模块首先计算各已知类特征与对应类原型的距离，然后挑选部分具有较大值的距离作为该已知类极值样本，并结合极值理论拟合各类极值距离的概率分布，以此确定了各已知类分布的边界。开集测试阶段，计算待测样本特征与各类原型的距离获得其闭集分类得分，同时计算各距离在对应已知类极值分布情况下的概率，并基于此修正网络的闭集分类得分，以获得开集场景下待测样本属于各已知类的识别概率以及属于库外未知类的拒判概率，实现对待测样本已知、未知的区分。所提方法在特征层面结合未知类特征生成提升了已知类特征间距，为真实未知类特征分布留有更大空间，潜在增强了已知类、未知类鉴别性，使已知类、未知类决策界面的准确确定更容易；在分类器设计层面，通过对已知类边界特征进行概率建模，以修正网络的闭集分类得分，避免了直接利用生成未知类学习未知类决策界面时因未知类生成质量难保证造成的决策界面对真实未知类适应性差的问题。下面分别对各模块详细介绍。

2.2.1 闭集训练模块

本模块旨在训练一个对已知类拥有良好分类性

能的特征提取网络 E ，以便在测试阶段能准确区分各已知类；同时，通过提升已知类间的特征可分性，间接地为测试阶段未知类分布留出足够的空间，利于未知类与已知类的鉴别，该模块的具体流程如图2所示。

如图2所示，本模块中将库内已知类目标图像通过特征提取网络 E 后，在特征空间利用原型对比损失^[8]约束各已知类特征分布，实现各已知类特征类内分布紧凑，类间分布分散的分布形式。文献^[8]首次提出了原型网络的基本结构，并采用原型对比损失取代交叉熵损失函数，作者认为相比交叉熵损失，原型对比损失能有效约束样本的特征分布，实现更高的分类精度。图3给出了在MSTAR数据集上，将BMP2, BTR70, BTR60, D7共4类作为已知类，其余类别作为未知类，在ResNet-50上分别采用交叉熵损失约束以及原型对比损失约束的特征通过t分布随机领域嵌入(t-distributed Stochastic Neighbor Embedding, t-SNE)的特征可视化结果。

从图3可以看出，相比交叉熵损失，原型对比损失能有效提升特征的类内紧凑性，有利于识别任务。具体来讲，原型网络为各类特征分配一个可学习原型，并利用原型对比损失约束各类特征与本类原型近、异类原型远，从而相较于以交叉熵损失为




图2 闭集训练模块示意图




图3 交叉熵损失与原型对比损失约束的特征可视化结果

代表的传统深度神经网络可以获得类内分布更紧凑、类间分布更分散的特征空间。因此，本文利用原型网络对库内已知类进行学习，保证已知类的识别准确性。

该模块将各库内已知类样本通过特征提取网络 E 后，映射到原型空间，在原型空间中为各类别设置一个可学习的原型参数，记为 $\mathbf{m}_i \in \mathbb{R}^N$ ，其中 N 为原型空间维度， $i \in \{1, 2, \dots, N_k\}$ 为类别索引，记 $\mathbf{M} = \{\mathbf{m}_i\}_{i=1}^{N_k}$ 。对于基于已知类学习的特征提取网络，其特征提取能力一方面会影响已知类间的特征可分性，从而直接决定对已知类的识别性能；另一方面由于已知类特征类间差异性大小还会影响特征空间中“低响应区域”（即已知类特征分布内侧且与已知类特征分布不交叠的区域）的大小，而根据先验认知，未知类特征一般位于此区域^[17]，故特征提取网络对已知类特征的学习能力还决定了模型学习完成后是否能为测试阶段低特征响应值的未知类特征分布留出足够的空间，从而间接影响了已知类与未知类的鉴别性，最终影响对未知类的拒判性能。通过以上考虑，本文中特征提取网络 E 选用SAR目标识别中常用的、对训练类别具有较强特征类间可分性的ResNet-50^[18]（包括卷积层、最大池化层、4个残差块层和平均池化层，具体结构同文献^[18]）作为基础特征提取网络。

记特征提取网络 E 的非线性映射为 $\mathbf{f}_\theta(\mathbf{X})$ ， $\mathbf{X}$ 为原始输入图像， θ 为网络 E 的待学习参数。在原型学习过程中，特征提取网络 E 与原型参数 $\mathbf{M}$ 以端到端的方式共同学习，则将样本 $\mathbf{X}$ 归属于原型 $\mathbf{m}_i$ 的概率表示为

$$p(\mathbf{X} \in \mathbf{m}_i | \mathbf{X}) = \frac{e^{-d(\mathbf{f}_\theta(\mathbf{X}), \mathbf{m}_i)}}{\sum_{k=1}^{N_k} e^{-d(\mathbf{f}_\theta(\mathbf{X}), \mathbf{m}_k)}} \quad (2)$$

其中， $d(\mathbf{f}_\theta(\mathbf{X}), \mathbf{m}_i) = \|\mathbf{f}_\theta(\mathbf{X}) - \mathbf{m}_i\|_2^2$ ，表示特征 $\mathbf{f}_\theta(\mathbf{X})$ 与原型 $\mathbf{m}_i$ 之间的距离。确定 $p(\mathbf{X} \in \mathbf{m}_i | \mathbf{X})$ 的定义后，定义原型对比损失 L_{PRO}

$$L_{\text{PRO}}(\mathbf{X}; \theta, \mathbf{M}) = -\ln p(\mathbf{X} \in \mathbf{m}_i | \mathbf{X}) \quad (3)$$

2.2.2 未知类特征生成与模型更新模块

本模块面对真实未知类特征易与已知类特征发生混淆的开放场景，在闭集训练完成的基础上，结合对潜在未知类特征分布的先验认知，预先生成未知样本特征，提升特征空间中已知类和未知类的可分性，具体流程如图4所示。在闭集训练完成的基础上，本模块挑选各已知类的部分内侧边界样本特征并利用mix-up方法生成未知类，通过未知类距离损失 L_{GEN} 和已知类原型损失 L_{PRO} 共同约束已知类特征与未知类特征的特征分布，训练收敛后实现各已知类间特征分布的进一步推远以及已知类/生

成未知类特征之间的远离, 从而保证特征空间良好的已知类间、已知类/未知类间可分性, 为后续决策边界求解的准确性提供基础。

文献[17]讨论了已知类、未知类特征在特征空间的分布情况, 认为由于已知类别有样本参与训练过程, 故网络学到的特征模式与已知类特征模式相匹配。因此, 已知类样本经网络特征提取后, 特征响应值较高, 位于特征空间的外侧; 相应的, 未知类别缺乏样本参与训练, 基于已知类学习后的网络学到的特征模式与未知类特征匹配度较低, 故未知类样本特征在特征空间中响应值较低, 位于特征空间的中心附近。基于此先验认知, 本文结合mix-up策略在原型网络学习的基础上生成未知类特征。

mix-up^[19]技术通过随机挑选样本并利用它们的凸组合生成新样本, 是一种使用广泛的数据增强方法。随机挑选样本 x_i, x_j , 其对应标签为 y_i 和 y_j 。mix-up通过式(4)生成样本及对应标签

$$\begin{cases} \tilde{x} = \lambda x_i + (1 - \lambda) x_j \\ \tilde{y} = \lambda y_i + (1 - \lambda) y_j \end{cases} \quad (4)$$

其中, 凸组合系数 λ 从分布 $\text{Beta}(\alpha, \beta)$ 中随机采样 (超参数 α, β 人为预设)。基于对已知类、未知类特征分布的如上认知, 本模块采用mix-up技术, 利用ResNet-50平均池化层输出的各已知类特征 (即ResNet-50的最后一层特征) 生成潜在未知类特征。图5给出了两种不同mix-up策略下的生成未知类样本特征示意。图5中暗蓝色、黑色和灰色圆圈分别代表不同类别的原型, 其他绿色、紫色和橙色圆圈分别代表不同类别的已知样本特征。亮蓝色圆圈代表生成未知样本特征。如果采用现有对所有已知类特征进行异类特征两两mix-up组合生成未知类的方式 (简称为随机mix-up, 如图5(a)所示), 那么各已知类中的每个样本特征均与其他已知类中的任一样本特征进行凸组合, 由于凸组合系数的随机性, 任意两个异类样本特征生成的未知类特征既可能位于这两类特征的中央也可能位于某一类特征分布之内, 如图5(a)所示的红圈内未知类特征。位于已知类类内的生成特征并不能准确表示未知类特征, 利用这些特征更新模型反而会影响未知类决策边界学习。因此, 本模块改进了mix-up生成技术, 使之适用于




图4 未知类特征生成与模型更新模块示意图




图5 已知类特征随机mix-up与挑取内侧边界特征mix-up产生未知类特征示意图

开放环境。在利用已知类特征生成未知类特征时,仅挑选各已知类内侧边界样本特征(如图5(b)中的深绿、深紫和深橙色圆圈),然后对所有已知类内侧边界特征进行异类特征的两两mix-up组合,如图5(b)所示。这样可以避免生成大量位于已知类分布内的未知类特征,生成的未知类特征更为合理,更能准确反映真实未知类特征分布规律。

对于各已知类内侧边界特征,其挑选方法如下:对于任一已知类特征,对该类特征按模值大小从小到大排序,根据内侧边界特征模值通常小于外侧边界特征模值和中问特征模值的先验认知,本文挑选一定比例的、具有小模值的特征作为该已知类的内侧边界特征。所有已知类内侧边界特征确定后,对任意两个异类内侧边界特征进行mix-up组合,生成一个未知类特征。

在采用改进mix-up方法生成潜在未知类特征

后,如图6所示,利用已知类原型损失与未知类距离损失更新原型网络,总损失函数如式(5)所示

$$\begin{aligned} L_{\text{total}} &= L_{\text{PRO}} + L_{\text{GEN}} \\ &= L_{\text{PRO}}(\mathbf{X}; \theta, \mathbf{M}) \\ &\quad + H(\text{softmax}(d(\mathbf{X}_{\text{GEN}}, \mathbf{M})), U_{N_k}) \end{aligned} \quad (5)$$

其中, $d(\mathbf{X}_{\text{GEN}}, \mathbf{M})$ 表示生成未知类特征 $\mathbf{X}_{\text{GEN}}$ 与各已知类原型 $\mathbf{M}$ 之间的距离, U_{N_k} 为 N_k 类别的均匀分布, $H(p, q)$ 表示 p 和 q 两分布的交叉熵损失。已知类原型损失旨在不断拉开各已知类特征之间的距离,而未知类距离损失通过约束生成未知类特征与各已知类原型距离相等,从而使各已知类特征远离未知类特征,提升了已知类与未知类特征的鉴别性,更有利于对未知类的拒判任务,算法1给出了未知类特征生成与模型更新模块的具体流程。

2.2.3 极值拟合模块

本模块经闭集训练模块与未知类特征生成与模

算法1 未知类仿制与模型更新流程

输入: 训练数据 $\{\mathbf{X}_i\}_{i=1}^{N_k}$; 特征空间中的各类初始化原型 $\mathbf{M}_0$; 特征提取网络 $\mathbf{E}$ 的初始化参数 θ_0 ; 超参数 λ ; 已知类类别数 N_k ; 已知类内侧边界特征挑选比例 K ; 学习率 μ ; Beta分布的参数 α, β ; 迭代次数 $t \leftarrow 0$ 。

输出: 原型参数 $\mathbf{M}$, 更新后的网络参数 θ 。

- (1) while not converge do
- (2) $t \leftarrow t + 1$
- (3) 按照比例 K 从各已知类中挑选较小模值的特征, 记为 $\{(\mathbf{f}_{\theta^t}(\mathbf{X}_{1,1}), \dots, \mathbf{f}_{\theta^t}(\mathbf{X}_{1,k}), \dots), \dots, (\mathbf{f}_{\theta^t}(\mathbf{X}_{i,1}), \dots, \mathbf{f}_{\theta^t}(\mathbf{X}_{i,m}), \dots)\}$;
- (4) for $i = 1: N_k$ do
- (5) for $j = i + 1: N_k$ do
- (6) 任意挑选 k, m do
- (7) 利用已知类特征的凸组合, 生成未知样本特征 $\mathbf{X}_{\text{GEN}} = \lambda \mathbf{f}_{\theta^t}(\mathbf{X}_{i,k}) + (1 - \lambda) \mathbf{f}_{\theta^t}(\mathbf{X}_{j,m})$, 其中 $\lambda \sim \text{Beta}(\alpha, \beta)$;
- (8) 计算已知类原型损失 $L_{\text{PRO}}^t = L_{\text{pro}}(\mathbf{X}; \theta, \mathbf{M})$;
- (9) 计算未知类距离损失 $L_{\text{GEN}}^t = H(\text{softmax}(d(\mathbf{X}_{\text{GEN}}, \mathbf{M})), U_{N_k})$;
- (10) 计算总损失 $L^t = L_{\text{PRO}}^t + \lambda L_{\text{GEN}}^t$
- (11) 更新原型、网络参数 $\{\theta, \mathbf{M}\}$: $\theta^{t+1} = \theta^t - \mu \frac{\partial L^t}{\partial \theta^t}$, $\mathbf{M}^{t+1} = \mathbf{M}^t - \mu \frac{\partial L^t}{\partial \mathbf{M}^t}$;
- (12) end while
- (13) end while




图6 结合生成未知类特征与已知类特征的闭集模型更新示意图

型更新模块训练完成后, 对各已知类特征到对应原型的距离从大到小进行排序, 记集合 D_i 包含了第 i 类所有样本特征与第 i 类原型间的距离(已按值从大到小排序), 随后每类挑选一定比例的极大距离基于极值理论进行概率分布拟合, 得到各已知类极值分布的概率密度函数 f_i 与累计分布函数 F_i , 具体流程如图7所示。

极值理论由著名统计学家Frshet等人^[21]于上世纪20年代提出, 该定理分析了顺序统计量的极限渐进行为; 该定理表示当一组随机变量独立同分布时, 在满足一定正则性条件的基础上, 其极大值的分布种类为Gumbel, Fréchet和Weibull分布其中之一, 其描述如定理1所示。

定理1(Fisher-Tippett-Gnedenko定理/极值理论): 若 $v_1, v_2, \dots, v_n$ 独立同分布于 $f(v; \theta)$, 令 $\zeta_n = \max\{v_1, v_2, \dots, v_n\}$, 若存在实序列 $\{\alpha_n, \beta_n\}$ 满足两个条件

$$\{\beta_n\} > 0 \quad (6)$$

$$\lim_{n \rightarrow \infty} P((\zeta_n - \alpha_n/\beta_n) \leq z) = H(z) \quad (7)$$

则 $H(z)$ 为非退化分布函数, $H_\gamma(z)$ 可表示为

$$H_\gamma(z) = \begin{cases} \exp(-e^{-z}), & \gamma = 0 \\ \exp(-(1-\gamma z)^{\frac{1}{\gamma}}), & \gamma \neq 0 \end{cases} \quad (8)$$

其中, $1-\gamma z > 0$ 。当 $\gamma = 0, \gamma < 0, \gamma > 0$ 时, 分别服从Gumbel, Fréchet和Weibull分布。取 $\{\alpha_n\} \equiv 0, \{\beta_n\} \equiv 1$, 则有 $\{v_i\}$ 序列的极大值服从以上3种分布之一。由此可以知道, 在所提原型学习的框架下, 同类样本特征到类原型距离的极大值服从3种分布之一。图8给出了3种分布在不同参数取值下的概率密度函数。从图8可以看出只有Weibull分布在形状参数 $k > 1$ (图8中对应 $k = 1.5, \lambda = 1$ 的绿色虚线) 时, 概率密度曲线先上升, 后迅速衰减至0, 而当Weibull分布的形状参数 $0 < k < 1$ 时, Weibull分

布与Gumbel分布和Fréchet分布一样, 随着变量取值的增加, 概率密度函数单调递减。因此, Weibull分布在形状参数变化时概率密度函数呈现不同的函数形态, 能刻画不同的极大值分布规律, 对极大值分布规律表征的全面性强于Gumbel分布和Fréchet分布。本文利用极值理论对各已知类边界样本特征离对应类原型的极大距离进行概率拟合, 由于边界特征与原型距离恒为正数, 且边界特征到对应原型距离取值的概率密度并不一定随距离的增大而严格减小, 可能呈现先增加再减小的趋势(见3.3.2极值拟合结果图)。因此, 本文选择用Weibull分布进行极大距离拟合, 具体拟合过程如算法2所示。

2.2.4 基于分类得分修正的开集测试模块

本模块在极值拟合模块所得各已知类边界特征分布的基础上, 利用边界样本特征的极值分布对模型的闭集分类得分进行修正, 以获得开集环境下的开集分类得分, 从而实现属于未知类概率的自动计算, 同时规避生成式方法存在的决策界面学习不准确的缺陷, 具体流程如图9所示。


如图9所示, 记待测样本为 $\tilde{\mathbf{X}}$, 经特征提取网络映射后, 得到其特征表示为 $\mathbf{f}_\theta(\tilde{\mathbf{X}})$ 。通过衡量与各原型的距离, 得到距离 d'

$$d' = (d'_1, d'_2, \dots, d'_{N_k}) \quad (9)$$

其中 $d'_i = \|\mathbf{f}_\theta(\tilde{\mathbf{X}}) - \mathbf{m}_i\|^2$, 表示待测样本特征与第 i 个已知类原型的距离。经softmax归一化后可得闭集分类概率 $\mathbf{p}$

$$\mathbf{p} = \text{softmax}(-d') = (p_1, p_2, \dots, p_{N_k}) \quad (10)$$

其中 $\mathbf{p} \in \mathbb{R}^{N_k}$, p_i 表示待测样本属于第 i 个已知类的闭集分类得分。极值拟合模块确定了各类特征与对应原型极大距离的概率分布, 将待测样本特征与各原型的距离 $d'_1, d'_2, \dots, d'_{N_k}$ 带入对应类所得极值分布的累计分布函数中得到该样本在各已知类极值累计






图8 不同参数取值下的3种分布的概率密度函数曲线

分布函数值 $\{F_{\text{weibull}}(d'_i; \lambda_i, k_i)\}_{i=1}^{N_k}$ 。累计分布函数呈单调递增特性，待测样本特征与第 i 个已知类原型距离越大时，在该已知类上 $F_{\text{weibull}}(d'_i; \lambda_i, k_i)$ 也越大。由于离类原型距离越大，越不属于该已知类，因此， $F_{\text{weibull}}(d'_i; \lambda_i, k_i)$ 越大，待测样本属于第 i 类的可能性就越小。相反，当待测样本特征离第 i 个已知类原型距离越小时， $F_{\text{weibull}}(d'_i; \lambda_i, k_i)$ 也越小。由于离类原型距离越小，越可能属于该已知类，因此， $F_{\text{weibull}}(d'_i; \lambda_i, k_i)$ 越小，待测样本属于第 i 类的可能性就越大。考虑到 $F_{\text{weibull}}(d'_i; \lambda_i, k_i)$ 取值大小与待测样本属于对应已知类的可能性呈负

相关，本文在利用 $F_{\text{weibull}}(d'_i; \lambda_i, k_i)$ 对测试样本在各已知类上的闭集分类得分修正时，赋予闭集分类得分 $(1 - F_{\text{weibull}}(d'_i; \lambda_i, k_i))$ 的修正量，即

$$\eta_i = (1 - F_{\text{weibull}}(d'_i; \lambda_i, k_i)) \quad (11)$$

$$p'_i = p_i \times \eta_i \quad (12)$$

其中 η_i 表示待测样本在第 i 个已知类上的闭集分类得分修正量。这样即可保证待测样本离已知类原型远时，在该已知类上的得分低，当待测样本离已知类原型较近时，在该已知类上的得分高，满足实际“离原型越近越可能属于该已知类”的规律。

进一步，待测样本属于未知类的概率 p_u 为

$$p_u = 1 - \sum_{i=1}^{N_k} p'_i \quad (13)$$

最终开集分类得分向量 $\mathbf{p}_u$ 可表示为

$$\mathbf{p}_u = (p'_1 p'_2 \cdots p'_{N_k} p_u) \quad (14)$$

最终基于最大后验概率给出开集场景下的类别推断

$$y = \arg \max (\mathbf{p}_u) \quad (15)$$

3 实验结果与分析

3.1 数据集

本文实验在运动和静止目标获取与识别(Moving and Stationary Target Acquisition and Recog-

算法2 极值拟合流程

输入：训练数据 $\{\mathbf{X}_i\}_{i=1}^{N_k}$ ；特征空间中的各类已知类原型 $\mathbf{M}$ ；特征提取网络的参数 θ ；用于拟合极值分布的极值个数挑选比例 L ；

输出：各已知类特征离类原型的极大距离所服从的威布尔分布函数参数 $\{F_{\text{Weibull}}(\mathbf{X}; \lambda_i, k_i)\}_{i=1}^{N_k}$

(1) for $i = 1 : N_k$

(2) 将训练数据 x_i 通过特征提取网络，得到对应特征 $\mathbf{f}_\theta(\mathbf{X}_i)$ ；

(3) 按类别计算样本特征与对应类原型的距离 $d_i = \|\mathbf{f}_\theta(\mathbf{X}_i) - \mathbf{m}'_i\|_2^2$ ，每类距离从小到大排序，按比例 L 选取取值较大的距离，构成距离向量 $\mathbf{D}_i = [d_{i1}, d_{i2}, \dots]$ ，其中 d_{ik} 表示第 i 个已知类的第 k 个极大值样本；

(4) 采取极大似然估计的方法拟合各类的极值分布参数 λ_i, k_i 。

(5) end




图9 基于分类得分修正的开集测试流程示意图

nitition, MSTAR)数据集^[21]上验证。MSTAR数据集由美国Sandia国家实验室收集,是当前主流的评价SAR图像目标识别性能的基准数据集。该数据集中包括许多不同方位角和俯仰角下的地面军事车辆目标的SAR图像,图像分辨率为0.3 m×0.3 m,图像的尺寸为64×64。共包含步兵战车BMP2、装甲车BTR70、主战坦克T72、自行榴弹炮2S1、装甲侦察车BRDM、装甲车BTR60、军用推土机D7、主战坦克T62、军用卡车ZIL131和自行防空火炮ZSU23/4共记10类军事车辆目标。图10展示了10类不同地面目标的SAR图像及其对应的光学图像示例,可以看出,SAR图像的视觉可分性较差,开集识别难度高于光学图像。

MSTAR数据集包含17°和15°两种俯仰角,本文将俯仰角为17°的SAR图像目标作为训练集,俯仰角为15°的SAR图像目标作为测试集。根据类别数目和型号数量的不同,通常将MSTAR数据集细分为3类7型、10类10型、10类14型等子数据集,本文在较为常用的10类10型子数据集进行SAR图像目标开集识别实验。10类10型的训练测试集划分如表1所示。

3.2 评价准则及实验设置

为了衡量在不同已知类、未知类数目的设定下开集识别任务的难易程度。Scheirer^[22]引入了开放度的概念,其定义为




图 10 MSTAR 10类不同地面目标的SAR图像及其对应的光学图像示例

$$o = 1 - \sqrt{\frac{2 \times N_{\text{train}}}{N_{\text{train}} + N_{\text{test}}}} \quad (16)$$

其中, N_{train} 为训练样本种类数, N_{test} 为测试样本种类数。为公平起见,本文分别在开放度为9.25%, 13.40%, 24.41%(对应已知类类别分别为: 7, 6, 4)下各随机挑选已知、未知类的划分,重复5次实验,以5次开集实验的平均值作为当前开放度下的评价指标。本文实验中各开放度情况下5次随机实验的已知类、未知类具体划分统计如表2所示。

本文采用F1-score和准确率Accuracy指标作为性能评价指标。用 TP_i 表示正确识别第*i*类已知类目标的数量;用 FN_i 表示错误识别第*i*类目标为其他类别的数量;用 FP_i 表示错误识别其余类目标为第*i*类的数量。F1-score和Accuracy由式(17)–式(20)计算得到

$$\text{Precision}_i = \frac{TP_i}{TP_i + FP_i}, \text{Recall}_i = \frac{TP_i}{TP_i + FN_i} \quad (17)$$

$$\left. \begin{aligned} \text{Precision} &= \frac{\sum_{i=1}^{N_k} \text{Precision}_i}{N_k} \\ \text{Recall} &= \frac{\sum_{i=1}^{N_k} \text{Recall}_i}{N_k} \end{aligned} \right\} \quad (18)$$

$$\left. \begin{aligned} \text{F1-score}_i &= \frac{2 \times \text{Precision}_i \times \text{Recall}_i}{\text{Precision}_i + \text{Recall}_i} \\ \text{F1-score} &= \frac{\sum_{i=1}^{N_k} \text{F1-score}_i}{N_k} \end{aligned} \right\} \quad (19)$$

$$\text{Accuracy} = \frac{\text{TN} + \sum_{i=1}^{N_k} TP_i}{U} \quad (20)$$

其中,查准率Precision反映了识别为已知类的结果中识别正确的比例,查全率Recall反映了真实已知类目标中被正确识别的比例。F1-score是查准率Precision和查全率Recall的调和平均值。准确率Accuracy反映了开集模型对测试数据集整体的识别指标,既包括对已知类测试样本的准确识别,也包括对未知类测试样本的准确拒判。

表 1 MSTAR数据集10类10型的训练测试集划分

	2S1	BMP2	BRDM2	BTR70	BTR60	D7	T62	T72	ZIL131	ZSU234
训练样本数	299	233	298	233	256	299	299	232	299	299
测试样本数	274	196	274	196	195	274	273	196	274	274

表 2 不同开放度下的已知类与未知类划分

开放度(%)	随机实验	已知类	未知类
9.25	实验1	BMP2 BTR70 T72 2S1 BRDM2 BTR60 D7	T62 ZIL131 ZSU234
	实验2	BMP2 BTR60 2S1 D7 T62 ZIL131 ZSU234	BMR70 T72 BRDM2
	实验3	BTR70 T72 BRDM2 BTR60 D7 T62 ZIL131	BMP2 2S1 ZSU234
	实验4	2S1 BRDM2 BTR60 D7 T62 ZIL131 ZSU234	BMP2 BTR70 T72
	实验5	BTR70 2S1 T72 BTR60 T62 ZIL131 ZSU234	BMP2 BRDM2 D7
13.40	实验1	BMP2 BTR70 T72 2S1 BRDM2 BTR60	D7 T62 ZIL131 ZSU234
	实验2	BMP2 BTR60 2S1 D7 T62 ZIL131	ZSU234 BMR70 T72 BRDM2
	实验3	BTR70 T72 BRDM2 BTR60 D7 T62	ZIL131 BMP2 2S1 ZSU234
	实验4	2S1 BRDM2 ZSU234 D7 T62 ZIL131	BMP2 BTR70 T72 BTR60
	实验5	BTR70 2S1 T72 BTR60 T62 ZSU234	ZIL131 BMP2 BRDM2 D7
24.41	实验1	BMP2 BTR70 BTR60 D7	BRDM2 T62 ZIL131 ZSU234 2S1 T72
	实验2	BMP2 BTR60 2S1 D7	T62 ZIL131 ZSU234 BMR70 T72 BRDM2
	实验3	BTR70 T72 BRDM2 BTR60	D7 T62 ZIL131 BMP2 2S1 ZSU234
	实验4	2S1 BRDM2 ZSU234 D7	T62 ZIL131 BMP2 BTR70 T72 BTR60
	实验5	BTR70 2S1 T72 ZSU234	BTR60 T62 ZIL131 BMP2 BRDM2 D7

在所有开集实验中,网络使用相同的训练超参数,初始化采取kaiming初始化;优化器选取SGDM优化器,动量设置为0.9,权重衰减率设置为0.000 1;原型维度为2 048;批大小 m 为32;超参数 λ ,Beta分布中的 α 和 β 分别设置为0.5, 2和2;初始学习率设置为0.01,分别在第90, 180, 270轮次开始时将学习率衰减为当前学习率的1/10;训练的轮次为300。

实验中,未知类特征生成模块中的各已知类内侧边界样本特征挑选比例 K 与极值拟合模块中各已知类特征与对应类原型距离极大距离的挑选比例 L 通过交叉验证的方式确定。具体地,先从已知类训练集里随机挑选一部分类别(挑选类别数占已知类类别数的70%),再从这些类别中各类抽取80%的样本分为新的训练集,挑选类别中各类剩余的20%样本与未挑选类别的所有样本共同作为验证集,利用新的训练集进行不同内侧边界样本特征挑选比例/极大值挑选比例情况下的开集模型学习。随机多次已知类类别挑选实验后分别计算不同内侧边界特征挑选比例/极大值挑选比例情况下的验证集平均F1-score,最高F1-score对应的内侧边界特征挑选比例/极大值挑选比例选择为最优比例,并按此比例开展基于全部已知类数据的开集识别模型学习。本文交叉验证实验中已知类内侧边界特征挑选比例/极大值挑选比例从5%开始设置,按步长5%增加至30%,已知类中进一步的类别随机挑选次数设置为5次。根据上述交叉验证方法确定了不同开放度下最优的内侧边界特征挑选比例/极大值挑选比例均为10%。

此外,由于不同开放度实验已知类数量不同,各开放度情况下每次随机实验已知类数量存在差异,因此,不同开放度设置、相同开放度不同已知类、未知类划分下产生的未知类特征数均不同。

本文实验的计算机配置信息及软件信息如下:操作系统Windows 11,处理器AMD Ryzen 7 5800-8-Core Processor @3.4GHz,显卡NVIDIA GeForce RTX 3060,集成开发工具PyCharm,深度学习框架PyTorch。

3.3 实验结果及分析

3.3.1 开集识别性能与分析

表3为所提方法及通用对比方法的开集实验结果。其中Softmax+概率阈值方法通过在得分空间设置概率阈值实现对未知目标的拒判,作为该组对比的基线。该方法已知类特征分布散布较大,易与未知类特征发生混淆,通过概率阈值难以拒判这部分未知类,因此在F1-score和准确率两个指标上均远低于其余方法。广义卷积原型学习(Generalized Convolutional Prototype Learning, GCPL)为文献[8]于2020年提出的方法,该方法利用原型对比损失取代交叉熵损失,并基于闭集分类得分设置阈值,实现对未知类的区分。从结果来看,因原型对比损失能有效限制已知类特征分布,尽可能减少了未知类与已知类特征的混淆,因此在不同开放度下F1-score指标较基线均有7%左右的提升,准确率指标有4%~6%的提升。相反点学习(Reciprocal Point Learning, RPL)为文献[23]于2020年提出的方法,该方法提出了“相反点”的概念用来取代原型,

表 3 所提方法及对比方法开集实验结果(%)

开集识别方法	开放度	Accuracy	Precision	Recall	F1-score
Softmax+概率阈值	9.25	82.14	84.68	90.58	87.82
	13.40	76.09	68.45	86.92	70.45
	24.41	60.45	52.82	84.28	61.26
GCPL ^[8]	9.25	88.41	94.48	93.88	93.69
	13.40	80.52	76.14	88.21	78.86
	24.41	64.85	60.74	86.52	68.43
RPL ^[23]	9.25	88.83	94.82	93.97	94.02
	13.40	82.76	77.29	89.65	79.74
	24.41	65.25	63.48	85.02	68.48
DIAS ^[12]	9.25	93.08	95.90	96.03	96.01
	13.40	84.25	82.36	89.42	82.14
	24.41	70.99	68.17	88.90	72.43
所提方法	9.25	94.38	96.03	96.58	96.86
	13.40	84.62	83.40	92.38	84.68
	24.41	73.99	70.25	89.24	74.28

“相反点”的学习过程更有利于类间差异特征的提取，在性能指标上较，GCPL有小幅提升。困难感知模拟器(Difficulty-Aware Simulator, DIAS)为文献[12]于2022年提出的方法，该方法生成具有不同难度的未知类样本模拟真实未知类的分布，能进一步提升未知类的拒判性能。本文所提方法既利用生成样本特征提升了已知、未知样本的鉴别性，又利用已知类边界样本确定了未知类决策边界，优于生成方法DIAS中利用生成样本确定未知类决策边界，在各开放度下，准确率和F1-score指标均达到最优。

上述对比方法主要为光学图像分类领域常用的开集识别方法，是通用性方法。为进一步验证所提方法在针对SAR图像方面的优势，表4给出了所提方法与文献[14]所提出的SAR目标开集识别方法(分别简称为OsmIL和GvRSC)的性能指标对比。此实验中，本文基于文献中所给出的已知类与未知类划分(T72,BMP2,BTR70作为已知类，其余7类作为未知类)进行对比实验，且OsmIL和GvRSC结果均直接从文献里摘录，可以看出本文所提方法在Precision、Recall和F1-score指标均高于对比方法，体现了本文所提方法在SAR目标开集识别方面的优越性。

3.3.2 模型分析

所提方法中涉及未知类特征生成与分类得分修正两个措施提升开集识别性能，为验证其合理性及不同参数设置对开集实验性能的影响，进行如下实验分析。

(1)未知类特征生成策略有效性分析。本文采

表 4 所提方法与现有SAR开集识别方法对比(%)

方法	Precision	Recall	F1-score
OsmIL ^[14]	87.0	93.4	89.9
GvRSC ^[14]	67.8	73.2	69.2
本文方法	93.4	95.7	94.1

用未知类特征生成策略生成潜在未知样本特征，并通过未知类损失进一步提升已知、未知特征的差异性。为直观展示该策略的合理性，挑选BMP2, BTR70, BTR60, D7共4类作为已知类，其余类别作为未知类进行下述实验。

图11绘制了在利用已知样本特征mix-up生成未知特征过程中，采取随机选择策略或挑选内部特征两种生成方式下已知类和生成未知类特征的特征可视化结果。

图11中，灰色表示采取不同策略生成样本特征，其余颜色表示已知样本特征。如图11(a)所示，在随机挑选策略下，部分生成特征与已知类发生重叠，这部分特征经过未知类损失约束后，将不利于已知类的识别任务，造成识别结果的下降。而本文所改进的挑选内部样本mix-up的方法生成未知特征与已知特征重叠较小，更能反映真实未知特征的分布，因而在开放场景下更具优势。

图12展示了真实未知类特征与mix-up生成特征的t-SNE可视化结果。从图12可以看出，所提方法生成样本具备一定的丰富性，其分布基本涵盖了真实未知特征的分布。为进一步验证特征生成模块的作用，图13展示了有无该生成策略的测试样本t-SNE




图 11 已知样本特征随机挑选和挑选内部特征mix-up生成的未知样本特征可视化




图 12 真实未知类特征分布与生成样本特征分布的t-SNE可视化

可视化结果。从图13(a)可以看出, 没有该策略时, 测试阶段的未知类特征散布较广, 且与已知类特征发生较大面积的重叠, 这意味着未知类拒判难度大; 当加入该模块后, 未知类样本特征得到了有效的收缩, 且与已知类特征重叠部分较小, 降低了未知类的区分难度, 也证明了该策略的有效性。

以上通过t-SNE特征可视化结果直观体现了未知类特征生成策略的有效性, 图14给出了在不同特征生成策略下实验的F1-score指标。可以看出采取使用生成未知类策略能相较不使用有接近3%的性

能提升, 通过改进mix-up方式, 能进一步获得1.12%的指标提升, 从而体现了所提生成策略的有效性。

(2)分类得分修正策略有效性分析。为自动确定未知类拒判概率, 本文引入了分类得分修正策略。训练时计算各已知类样本特征到原型的距离, 拟合极大距离服从的威布尔分布函数参数, 测试时基于待测样本在各类极值分布上的概率得分, 对闭集分类得分进行修正。

为检验极值分布拟合的准确性, 图15绘制了4个已知类极值拟合的结果。具体地, 首先计算了训练阶段各已知类目标特征与对应原型的距离, 然后选取了各已知类前10%个(根据交叉验证方式确定)较大距离值作为极值样本, 再对各已知类各极值样本减去该类极值样本最小值(即对各已知类极值样本平移最小极值的距离, 此操作是为了便于直观理解、对比不同已知类的极值分布图, 测试过程中计算待测样本特征与各已知类原型距离后, 也会先减去对应已知类训练阶段的最小极值再输入各已知类极值累积分布函数估计分类得分修正量以保证修正量的准确性), 图15给出了已知类极值样本平




图 13 有无未知类特征生成策略的测试已知类样本与未知类样本的t-SNE特征可视化




图 14 不同未知类生成策略下的F1-score指标

移后的分布直方图和基于Weibull分布的概率密度函数曲线拟合结果。

从图15中可以看出，极值拟合模块能较好地拟合各已知类特征极大距离。在此基础上，如式(11)所示，定义待测样本在各已知类上的修正量为 η ，并利用修正量对模型的闭集分类结果进行修正，修正量 η 对于已知类来讲，为不影响其正确分类，值应较大，对于未知类而言为了实现正确拒判，修正

量应较小。图16(a)–图16(d)分别统计了测试阶段BMP2, BTR70, BTR60, D7测试样本的修正量 η 的各维取值，一行表示一个测试样本的修正量向量(向量各元素取值范围为0~1)，颜色越亮表示在对应横坐标的类别上修正量值越大。图16(e)统计了测试阶段的未知类样本的修正量 η 的各维取值。从图16可以看出，各已知类测试样本在对应类别上的修正量最大(接近于1)，保证了已知类的准确识别，同时，未知类测试样本在各已知类上的修正量都很小(基本均小于0.3)，则会使这些样本在各已知类上的得分均降低，从而保证其属于未知类的概率较大，实现未知类准确判断。

为探究该模块对识别性能的影响，在均使用改进mix-up生成策略的情况下，实验编号(1)未加入分类得分修正模块(人工设置拒判阈值)，编号(2)加入分类得分修正模块，实验结果如表5所示。较不加入分类得分修正模块，F1-score指标提升1.8%，显示了所提策略的优越性。

3.3.3 超参数分析

所提方法未知类特征生成模块中已知类内侧边界特征挑选比例 K 和极值拟合模块中各已知类极值




图 15 4类已知类特征与对应类原型距离的极大值分布柱状图与基于Weibull分布的概率密度函数拟合结果




图 16 4类已知类测试样本及未知类测试样本的修正量统计图

个数挑选比例 L 均会对开集识别性能产生影响。本文通过3.2节所述的交叉验证方法分别确定了不同开放度情况下最优 K 与最优 L 均为10%，本小节主要对已知类内侧边界特征挑选比例与极值个数挑选比例对开集识别性能的影响与所采取交叉验证策略的合理性进行分析。

(1)已知类内侧边界特征挑选比例分析。内侧边界样本特征挑选比例过高会生成位于已知类特征分布内部、与已知类十分相近的未知类特征，利用这些未知类特征更新闭集模型推远已知类特征的过程中，由于已知类、未知类的高度相似性，部分已知类特征会被误认为是未知类特征难以被推远，最终测试阶段很容易已知类拒判为未知类；内侧边界样本特征挑选比例过低会难以表示与已知类边界特

表 5 消融实验设置

实验编号	未知类特征生成	分类得分修正	F1-score(%)
(1)	✓	×	72.48
(2)	✓	✓	74.28

征分布交叠的难分未知类特征，利用这些表征能力有限的未知类特征更新闭集模型后仍然难以对实际易混淆的难分已知类、未知类特征进行准确区分。因此已知类内侧边界特征挑选比例过高或者过低均会影响本文所提开集识别方法的性能。

图17给出了不同开放度情况下所提开集识别方法在MSTAR数据集上的F1-score随已知类内侧边界特征挑选比例的变化曲线(全部已知类训练数据在不同挑选比例情况下学习，已知类测试数据和真

实未知类数据分别在不同挑选比例对应的已学模型上识别)。从图17可以看出, 已知类边界特征挑选比例确实对开集识别性能有明显影响, 比例过高或者过低均会降低模型对已知类和未知类区分能力。而且, 在各开放度下所提开集识别方法F1-score均在挑选比例为10%时达到最大, 说明了本文利用交叉验证确定已知类内侧边界特征比例的合理性。

(2) 已知类极值个数挑选比例分析。极值拟合模块中各已知类极值数量挑选比例对已知类边界分布描述的准确度影响很大, 极值数量过多, 很可能将已知类内部特征用于拟合边界分布, 使边界向已知类内侧收缩, 容易将已知类判别为未知类; 极值数量太少, 会使边界向已知类外侧扩张, 容易将未

知类误判为某类已知类。因此已知类极值个数挑选比例过高或者过低也同样会影响本文所提开集识别方法的性能。

图18给出了不同开放度情况下所提开集识别方法在MSTAR数据集上的F1-score随不同极值数量占比的变化曲线(全部已知类训练数据在不同极值数量占比情况下学习, 已知类测试数据和真实未知类数据分别在不同极值数量占比对应的已学模型上识别)。从图18可以看出, 各已知类极值数量挑选比例确实对开集识别性能有明显影响, 且在各开放度下所提开集识别方法F1-score均在极值数量占比为10%时达到最大, 说明了交叉验证挑选策略的合理性。




图 17 不同开放度下所提开集识别方法F1-score随已知类内侧边界特征挑选比例的变化曲线




图 18 不同开放度下所提开集识别方法F1-score随极值个数挑选比例的变化曲线

需要注意的是, 在实际应用中面对不同的数据集、不同开放度, 已知类最优内侧边界特征挑选比例/最优极值个数挑选比例可能不同, 应该按照上述交叉验证方法具体确定最优挑选比例。

4 结论

本文研究了在已知类、未知类共存的开放环境下的SAR目标开集识别方法, 通过特征生成策略及分类得分修正策略提升了已知、未知样本的鉴别性, 缓解了人工设置拒判阈值/结合生成未知类学

习拒判边界的传统开集识别方法在已知/未知类决策界面确定方面的不足, 显著提升了开集识别性能。基于实测MSTAR数据的实验证明了所提方法未知类特征生成的丰富性、模型更新的有效性以及分类得分修正的合理性, 所提方法能有效实现对已知、未知目标的准确区分。

参考文献

- [1] 金亚秋. 多模式遥感智能信息与目标识别: 微波视觉的物理智能[J]. 雷达学报, 2019, 8(6): 710-716. doi: 10.12000/

- JR19083.
- JIN Yaqiu. Multimode remote sensing intelligent information and target recognition: Physical intelligence of microwave vision[J]. *Journal of Radars*, 2019, 8(6): 710–716. doi: [10.12000/JR19083](#).
- [2] LOWE D G. Distinctive image features from scale-invariant keypoints[J]. *International Journal of Computer Vision*, 2004, 60(2): 91–110. doi: [10.1023/B:VISI.0000029664.99615.94](#).
- [3] 李璐, 杜兰, 何浩男, 等. 基于深度森林的多级特征融合SAR目标识别[J]. 电子与信息学报, 2021, 43(3): 606–614. doi: [10.11999/JEIT200685](#).
- LI Lu, DU Lan, HE Haonan, *et al.* Multi-level feature fusion SAR automatic target recognition based on deep forest[J]. *Journal of Electronics & Information Technology*, 2021, 43(3): 606–614. doi: [10.11999/JEIT200685](#).
- [4] LIN Huiping, WANG Haipeng, XU Feng, *et al.* Target recognition for SAR images enhanced by polarimetric information[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2024, 62: 5204516. doi: [10.1109/TGRS.2024.3361931](#).
- [5] ZENG Zhiqiang, SUN Jinping, YAO Xianxun, *et al.* SAR target recognition via information dissemination networks[C]. 2023 IEEE International Geoscience and Remote Sensing Symposium, Pasadena, USA, 2023: 7019–7022. doi: [10.1109/IGARSS52108.2023.10282727](#).
- [6] MENDES JÚNIOR P R, DE SOUZA R M, DE O. WERNECK R, *et al.* Nearest neighbors distance ratio open-set classifier[J]. *Machine Learning*, 2017, 106(3): 359–386. doi: [10.1007/s10994-016-5610-8](#).
- [7] XIA Ziheng, WANG Penghui, DONG Ganggang, *et al.* Radar HRRP open set recognition based on extreme value distribution[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2023, 61: 5102416. doi: [10.1109/TGRS.2023.3257879](#).
- [8] YANG Hongming, ZHANG Xuyao, YIN Fei, *et al.* Convolutional prototype network for open set recognition[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022, 44(5): 2358–2370. doi: [10.1109/TPAMI.2020.3045079](#).
- [9] LU Jing, XU Yunlu, LI Hao, *et al.* PMAL: Open set recognition via robust prototype mining[C]. The 36th AAAI Conference on Artificial Intelligence, Vancouver, British Columbia Canada, 2022: 1872–1880. doi: [10.1609/aaai.v36i2.20081](#).
- [10] HUANG Hongzhi, WANG Yu, HU Qinghua, *et al.* Class-specific semantic reconstruction for open set recognition[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2023, 45(4): 4214–4228. doi: [10.1109/TPAMI.2022.3200384](#).
- [11] XIA Ziheng, WANG Penghui, DONG Ganggang, *et al.* Adversarial kinetic prototype framework for open set recognition[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2024, 35(7): 9238–9251. doi: [10.1109/TNNLS.2022.3231924](#).
- [12] MOON W J, PARK J, SEONG H S, *et al.* Difficulty-aware simulator for open set recognition[C]. The 17th European Conference on Computer Vision, Tel Aviv, Israel, 2022: 365–381. doi: [10.1007/978-3-031-19806-9_21](#).
- [13] ENGELBRECHT E R and DU PREEZ J A. On the link between generative semi-supervised learning and generative open-set recognition[J]. *Scientific African*, 2023, 22: e01903. doi: [10.1016/j.sciaf.2023.e01903](#).
- [14] DANG Sihang, CAO Zongjie, CUI Zongyong, *et al.* Open set SAR target recognition using class boundary extracting[C]. The 6th Asia-Pacific Conference on Synthetic Aperture Radar, Xiamen, China, 2019: 1–4. doi: [10.1109/APSAR46974.2019.9048316](#).
- [15] GENG Xiaojing, DONG Ganggang, XIA Ziheng, *et al.* SAR target recognition via random sampling combination in open-world environments[J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2023, 16: 331–343. doi: [10.1109/JSTARS.2022.3225882](#).
- [16] LI Yue, REN Haohao, YU Xuelian, *et al.* Threshold-free open-set learning network for SAR automatic target recognition[J]. *IEEE Sensors Journal*, 2024, 24(5): 6700–6708. doi: [10.1109/JSEN.2024.3354966](#).
- [17] XIA Ziheng, WANG Penghui, DONG Ganggang, *et al.* Spatial location constraint prototype loss for open set recognition[J]. *Computer Vision and Image Understanding*, 2023, 229: 103651. doi: [10.1016/j.cviu.2023.103651](#).
- [18] HE Kaiming, ZHANG Xiangyu, REN Shaoping, *et al.* Deep residual learning for image recognition[C]. 2016 IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, USA, 2016: 770–778. doi: [10.1109/CVPR.2016.90](#).
- [19] ZHANG Hongyi, Cissé M, DAUPHIN Y N, *et al.* mixup: Beyond empirical risk minimization[C]. The 6th International Conference on Learning Representations, Vancouver, Canada, 2018.
- [20] FISHER R A and TIPPETT L H C. Limiting forms of the frequency distribution of the largest or smallest member of a sample[J]. *Mathematical Proceedings of the Cambridge Philosophical Society*, 1928, 24(2): 180–190. doi: [10.1017/S0305004100015681](#).

- [21] ROSS T D, WORRELL S W, VELTEN V J, *et al.* Standard SAR ATR evaluation experiments using the MSTAR public release data set[C]. SPIE 3370, Algorithms for Synthetic Aperture Radar Imagery V, Orlando, USA, 1998. doi: [10.1117/12.321859](https://doi.org/10.1117/12.321859).
- [22] SCHEIRER W J, DE REZENDE ROCHA A, SAPKOTA A, *et al.* Toward open set recognition[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2013, 35(7): 1757–1772. doi: [10.1109/TPAMI.2012.256](https://doi.org/10.1109/TPAMI.2012.256).
- [23] CHEN Guangyao, QIAO Limeng, SHI Yemin, *et al.* Learning open set network with discriminative reciprocal points[C]. The Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, 2020: 507–522. doi: [10.1007/978-3-030-58580-8_30](https://doi.org/10.1007/978-3-030-58580-8_30).
- 陈 健: 男, 博士, 副教授, 硕士生导师, 主要研究方向为雷达目标检测识别与机器学习.
- 雍奇锋: 男, 硕士生, 研究方向为雷达目标识别与机器学习.
- 杜 兰: 女, 博士, 教授, 博士生导师, 主要研究方向为雷达目标识别、雷达信号处理、机器学习.
- 尹林伟: 男, 硕士生, 研究方向为雷达目标识别与机器学习.
- 责任编辑: 余 蓉