

仿真数据辅助的雷达HRRP小样本目标识别方法

陈健* 於刚 杜兰 董文强 郭昱辰

(西安电子科技大学雷达信号处理国家重点实验室 西安 710071)

摘要: 雷达高分辨距离像(HRRP)目标识别研究广泛、方法众多,特别是深度学习在雷达HRRP识别领域的应用与发展,为直接利用雷达回波实现高效、精确的目标感知提供了技术支撑。然而,深层识别网络依赖大量训练数据。对于非合作目标,受雷达系统参数、目标快速机动等因素限制,实际很难提前获取姿态完备的HRRP训练样本,深层识别网络面临学习过拟合、泛化能力显著下降的问题。针对上述问题,考虑关注目标的全姿态电磁仿真数据易获取,该文以仿真数据为辅助,从数据扩充和跨域知识迁移学习两方面来缓解小样本问题。数据扩充方面,结合一定姿态角域范围内仿真、实测HRRP在均值和方差特性两方面的差异分析,对与少量实测HRRP同角域的大量仿真HRRP样本进行线性变换,使其均值、方差满足实测域HRRP特性,实现可表征真实HRRP分布特性的数据扩充。跨域知识迁移学习方面,考虑数据扩充策略仅能实现临近姿态角的样本扩充,对仿真数据知识的利用仍不充分,所提方法利用基于生成对抗约束的域对齐策略和基于对比学习约束的类对齐策略,将具有强可分性与泛化性的仿真域全姿态数据特征和实测域特征按类拉近,进一步辅助实测域数据的学习,实现小样本识别性能的更大提升。基于3类飞机目标以及10类地面车辆目标电磁仿真和实测HRRP数据的实验表明,所提方法相较于现有小样本识别方法具有更优的识别稳健性。

关键词: 雷达目标识别; 高分辨距离像; 小样本; 仿真数据辅助; 数据扩充; 跨域知识迁移学习

中图分类号: TN957.5

文献标识码: A

文章编号: 2095-283X(2026)x-0001-22

DOI: 10.12000/JR25123

CSTR: 32380.14.JR25123

引用格式: 陈健, 於刚, 杜兰, 等. 仿真数据辅助的雷达HRRP小样本目标识别方法[J]. 雷达学报(中英文), 待出版. doi: 10.12000/JR25123.

Reference format: CHEN Jian, YU Gang, DU Lan, *et al.* Few-shot radar high-resolution range profile: target recognition with simulated data assistance[J]. *Journal of Radars*, in press. doi: 10.12000/JR25123.

Few-shot Radar High-resolution Range Profile: Target Recognition with Simulated Data Assistance

CHEN Jian* YU Gang DU Lan DONG Wenqiang GUO Yuchen

(National Key Laboratory of Radar Signal Processing, Xidian University, Xi'an 710071, China)

Abstract: Research on target recognition using radar High-Resolution Range Profiles (HRRPs) is extensive and diverse in methodology. In particular, the application and development of deep learning to radar HRRP target recognition have enabled efficient, precise target perception directly from radar echoes. However, deep learning-based recognition networks rely on large amounts of training data. For non-cooperative targets, due to limited radar system parameters and rapid target attitude variations, acquiring adequate HRRP training samples that comprehensively cover target attitudes in advance is difficult in practice. Consequently, deep recognition

收稿日期: 2025-07-15; 改回日期: 2026-01-16; 网络出版: 2026-xx-xx

*通信作者: 陈健 jianc@xidian.edu.cn

*Corresponding Author: CHEN Jian, jianc@xidian.edu.cn

基金项目: 教育部联合基金(8091B03032401), 国家自然科学基金(U24B20137, U21B2039), 航空科学基金(20230020081006)

Foundation Items: Joint Fund of the Ministry of Education of China (8091B03032401), The National Natural Science Foundation of China (U24B20137, U21B2039), The Aviation Science Foundation(20230020081006)

责任编辑: 张双辉 Corresponding Editor: ZHANG Shuanghui

©The Author(s) 2026. This is an open access article under the CC-BY 4.0 License

(https://creativecommons.org/licenses/by/4.0/)

networks are prone to overfitting and exhibit considerably degraded generalization capability. To address these issues, and given the ease of obtaining full-attitude electromagnetic simulation data for the target, this paper leverages simulated data as auxiliary information to mitigate the small-sample-size problem through data augmentation and cross-domain knowledge-transfer learning. For data augmentation, based on the analysis of differences in mean and variance between simulated and measured HRRPs within a given attitude-angle range, a linear transformation is applied to a set of simulated HRRPs spanning the same angular domain as a small set of measured HRRPs. This adjustment ensures that the simulated data's mean and variance match the characteristics of the measured HRRPs, thereby achieving data augmentation that approximates the true distributional properties of HRRPs. Meanwhile, for cross-domain knowledge transfer learning, the proposed method introduces a domain alignment strategy based on generative adversarial constraints and a class alignment strategy based on contrastive learning constraints. These approaches draw the domain features of full-attitude simulation—strong discriminability and generalizability—closer to the measured domain features on a class-by-class basis, thereby further aiding learning from the measured domain data and leading to substantial improvements in few-shot recognition performance. Experimental results based on electromagnetic simulated and measured HRRP data for three and ten types of aircraft and ground vehicle targets, respectively, demonstrate that the proposed method yields superior recognition robustness compared with existing few-shot recognition methods.

Key words: Radar target recognition; High-Resolution Range Profile (HRRP); Few-shot learning; Simulated data assistance; Data expansion; Cross-domain knowledge transfer learning

1 引言

雷达高分辨率距离像(High-Resolution Range Profile, HRRP)目标识别技术^[1-3]旨在通过提取目标后向散射回波中蕴含的目标尺寸、结构等关键判别信息,实现对目标属性、类别甚至型号的判断,在目标监测预警、侦察跟踪等军事方面和智能交通、地物勘探等民事领域方面具有不可替代的战略价值。相较于合成孔径雷达(Synthetic Aperture Radar, SAR)图像,HRRP具有数据获取便捷、处理成本低、响应速度快的优势。因此,雷达HRRP目标识别技术受到了广泛关注与深入研究,并取得了丰富的研究成果。

经典雷达HRRP目标识别方法可以大致分为以下几种。基于浅层特征提取的识别方法^[4-6]:该类方法通过人工设计或变换域分析(如时频分析、小波变换等)提取HRRP的物理或统计特征(如目标长度、散射中心分布),再设计合适的分类器实现类别判断。基于模板匹配的识别方法^[7-9]:该类方法通常预先构建不同目标、不同姿态的HRRP模板库或稀疏字典,通过度量测试样本与模板的相似性(如相关系数、重构误差)实现目标识别。基于统计建模的识别方法^[3,10,11]:该类方法基于概率模型(如高斯混合模型、隐马尔可夫模型)对HRRP的统计分布建模,通过最大似然估计或贝叶斯推断完成分类。近年来,深度学习在计算机视觉领域得到广泛应用,涌现出大量创新性的研究和方法,为雷达自动目标识别研究提供了一条新的技术途径^[12-14]。卷

积神经网络(Convolutional Neural Networks, CNN)、循环神经网络(Recurrent Neural Networks, RNN)等深层网络通过端到端的学习,能够有效挖掘HRRP数据中的深层判别特征,在雷达HRRP目标识别领域得到广泛研究。2016年,Lundén等人^[15]首先利用CNN对HRRP数据提取空间特征并用于目标识别,取得了良好的识别性能。Jithesh等人^[16]使用长短期记忆(Long Short Term Memory, LSTM)网络提取飞机目标HRRP的时序特征,通过学习HRRP间的时序相关性进行目标识别。Guo等人^[17]提出了一种循环伽马置信网络(Recurrent Gamma Belief Network, RGBN)用于雷达HRRP目标识别,利用层次化的伽马分布建模距离单元间的时间依赖关系,概率模型和深层网络优势互补,增强了特征的判别性,改善了HRRP目标识别性能。Jiang等人^[18]基于原型网络(Prototype Networks, PN),利用高置信度样本生成伪原型并修正原型的学习,增强类别特征的判别性,提升了雷达HRRP目标识别性能。

然而,深度学习方法通常高度依赖全姿态、大规模训练数据,实际应用中,特别是对于非合作目标,受雷达系统参数等系统资源和目标信噪比/探测环境/目标机动性等观测条件限制,可获取的HRRP训练样本姿态严重不完备。因此,实际能够用于HRRP目标识别的训练样本数量往往是有限的、呈现典型的小样本特性。少量训练样本情况下深层识别网络的学习易发生过拟合问题,目标识别性能显著下降^[19,20]。

基于目标先验信息,通过对感兴趣目标仿真建模及回波信号电磁仿真,可以获得目标大量仿真数据。利用电磁仿真数据知识辅助实测雷达HRRP数据,已成为小样本雷达目标识别的一种可行思路。李昱琛等人^[21]提出一种基于电磁散射计算的HRRP仿真方法,通过FEKO软件生成不同姿态角下的目标HRRP,结合少量实测数据构建混合训练集,辅助雷达HRRP目标识别任务。Ren等人^[22]使用仿真数据作为辅助数据集,结合元学习方法,实现雷达HRRP小样本目标识别。Li等人^[23]利用仿真数据辅助,引入正则化的马氏距离改进了传统PN,提升了小样本识别性能。然而,上述方法忽略了仿真和实测HRRP数据存在的域偏移问题:仿真数据虽覆盖全角域,但其分布特性与实测数据存在系统性偏差(如均值漂移等),简单、直接地使用仿真数据参与模型学习对实测HRRP的辅助性有限、影响识别性能提升空间。

在跨域数据辅助学习中,域适应方法通过跨域特征对齐实现跨域知识有效迁移^[24,25],是解决域偏移问题的有效途径。Zhou等人^[26]提出了一种基于两阶段去噪扩散概率模型的域适应HRRP目标识别方法,旨在解决雷达目标识别中因测试条件变化导致的性能下降问题,迁移不同测试条件下的共性知识。Li等人^[27]提出一种跨域雷达HRRP目标识别方法,结合元学习,通过视觉掩模提取HRRP的局部-全局特征,并设计基于布朗距离协方差的分类器,提升目标识别性能。然而,上述域适应方法存在以下局限:其一,依赖于目标域充足的训练数据以支撑跨域特征分布对齐,当目标域只有少量数据时,难以实现源域特征与目标域真实特征分布的准确对齐,迁移性能急剧下降;其二,仅将源域和目标域特征整体分布对齐,未充分考虑源域与目标域类语义对齐,源域特征的类间强区分性特性未利用。因此,将现有域适应方法直接应用于实测域(目标域)小样本情况下的识别任务,迁移效果差、识别性能提升有限。

结合电磁仿真数据,针对现有仿真数据辅助的雷达HRRP小样本识别方法以及域适应方法存在的问题,本文通过数据扩充和跨域知识迁移学习双重策略提升实测域小样本条件下的目标识别性能:一方面,在对少量实测HRRP数据和全姿态仿真HRRP数据角域划分的基础上,分析同角域仿真和实测数据的均值、方差特性差异,并通过对角域内所有仿真HRRP样本进行线性变换,使其与同角域实测HRRP均值、方差相同,从而生成符合实测分布特性的、兼具仿真数据多样性的增强样本,在数据

域层面缓解实测数据不足的问题,同时也可缓解仿真数据知识跨域迁移学习中因实测域样本少而面临的迁移效果差的问题;另一方面,设计域级与类级双层特征对齐框架,在域级通过生成对抗方式对齐仿真域与实测域整体特征分布,在类级进一步通过对比学习方式约束实测域与仿真域特征依类别对齐,利用具有强类间可分性和泛化性的全姿态大量仿真数据特征辅助实测数据特征的学习,实现仿真域知识的有效迁移,增强模型对实测数据的判别能力和泛化能力。基于3类飞机目标和10类车辆目标实测HRRP数据以及对应类别的电磁仿真HRRP数据,所提方法在每类1,5,10个实测训练样本的条件下,识别性能较直接使用小样本实测数据训练的PN、基于域对抗网络的域适应迁移学习方法和基于元学习的小样本学习方法均有显著提升,表明所提方法的小样本识别稳健性。

2 方法介绍

2.1 模型概述

本文提出的基于仿真数据辅助的雷达HRRP小样本目标识别方法整体框架如图1所示,主要包含以下两个过程。(1)仿真数据辅助的实测域数据扩充:将少量实测HRRP数据和大量仿真HRRP划分为多个小角域,在分析同角域仿真HRRP和实测HRRP均值、方差差异的基础上,对各仿真HRRP样本进行线性变换,使变换样本的均值和方差与同角域实测HRRP相同,实现实测域数据扩充。(2)仿真数据辅助的跨域知识迁移学习:该过程通过以下3个核心模块实现仿真域(源域)与实测域(目标域)特征分布的准确对齐,以实现仿真数据知识的有效迁移,进一步缓解小样本问题。(1)特征提取模块:通过一维卷积神经网络(One Dimensional Convolutional Neural Networks, 1D-CNN),从原始HRRP数据中提取具有高判别性的深层特征。(2)域对齐模块:该模块基于生成对抗网络(Generative Adversarial Network, GAN)并利用域对齐损失,将仿真域和实测域特征分布进行整体对齐,减小跨域特征差异,为跨域特征类对齐提供域特征分布一致的特征空间。(3)类对齐模块:基于PN并设计类对齐损失,约束仿真域和实测域特征类内紧致、类间分离,实现仿真域与实测域特征的按类准确对齐。所提方法通过仿真数据辅助的实测域数据扩充和跨域知识迁移学习,从数据域和特征域两个层面将仿真数据知识迁移到小样本实测域,提升了模型在小样本情况下的泛化性。




图 1 仿真数据辅助的雷达HRRP小样本目标识别方法整体框架图

Fig. 1 Overall framework diagram of simulated data-assisted few-shot radar HRRP target recognition method

2.2 仿真数据辅助的实测域数据扩充

传统数据增广方法(如随机噪声注入、时域平移或幅度扰动)虽能增加样本多样性,却无法较好地模拟HRRP的物理特性,如散射中心间距、能量分布等,导致生成样本偏离真实样本分布。相比于传统数据扩充方法,利用目标三维模型生成的电磁仿真HRRP能够更好地表征目标特性。但由于模型逼真度有限、仿真环境与实际测量环境不同,电磁仿真数据与实际实测数据存在域差异。因此,利用仿真数据辅助实测域数据扩充需要重点解决仿真域和实测域数据域差异的合理度量问题,并最终通过弥补域差异实现实测域数据的准确扩充。本文主要在分析仿真、实测HRRP分布特性差异的基础上,利用大量仿真HRRP实现满足实际HRRP分布特性的实测域数据扩充。

根据雷达HRRP成像机理^[28],雷达HRRP各距离单元回波受该距离单元内各散射点形成的自身项和散射点间的交叉项共同影响,在目标转动但不发生越距离单元走动(Motion Through Range Cell,

MTRC)时,各距离单元内散射点个数、各散射点散射强度保持稳定,即自身项基本不变,只是各距离单元内散射点之间的相对距离发生改变,从而造成交叉项的改变。由于自身项决定了HRRP回波中各距离单元是否存在散射点以及散射点的整体强度,交叉项仅对距离单元回波幅度产生细微影响。因此,在不发生MTRC对应的姿态角角域内,所有HRRP统计特性基本一致。由于各距离单元回波是距离单元内多个散射点回波的向量和,根据中心极限定理,不发生MTRC对应的姿态角内,所有雷达HRRP样本可大致认为均服从相同的高斯分布^[29]。对于不发生MTRC的同角域电磁仿真、实测HRRP,由于仿真模型在材料设置、目标结构逼真度、测量环境等方面与真实目标不可避免存在差异,其高斯分布特性不同。假设一定角域内仿真HRRP数据 x_s 服从高斯分布 $x_s \sim N(\mu_s, \Sigma_s)$,其中 μ_s 为该角域仿真数据的均值向量, Σ_s 为仿真数据的协方差矩阵(对角阵),假设相同角域内实测HRRP数据 x_r 服从高斯分布 $x_r \sim N(\mu_r, \Sigma_r)$,其中 μ_r 为实测数据的均值向量, Σ_r 为实测数据的协方差矩阵(对角阵),

则 $\mu_s \neq \mu_r$, $\Sigma_s \neq \Sigma_r$ 。考虑到实测环境(如接收机热噪声、地物杂波、大气衰减引起的随机扰动)以及载波频率随机抖动等因素, 实际雷达目标HRRP回波往往表现出更强的随机性与不确定性, 因此可假设 $\Sigma_r = \alpha \Sigma_s$, 且 $\alpha > 1$ 。

基于上述HRRP回波特性的先验认知以及仿真、实测HRRP在均值、方差特性方面的差异分析, 所提方法在对各类目标实测/仿真数据姿态角估计且按不发生MTRC进行角域划分的基础上, 对实测HRRP所在角域, 利用同角域大量仿真HRRP进行数据扩充, 并保证扩充HRRP满足上述的高斯分布均值 μ_r 和协方差 Σ_r 的相关特性, 从而获得兼具仿真数据的多样性与实测数据的域特性的实测域扩充数据, 从数据层面缓解实测域小样本问题, 也为仿真数据辅助的跨域知识迁移学习提供基础。

具体地, 将实测HRRP训练数据按散射点不发生MTRC对应的临界角^[29]划分为 K 个子角域的回波集合 $\{\Theta_k\}_{k=1}^K$ 。对于每个划分好的小角域 Θ_k , 计算其对应的实测HRRP样本均值:

$$\mu_k^{\text{real}} = \frac{1}{N_k^{\text{real}}} \sum_{i=1}^{N_k^{\text{real}}} x_{k_i}^{\text{real}} \quad (1)$$

其中, μ_k^{real} 为第 k 个角域内实测样本均值, N_k^{real} 为该角域内实测样本数, $x_{k_i}^{\text{real}}$ 为该角域第 i 个实测样本。类似地, 计算各角域的仿真数据均值:

$$\mu_k^{\text{sim}} = \frac{1}{N_k^{\text{sim}}} \sum_{i=1}^{N_k^{\text{sim}}} x_{k_i}^{\text{sim}} \quad (2)$$

式(2)符号含义与式(1)类似, 这里不再赘述。

对于仿真、实测相同的姿态角角域, 根据实测与仿真样本的均值与方差差异分析, 对同角域内所有仿真HRRP样本按式(3)进行差异补偿, 以缓解仿真域和实测域数据的域差异问题, 得到实测域扩充样本:

$$x_{k_{i,n}}^{\text{aug}} = \sqrt{\beta_n} x_{k_i}^{\text{sim}} - \sqrt{\beta_n} \mu_k^{\text{sim}} + \mu_k^{\text{real}}, n = 1, 2, \dots, N \quad (3)$$

其中, $x_{k_{i,n}}^{\text{aug}}$ 表示由仿真域第 k 个角域内第 i 个样本 $x_{k_i}^{\text{sim}}$ 经过第 n 次变换后形成的扩充样本, β_n 为方差缩放因子, $\beta_1, \beta_2, \dots, \beta_N$ 为 $(1, \alpha)$ 间的 N 个等间隔采样, α 为超参数。根据高斯分布线性变换特性, 上述扩充方式可得实测域扩充数据 $x_{k_{i,n}}^{\text{aug}}$ 的均值为 μ_r 、协方差矩阵为 $\alpha \Sigma_s$, 从而在实现数据扩充的同时充分保证扩充数据与真实数据分布一致性, 保证数据扩充的合理性。此外, 根据式(1)和式(2)可知, 所提数据扩充方法在度量各角域内HRRP高斯分布的均值时, 直接对样本进行统计平均得到, 不考虑实

测HRRP样本量的影响, 这是因为一定角域内样本均值对样本量具有稳健性。

所提数据扩充策略避免了传统简单添加随机噪声等数据增强方法在模拟真实HRRP数据特性方面的局限性, 从数据层面缓解了小样本问题, 也为缓解后续跨域特征对齐因目标域(实测域)小样本而面临的对齐精度差的问题提供了一定基础。然而, 所提数据扩充方法相较于其他方法的需求增量也很明显, 即需要先对实测、仿真HRRP进行角域划分, 保证同角域HRRP分布特性一致, 然后对同角域仿真、实测HRRP进行匹配。如前所述, 当实测雷达目标跟踪信息可获取时, 各实测HRRP对应的姿态角可根据跟踪信息直接估计得到^[30], 结合雷达参数和目标尺寸先验计算不发生MTRC对应的临界角后, 可实现实测HRRP角域划分, 以及进一步的同角域仿真HRRP确定(仿真HRRP角域划分可根据仿真信息直接确定)。若雷达跟踪信息无法及时获取, 则可结合Akaike信息论准则^[29], 基于HRRP数据统计特性的变化, 实现实测HRRP自适应角域划分。进一步通过计算各角域实测HRRP样本高斯分布与所有角域仿真HRRP高斯分布间的相似度, 可实现同角域仿真和实测HRRP数据的匹配, 为后续基于仿真HRRP数据的同角域实测域HRRP扩充奠定基础。因此, 无论是否可获取目标跟踪信息, 角域划分操作均较易实现, 所提方法具备实际推广应用能力。

2.3 仿真数据辅助的跨域知识迁移学习

仿真数据辅助的实测域数据扩充策略在数据域弥补了实测数据的不足, 然而, 数据扩充策略只能利用到部分角域的仿真数据对实测域数据进行临近姿态数据扩充, 即实测数据所在小角域内的临近样本扩充。其对仿真数据知识的利用有限, 仍不足以训练泛化性良好的模型, 特别是对大角域间隔的姿态缺失数据。为更充分地利用大量仿真数据的知识, 所提方法通过仿真数据辅助的跨域知识迁移学习, 在特征域准确对齐仿真域和实测域特征分布, 实现模型泛化能力的进一步提升。

按2.1节模型框架描述, 下面分别对跨域知识迁移学习策略中的特征提取模块、域对齐模块和类对齐模块进行详细介绍。

2.3.1 特征提取模块

特征提取模块旨在提取HRRP深层特征, 对于输入的仿真、实测数据和扩充数据(以下简称为实测-扩充数据), 特征提取器 F 将其映射到特征空间

以提取目标的深层特征。如图2所示,本文特征提取模块由1D-CNN和全连接层构成,具体为3个含有卷积、批归一化、激活函数以及最大池化层的卷积结构,以及最后使用两个全连接层调整特征输出维度。1D-CNN卷积核的滑动窗口机制可精确捕捉HRRP中与目标物理结构相关的局部起伏特征,通过多层卷积堆叠,实现从底层波形到深层语义特征的逐层挖掘。

1D-CNN基于卷积运算由多层组成,可以看作从输入映射到输出映射的转换。假设为HRRP构建的1D-CNN包含 L 个卷积层,第 l 层($l=1,2,\dots,L$)包含 Q_l 个卷积核。对于第 l 层的第 q ($q=1,2,\dots,Q_l$)个卷积核,记为 $\mathbf{W}_q^l$,其通道数为 Q_{l-1} ($Q_0=1$),假设每个通道是一个大小为 $h_l \times 1$ 的向量,即 $\mathbf{W}_q^l \in \mathbb{R}^{h_l \times 1 \times Q_{l-1}}$ 。设 $\mathbf{F}^{l-1} \in \mathbb{R}^{H_{l-1} \times 1 \times Q_{l-1}}$ 表示第 l 个卷积层的输入(即第 $l-1$ 层的输出, $\mathbf{F}^0 \in \mathbb{R}^D$ 为HRRP样本), Q_{l-1} 为其通道数, H_{l-1} 为每个通道的向量维数。 $\mathbf{W}_q^l$ 和 $\mathbf{F}^{l-1}$ 的卷积结果,记作 $\mathbf{F}_q^l \in \mathbb{R}^{H_l \times 1}$,可表示为

$$\mathbf{F}_q^l = \sigma(\mathbf{F}^{l-1} * \mathbf{W}_q^l + \mathbf{b}_q^l) \quad (4)$$

其中, $*$ 表示卷积算子, $\mathbf{b}_q^l \in \mathbb{R}^{H_l \times 1}$ 表示偏置, $\sigma(\cdot)$ 是非线性激活函数(本方法使用ReLU)。那么第 l 层的最终输出即 $\mathbf{F}^l$ 为所有通道的叠加,即 $\mathbf{F}^l = \{\mathbf{F}_q^l\}_{q=1}^{Q_l}$,其大小为 $H_l \times 1 \times Q_l$ 。对于多通道的 $\mathbf{F}^{l-1}$ 和 $\mathbf{W}_q^l$,它们的卷积即 $\mathbf{F}^{l-1} * \mathbf{W}_q^l$ 为所有通道的卷积和。为了增加卷积核的感受野和隐特征的稀疏性,通常在上述卷积计算和非线性变换后嵌入一个子采样层,本文采用最大池化操作,对每个卷积层的每个特征向量去除池化区域中除最大元素以外的所有元素,该操作通过局部特征选择增强对微小姿态波动的容忍性,同时通过降维降低过拟合风险。

批归一化(Batch normalization, BN)是一种加速训练和提高泛化的技术,广泛应用于各种深度神经网络。所提方法在每次卷积操作后使用批处理归一化,对于具有 d 维输入的层 $\mathbf{x} = (x^1, x^2, \dots, x^d)$, BN操作首先通过式(5)

$$\hat{x}^k = \frac{x^k - \mathbb{E}[x^k]}{\sqrt{\text{Var}[x^k] + \epsilon}} \quad (5)$$

对每个维度进行归一化,其中期望和方差是在来自训练数据集的小批量上计算的,并且添加一个常数到小批量方差中以保持数值稳定性。归一化后,引入一对参数 γ^k, β^k 对归一化值进行缩放和移位:

$$y^k = \gamma^k \hat{x}^k + \beta^k \quad (6)$$

在原始模型参数的基础上学习参数 γ^k 和 β^k 。通过将每个输入单元归一化,使其均值和方差为零,批归一化层有助于处理训练阶段初始化不良的问题,并有助于缓解HRRP数据因目标姿态变化导致的内部协变量偏移问题,加速学习和收敛。

特征提取模块的参数在仿真HRRP数据域和实测-扩充HRRP数据之间共享。采用参数共享的特征提取器,一方面减少了网络参数量,另一方面,参数共享设置更有利于提取域不变特征。

2.3.2 域对齐模块

由于仿真HRRP数据(仿真域 $\mathcal{S}$)与实测-扩充HRRP数据(实测域 $\mathcal{T}_{\text{aug}}$)之间的分布存在显著差异,因而仿真域特征与实测域特征分布不匹配,进而使用大量仿真数据特征学习的分类器并不适用于实测数据特征的分类。域对齐模块旨在将仿真域所有类全部特征和实测域所有类全部特征进行对齐,从特征整体分布层面减小仿真和实测域差异,促进仿真域特征学习的分类界面在实测域特征上的适用性。

本文域对齐的核心目标是通过对抗学习减小仿真域与实测域的特征分布差异。对抗学习已经被证实是有效的域级特征对齐方法^[31],所提方法基于GAN构建了域对齐模块,如图3所示,其核心组件与训练机制如下:对于特征提取模块 F 提取到的原始特征,引入一个生成器 G 和判别器 D ,生成器 G 将原始实测域特征和原始仿真域特征映射到域不变特征空间,混淆域判别器,从而减小域差异性,考虑到模型复杂度,本文使用3层全连接网络作为其基础结构;判别器 D 旨在对仿真域特征和实测域特征进行域分类,区分特征来自仿真域或实测域,本质为二元分类器,其结构为两层全连接层。二者通过极小极大博弈优化的对抗学习的方式优化以下域对齐损失:

$$L_{\text{domain}} = \mathbb{E}_{x_s \sim \mathcal{S}} [\log D(F(x_s))] + \mathbb{E}_{x_t \sim \mathcal{T}_{\text{aug}}} [\log (1 - D(G(F(x_t))))] \quad (7)$$

其中, $F(\cdot)$ 表示特征提取模块的特征变换, x_s 和 x_t 分别表示仿真域和实测域HRRP样本。生成器目




图2 特征提取模块结构示意图

Fig. 2 Schematic diagram of feature extraction module structure

标是混淆域判别器、最小化特征的域可区分性，因此优化生成器 G 可通过最小化下式实现：

$$L_G = \mathbb{E}_{x_t \sim \mathcal{T}_{\text{aug}}} [\log(1 - D(G(F(x_t))))] \quad (8)$$

域判别器目标是最大化域分类准确率，因此优化判别器 D 可通过最大化式(8)实现。

生成器和鉴别器交替迭代以生成对抗的思想进行训练，最终达到纳什均衡，从而将仿真域和实测域特征分布进行域级全局对齐，减小跨域特征差异，为跨域特征类对齐提供基础。

2.3.3 类对齐模块

尽管域对齐模块已经对仿真域与实测域特征分布进行了整体对齐，但类级偏移仍存在：仿真域与实测域同类特征的位置偏差仍然较大，导致部分同类样本跨域距离大于类间距离，形成类重叠，即仿真域类别A可能与实测域类别B在域不变特征空间中产生伪对齐，尤其在目标域样本稀少时，伪对齐的可能性更高，如图3所示。伪对齐特征对后续分

类界面学习带来严重负担，很容易导致分类界面学习不准进而影响最终识别准确性。针对此问题，在数据扩充、域对齐基础上，所提方法引入类对齐策略，使同类仿真和实测域HRRP特征拉近、异类HRRP特征原理，进一步使利用大量仿真HRRP数据充分学习的、对仿真域特征具有强类间区分能力的识别模型也能够少量实测HRRP训练数据参与模型学习时对实测域测试特征也具有强类间可分性的泛化能力，从而提升实测域小样本情况下的识别稳健性。

结合HRRP成像机理先验^[32]，HRRP强姿态敏感，各类HRRP在特征空间呈现多模分布，所提类对齐策略分别为各类仿真和实测域HRRP特征分配多个可学习的原型，通过建模跨域多原型之间以及多原型与HRRP样本特征之间的关系构建类对齐损失。如图4所示，跨域多原型对比损失从类级整体对齐的角度，将距离上靠近的同类仿真、实测域原型进行两两拉近，同时推远所有异类原型间的距




图 3 域对齐示意图

Fig. 3 Schematic diagram of domain alignment




图 4 类对齐示意图

Fig. 4 Schematic diagram of class alignment

离; 跨域样例对比损失从各类仿真、实测样例对齐的角度, 将所有样本特征和对应类最近的仿真域、实测域原型进行拉近并推远所有样本特征与异类所有原型间的距离。具体来说, 类对齐损失包括跨域多原型对比损失以及跨域样例对比损失:

$$L_{\text{class}} = L_{\text{PP}} + L_{\text{IP}} \quad (9)$$

其中, L_{PP} 为跨域多原型对比损失, L_{IP} 为跨域样例对比损失。

(1) 跨域多原型对比损失

跨域多原型对比损失从类级整体对齐的角度, 拉近同类跨域相近原型间的距离, 同时推远所有异类原型间的距离, 其通过最小化式(10)实现:

$$L_{\text{PP}} = \sum_{m=1}^M \sum_{q=1}^N \log \frac{\exp(d(p_{m,q}^{\text{sim}}, p_{m,q}^{\text{aug}}) / \tau_p)}{\sum_{k=1}^M \sum_{q=1}^N \exp(d(p_{m,q}^{\text{sim}}, p_{k,q}^{\text{aug}}) / \tau_p)} \quad (10)$$

其中, $p_{m,q}^{\text{sim}}$ 和 $p_{m,q}^{\text{aug}}$ 分别表示仿真域中第 m 类第 q 个原型和与 $p_{m,q}^{\text{sim}}$ 距离最近的同类实测域原型, τ_p 表示原型级温度缩放系数, 用于调节同类匹配权重, $d(\cdot, \cdot)$ 表示度量函数, 用于计算原型相似度, 本方法采用欧氏距离函数, 该损失从类整体角度约束仿真域与实测域特征分布对齐。

(2) 跨域样例对比损失

跨域样例对比损失从各类各模态样例对齐的角度, 拉近所有样本特征和对应类最近类原型(包括实测域和仿真域两个域的同类对应最近类原型)间的距离、推远所有样本特征与异类所有原型间的距离, 促进跨域特征类内紧致、类间分离, 兼顾同类跨域特征分布一致性与不同类特征可分性, 保证仿真域特征对实测域特征的有效辅助。跨域样例对比损失 L_{IP} 具体可通过最小化式(11)实现:

$$L_{\text{IP}} = \frac{1}{2} (L_{\text{sim2aug}} + L_{\text{aug2sim}}) \quad (11)$$

其中, L_{sim2aug} 表示仿真样例与仿真域对应类最近原型之间的拉近项以及仿真样例到同类实测域最近原型的对齐项, 即

$$L_{\text{sim2aug}} = \sum_{i=1}^{N_s} \log \frac{\exp(d(f_i^{\text{sim}}, p_{y_i, q_i}^{\text{aug}}) / \tau_i)}{\sum_{m=1}^M \sum_{q=1}^N \exp(d(f_i^{\text{sim}}, p_{m,q}^{\text{aug}}) / \tau_i)} + \sum_{i=1}^{N_s} \log \frac{\exp(d(f_i^{\text{sim}}, p_{y_i, q_i}^{\text{sim}}) / \tau_i)}{\sum_{m=1}^M \sum_{q=1}^N \exp(d(f_i^{\text{sim}}, p_{m,q}^{\text{sim}}) / \tau_i)} \quad (12)$$

L_{aug2sim} 表示实测样例与实测域对应类最近原

型之间的拉近项以及实测样例到同类仿真域最近原型的对齐项:

$$L_{\text{aug2sim}} = \sum_{i=1}^{N_T} \log \frac{\exp(d(f_i^{\text{aug}}, p_{y_i, q_i}^{\text{sim}}) / \tau_i)}{\sum_{m=1}^M \sum_{q=1}^N \exp(d(f_i^{\text{aug}}, p_{m,q}^{\text{sim}}) / \tau_i)} + \sum_{i=1}^{N_T} \log \frac{\exp(d(f_i^{\text{aug}}, p_{y_i, q_i}^{\text{aug}}) / \tau_i)}{\sum_{m=1}^M \sum_{q=1}^N \exp(d(f_i^{\text{aug}}, p_{m,q}^{\text{aug}}) / \tau_i)} \quad (13)$$

其中, τ_i 表示特征级缩放系数, f_i^{sim} 表示仿真域第 i 个样本经特征提取模块输出的原始特征向量, f_i^{aug} 表示实测域第 i 个样本的原始特征向量经生成器 G 输出的特征向量, y_i 表示第 i 个样本对应的类别标签, $p_{y_i, q_i}^{\text{sim}}$ 表示第 i 个样本对应的仿真域同类最近原型, $p_{y_i, q_i}^{\text{aug}}$ 表示第 i 个样本对应的实测域同类最近原型。

基于样本类别标签, 利用传统交叉熵损失, 通过将同类仿真域和实测域特征映射至相同类别标签、不同类仿真域和实测域特征映射至不同类别标签也可实现跨域特征类对齐。但其优化目标更侧重于将仿真域和实测域中不同类别的特征在决策边界上区分开, 而对类内特征的聚合性约束相对本文采用的原型对比损失较弱。这是因为传统交叉熵损失函数在特征-类别标签映射学习过程中对特征的指数归一化操作会削弱同类特征间的聚合性, 导致即使本身相似度低的同类特征在对应类的预测概率上均有非常高的类别得分输出。这种过度自信会在模型学习时削弱模型对类内特征细微变化的敏感性, 使得同类特征(特别是来自仿真和实测两个域的同类别样本)难以在嵌入空间中紧密聚合, 最终影响跨域类对齐效果。相比之下, 本文所采用原型对比损失通过度量学习直接优化特征空间, 不对特征再进行指数级变换, 能够有效缓解传统标签约束方式面临的过度自信问题, 实现更好的跨域特征类对齐效果。以3类飞机目标为例, 图5给出了基于类别标签约束的类对齐方法和基于原型对比损失约束的类对齐方法在每类10个实测训练HRRP样本情况下仿真HRRP和实测HRRP测试数据的特征对齐可视化。可以看到, 类别标签约束策略下, 各类仿真域特征(红色)与实测域特征(蓝色)虽在一定程度上实现了对齐, 但对齐精度仍有限, 特别是雅克-42目标仿真和实测域特征混叠性相对较差, 甚至部分实测域特征与异类特征相近。而原型对比损失约束策略下, 仿真域与实测域在各类别特征分布上实现了较好对齐, 且跨域特征类内特征更加紧凑、类间特征更好分离。




图 5 每类10个实测训练HRRP样本情况下不同类对齐约束方式对仿真HRRP和实测HRRP测试数据的特征对齐可视化

Fig. 5 Visualization of feature alignment under different class alignment constraints for simulated HRRPs and measured test HRRPs with 10 HRRP samples per class

2.4 损失函数

对于仿真域样本 x_i^{sim} ，所提方法在域不变空间中根据距离度量函数 $d(\cdot, \cdot)$ 计算其特征与仿真域各原型的距离得到样本分类概率：

$$p(y = y_i | x_i^{\text{sim}}) = \frac{\exp(d(f_i^{\text{sim}}, p_{y_i, q_i}^{\text{sim}}))}{\sum_{m=1}^M \sum_{q=1}^N \exp(d(f_i^{\text{sim}}, p_{m, q}^{\text{sim}}))} \quad (14)$$

训练过程中通过最小化式(15)所表示的分类概率的对数值得到仿真域样本分类损失：

$$L_{\text{ce_sim}} = \log p(y = y_i | x_i^{\text{sim}}) \quad (15)$$

类似地，对于实测域样本 x_i^{aug} ，所提方法根据距离度量函数计算其经过生成器 G 映射到特征域不变空间的特征(即 f_i^{aug})与实测域各原型的距离得到样本的分类概率，并通过最小化分类概率的对数值得到实测域样本分类损失：

$$L_{\text{ce_aug}} = \log p(y = y_i | x_i^{\text{aug}}) \quad (16)$$

所提方法的整体损失是式(16)和式(17)中仿真域和实测域分类损失、式(8)中的域对齐损失和式(10)中的类对齐损失的结合，具体可以表示为

$$L = \lambda_1 L_{\text{ce}} + \lambda_2 L_{\text{domain}} + \lambda_3 L_{\text{class}} \quad (17)$$

其中， $\lambda_1, \lambda_2, \lambda_3$ 是权重参数，用于平衡不同损失权重， $L_{\text{ce}} = L_{\text{ce_sim}} + L_{\text{ce_aug}}$ 表示总分类损失。

综上，所提方法以雷达目标电磁仿真生成仿真HRRP数据为基础，利用电磁仿真HRRP实现实测域HRRP扩充，并结合仿真、实测域HRRP域对齐和类对齐策略进一步缓解缓解小样本问题。相较直接利用实测数据均值生成同角域仿真数据的方式，本文所采用流程能够避免该角域内仿真数据方差难

确定的问题以及实测缺失角域对应的仿真数据无法生成的问题，从而保证所生成仿真数据对目标特性的表征精度以及丰富度，最大化仿真信息利用率，最终实现小样本识别能力的更大增强。

此外，由前可知，雷达目标HRRP电磁仿真是所提方法的基础，电磁仿真模型精度、仿真环境均会对算法性能产生影响。电磁仿真模型精度方面，仿真模型在整体结构、精细部件以及涂层材料等方面不可避免地与实际模型存在差异，这些差异造成仿真HRRP和实测HRRP波形(散射点位置、幅度)的不同，本文也正是考虑了仿真模型与真实目标模型的差异，故而在利用仿真数据进行实测域数据扩充以及利用仿真数据辅助少量实测HRRP学习时，针对性地设计了域偏移缓解策略，减小因仿真模型与真实模型差异造成的仿真HRRP数据辅助能力削弱甚至造成负影响的问题。因此，本文所提方法对目标3D建模精度要求可放宽，可松弛对目标真实特性的先验认知，但条件允许，还是尽可能高逼真度地模拟真实目标，以缓解仿真域到实测域的迁移难度，更充分地发挥所提跨域迁移学习方法的能力。仿真环境方面，实际雷达HRRP回波不可避免地受接收机热噪声等影响，仿真过程中要尽可能使仿真与实测HRRP数据的信噪比水平保持一致。这是因为，所提方法计算同角域仿真、实测HRRP样本均值之间的差异进行数据扩充。对于接收机热噪声(高斯白噪声)，无论其噪声水平如何，其均值近似为0^[33]。因此，即使仿真、实测HRRP噪声水平不同，计算同角域样本均值的方式对于仿真和实测HRRP非支撑区噪声部分的均值始终趋近于0，并不能弥补仿真和实测HRRP噪声水平差异，从而造成扩充数据与真实HRRP数据信噪比水平的差异，

削弱数据扩充策略在小样本识别方面的性能提升。以3类飞机目标为例,表1展示了仿真HRRP数据信噪比为30 dB、实测HRRP数据信噪比为30 dB, 20 dB, 10 dB, 5 dB(对高信噪比的实测HRRP数据添加对应功率的高斯白噪声)情况下,所提方法对应的识别结果(每类10个实测HRRP训练样本),可以看到仿真与实测数据的信噪比不同时,所提方法小样本识别性能会有明显下降。因此,本文所提方法对仿真环境要求较高,要尽可能使仿真HRRP信噪比水平与实测HRRP信噪比水平保持一致。实际电磁仿真过程中,可以在估计实测HRRP信噪比水平的基础上^[33],向高信噪比仿真HRRP添加合适功率的高斯白噪声,使仿真HRRP与实测HRRP信噪比一致,操作简单易实现。

3 实验与分析

本节首先介绍实验中采用的数据集以及实验设置,然后将所提方法与现有典型的雷达HRRP目标识别方法的性能进行比较,以验证所提方法的有效性,最后对模型进行分析,包括数据扩充、特征对齐的有效性分析和消融实验,以验证所提方法各模块的合理性。

3.1 实验数据集介绍

3.1.1 飞机目标数据集

本文飞机目标实验所采用数据集为C波段雷达获取的3类飞机目标实测HRRP数据。3类飞机目标分别为:安-26(An-26)、奖状(Cessna Citation S/II)和雅克-42(Yak-42)。其中,安-26是中小型螺旋桨飞机,奖状是小型喷气式飞机,雅克-42是中大型喷气式飞机。表2和表3分别给出了实验中所用雷达和飞机目标的具体参数。

图6展示了3类飞机目标飞行轨迹在地平面上的投影,图中黑色小圆圈表示观测雷达位置,每个目

标航迹被分为多个数据段,在图中以序号“1, 2, …”表示,每个数据段包含总共25600个HRRP实测样本,每个实测HRRP样本的距离单元长度为256。在实验中随机在安-26的第5段和第6段数据、奖状的第6段和第7段数据以及雅克-42的第2段和第5段的某些角域内抽取少量实测样本作为实测域训练样本,以3类飞机目标的其他数据段作为实测域训练样本,共5200个实测测试HRRP样

表1 仿真HRRP信噪比为30 dB、实测HRRP信噪比为30 dB, 20 dB, 10 dB, 5 dB情况下所提方法的识别性能
(每类10个实测HRRP训练样本)

Tab. 1 Performance of proposed method under the SNR of simulated HRRP being 30 dB and the SNR of measured HRRP being 30 dB, 20 dB, 10 dB, 5 dB with 10 measured training HRRPs per class

实测HRRP数据信噪比	识别准确率
30 dB	90.22%
20 dB	85.24%
10 dB	79.58%
5 dB	71.93%

表2 实验雷达参数

Tab. 2 Radar parameters in the experiment

参数	数值
中心频率(MHz)	5520
脉冲重复频率(Hz)	400
Dechirp后采样频率(MHz)	10
信号带宽(MHz)	400

表3 实验飞机参数

Tab. 3 Aircraft parameters in the experiment

飞机	机长(m)	机宽(m)	机高(m)
安-26	23.80	29.20	9.83
奖状	14.40	15.90	4.57
雅克-42	36.38	34.88	9.83




图6 3类飞机目标轨迹投影到地平面的展示图

Fig. 6 Projection diagram of trajectories of three types of aircraft targets onto the ground plane

本。实验中采用的电磁仿真数据由雅克-42、奖状和安-26 3类飞机3D模型仿真得到,各目标仿真数据覆盖 $0\sim 360^\circ$ 全方位(间隔 0.02°),且包含3个不同的俯仰角(雅克-42俯仰角分别为 $6^\circ, 11^\circ, 15^\circ$,奖状和安-26俯仰角均为 $11^\circ, 15^\circ, 21^\circ$),每类总共54000个电磁仿真HRRP样本,作为仿真域训练样本。

3.1.2 地面车辆目标数据集

本文地面车辆目标数据来自SAMPLE数据集。SAMPLE数据集由美国空军实验室公开发表,包含10类车辆目标的仿真/实测SAR图像,目标方位角范围为 $10^\circ\sim 80^\circ$,俯仰角范围为 $14^\circ\sim 17^\circ$,表4展示了10类地面车辆目标的类别和数据量,在训练时随机抽取实测训练集中每类1,5,10个实测样本作为实验的小样本设置。在实验设置中,测试数据的仰

角为 17° ,训练数据的仰角分别为 $14^\circ, 15^\circ$ 和 16° 。SAMPLE数据集包含了标准操作条件、含杂波、目标遮挡3种场景设置。其中,标准操作条件指无杂波且无目标遮挡的标准场景。杂波场景设置方面,数据集在标准操作条件下的SAR图像中人工加入草地、树林等杂波;目标遮挡设置方面,数据集在标准操作条件下的SAR图像上随机覆盖规则形状的掩模以模拟被部分遮挡的场景,遮挡位置覆盖目标强散射中心部分区域。为验证所提雷达HRRP小样本识别方法在更为复杂场景情况下的泛化性,实验中将SAMPLE数据集不同场景条件设置(标准操作条件、含杂波、目标遮挡)的SAR图像转换成对应HRRP数据作为实验数据。图7直观展示了不同场景设置情况下各类车辆目标一幅SAR图像及对应转换后的HRRP样本示例。

3.2 实验设置

实验中对比方法和所提方法使用的具体实测数据和仿真数据规模如表5所示。对比方法中,自适应高斯分类器(Adaptive Gaussian Classifier, AGC)、支持向量机(Support Vector Machine, SVM)、因子分析(Factor analysis, FA)模型、CNN、RNN、长短期记忆(Long Short-Term Memory, LSTM)网络、PN均分别使用1, 5, 10个实测HRRP训练样本进行模型学习,仿真数据未参与模型训练;“PN+微调”表示利用全部仿真HRRP样本训练PN后利用1, 5, 10个实测HRRP样本进行微调;原型网络元学习(Prototypical Network Meta Learning, PNML)和模型无关元学习(Model Agnostic Meta Learning,

表 4 SAMPLE数据集类别和数据量
Tab. 4 The category and volume of the SAMPLE dataset

类别	仿真	实测训练	实测测试
2S1	174	116	58
BMP2	107	55	52
BTR70	92	43	49
M1	129	78	51
M2	128	75	53
M35	129	76	53
M548	128	75	53
M60	176	116	60
T72	108	56	52
ZSU23	174	116	58




图 7 SAMPLE数据集场景条件设置及对应的各类样本示例

Fig. 7 Scene condition settings for the SAMPLE dataset and corresponding sample examples of various types

MAML)分别是基于度量和基于优化的元学习方法,均使用仿真数据作为元学习的辅助数据集,再使用1, 5, 10个实测样本计算原型或简单更新参数,最后用于全部实测HRRP测试样本的识别。深度适应网络(Deep Adaptation Network, DAN)、域对抗网络(Domain Adversarial Neural Network, DANN)均利用一定策略对全部仿真数据和1,5,10个实测训练样本进行特征对齐,并利用对齐的仿真特征和实测特征学习分类器,用于后续实测HRRP测试样本的识别。

为了保证对比的公平性,在实验中,对比方法和所提方法均随机抽取了20次不同角域的实测HRRP样本进行实验,且二者每次实验采用的实测HRRP训练样本相同。所有深层网络均调至最佳参数,对于本文所使用的网络,所有权重矩阵采用随机初始化,所有偏差项初始化为0,小批量大小设置为64,超损失权重参数分别为 $\lambda_1 = 1, \lambda_2 = 0.5, \lambda_3 = 0.5$,温度系数超参数分别为 $\tau_p = 0.5, \tau_i = 0.1$ 。使用初始学习率为0.001的Adam优化器进行优化,学习率每过20训练批次衰减0.1倍,所有实验均在GPU 1060T 8 GB, RAM 16 GB的条件下训练。除非另有说明,否则所有实验均采用此设置。

3.3 飞机目标雷达HRRP识别结果与分析

3.3.1 识别结果与分析

为了验证本文提出的方法在雷达HRRP小样本目标识别任务中的性能,本节将所提方法与典型的浅层雷达HRRP目标识别方法、深层雷达HRRP目标识别方法、小样本识别方法、传统域适应方法进行了比较,如表6所示。其中,AGC, SVM, FA是传统浅层雷达HRRP识别方法;CNN, RNN, LSTM, PN均是典型的深层雷达HRRP识别方法;PN+微调、PNML, MAML是小样本识别方法;DAN和DANN是传统域适应方法,其中DAN是使用MMD约束对齐仿真域和实测域特征全局分布的方法,DANN是使用域对抗学习方式对齐仿真域和实测域特征全局分布的方法,这两种域适应方法在

实验中均使用仿真数据作为源域和使用少量目标域实测数据作为目标域进行域适应迁移学习。

表6给出了上述各种典型的雷达HRRP识别方法的识别性能,表中“仅使用少量实测数据训练”一类方法是指,识别模型学习仅依赖观测到的少量HRRP实测样本,仿真数据完全不参与模型学习(在实验中,该类方法训练识别模型仅用每类1, 5, 10个实测HRRP样本,不使用仿真HRRP)。由于所提方法的数据扩充、域对齐以及类对齐均建立在有效利用仿真HRRP数据的基础之上(若仅使用少量实测数据训练,所提方法则退化为传统PN网络),因此,在“仅使用少量实测数据训练”设置方式下,所提方法无法实现,故表6中针对“仅使用少量实测数据训练”一类方法不再罗列所提方法。由表6可知,所提方法取得了最佳识别性能。在只使用少量实测数据的情况下,传统浅层雷达HRRP目标识别方法和深层雷达HRRP目标识别方法因实测训练数据的缺失,识别模型过拟合,识别性能低下,特别是只有一个实测训练样本时,识别性能略高于随机分类,几乎不具有识别能力。在使用大量电磁仿真数据辅助的情况下,小样本识别方法和传统域适应方法性能均有提升,识别率提升10%~15%。这是因为不论微调方式、元学习的方式或者传统域适应的方式,都可以利用到大量仿真数据学习到的知识辅助小样本识别任务,只是利用方式有所区分。微调方式认为网络浅层知识是类共有的域不变信息,通过冻结浅层参数、微调深层参数,在实现知识迁移的同时还可以学习实测域的域

表6 不同方法小样本识别性能对比(20次实验平均结果)(%)

Tab. 6 Comparison of few-shot recognition performance among different methods (average results of 20 experiments) (%)

训练数据	方法	1shot	5shot	10shot
仅使用少量实测数据训练	AGC	40.86±5.23	49.42±4.63	53.42±4.21
	SVM	42.81±5.77	50.86±5.08	54.88±3.83
	FA	41.58±5.36	51.69±4.89	57.52±4.57
	CNN	48.62±3.87	53.88±3.42	57.28±2.93
	RNN	47.83±4.09	53.62±3.76	55.12±3.25
	LSTM	49.76±3.53	54.12±3.04	56.85±2.73
	PN	54.27±3.28	61.98±2.59	65.96±2.05
	PN+微调	61.85±1.84	70.24±1.37	74.21±1.06
	PNML	63.86±1.26	75.56±1.14	79.45±0.87
	MAML	64.33±1.32	75.85±1.03	79.95±0.97
使用仿真数据和少量实测数据训练	DAN	57.58±0.95	71.75±0.79	77.42±0.72
	DANN	57.93±0.93	72.65±0.84	78.65±0.64
所提方法		74.94±0.68	85.78±0.32	90.22±0.27

注:表内加粗数值表示最优指标数值。

表5 实验所用实测与仿真训练样本具体数量

Tab. 5 The specific quantities of measured and simulated training samples used in the experiment

方法	每类实测/仿真训练样本数		
	1shot	5shot	10shot
AGC, SVM, FA, CNN, RNN, LSTM, PN	1/0	5/0	10/0
PN+微调, PNML, MAML, DAN, DANN, 所提方法	1/54000	5/54000	10/54000

特有信息。但对于此简单直接的迁移学习方法，可迁移的知识对源域和目标域数据的差异大小、冻结的浅层层数严重敏感，因此整体小样本识别性能弱于元学习和域适应方法。元学习方法(PNML, MAML)通过大量仿真域数据构建小样本学习元任务，积累小样本泛化学习能力，并将这种能力应用于目标任务，但是元学习没有考虑到仿真域与实测域的域差异，导致小样本泛化学习能力迁移效果有限，小样本识别能力仍不足。传统域适应方法(DAN, DANN)依赖仿真域(源域)特征与实测域(目标域)特征的准确对齐，从而将源域学习到的知识迁移到目标域，辅助目标域识别任务。然而在目标域只有少量训练数据的情况下，传统域适应难以准确对齐仿真域与实测域特征分布，稀少的目标域训练数据影响了源域、目标域特征对齐效果，识别模型只是对齐了源域与有限的目标域训练样本特征，导致传统域适应方法在小样本条件下性能仍然有限，特别是每类1个实测训练HRRP样本情况下，域适应方法性能差于微调方法。

对比表6中的小样本识别方法PNML, MAML和传统域适应方法DAN, DANN，本文所提方法性能提升9%~17%，这说明了所提方法使用数据扩充

策略和跨域知识迁移学习策略缓解小样本问题的有效性：首先通过实测域数据扩充，在数据域层面缓解了传统域适应需要足够的目标域训练数据的限制，再通过跨域知识迁移学习策略，在特征域层面进行跨域知识迁移，实现了仿真数据知识的有效迁移，从而取得了最优性能。

为了更直观地说明所提方法的识别效果以及所提特征可分性，图8给出了对比实验中几种典型方法和所提方法在每类10个实测训练样本情况下对3类飞机实测HRRP测试数据所提特征的T-SNE可视化。从图8(a)、图8(b)、图8(c)可以看出，直接使用少量实测数据训练的深层网络所提特征类间出现大量混淆，模型过拟合、泛化性严重下降。由图8(d)可以看到，小样本学习方法PNML所提取特征可分性有了明显提升，但特征仍然存在较大混淆，识别性能提升有限。从图8(e)可以看到，传统域适应方法所提取的实测域特征可分性仍然有限，造成识别性能不佳。此外，由图8(c)和图8(d)可以看到，PN, PNML在小样本训练集学习到的原型和样本测试集分布有较大偏差，所学习到的原型难以准确表示实测域样本真实分布。而如图8(f)所示，本文所提方法提取的特征类间混叠现象明显减少，且学习




图 8 每类10个实测训练样本情况下不同方法在实测HRRP测试集上的特征可视化对比(10shot)

Fig. 8 Feature visualization comparisons of different methods on the measured HRRP test set in the condition of 10 HRRP training samples per class

到的多原型基本位于各特征子集中心、准确性更好,能够良好地表示实测域特征真实分布。表明所提方法在少量实测训练样本情况下泛化性更强、识别性能更优。

3.3.2 模型分析

(1) 实测数据扩充有效性分析

为了直观说明实测域扩充样本和实测真实样本的关系,本节分别对一定角域内实测HRRP样本以及对应角域的仿真HRRP样本和扩充样本进行T-SNE可视化,以展示实测域扩充数据的有效性,如图9-图11所示。其中黑色为已知方位角信息的实测HRRP训练样本,红色为角域内其他未参与训练的实测样本(即缺失的实测样本),蓝色为角域内的实测域扩充样本,绿色为对应角域仿真样本。通过图9-图11可以看到,所提方法扩充的数据和对应角域内真实的实测数据分布接近,说明了本方法所提实测域扩充数据的有效性。

为进一步说明数据扩充策略的有效性,将数据

扩充策略与传统对比方法结合,包括浅层识别方法SVM、深层识别方法CNN、传统基于仿真数据预训练+实测数据微调(PN+微调)的小样本识别方法、传统域适应方法DAN和DANN,并与不使用所提数据扩充策略的各类传统方法在每类10个实测训练HRRP样本情况下进行比较,实验结果如表7所示。在基于SVM的传统识别方法中,结合所提数据扩充策略,相较未使用数据扩充策略识别率提高了3.06%;CNN结合所提数据扩充策略相较未使用数据扩充的传统CNN方法识别率提高5.78%;类似地,结合数据扩充策略的传统小样本方法PN+微调、域适应方法DAN,DANN相较未使用数据扩充策略,识别准确率分别提升4.12%, 8.36%, 7.76%,共同证明了所提数据扩充策略在解决小样本问题上的有效性。

(2) 特征对齐有效性分析

为了分析所提方法在仿真域和实测域特征对齐方面的有效性,图12给出了由仿真域训练并在实测域直接测试(Simulation to Real, S2R)的方法、




图9 雅克-42在不同方位角域内的HRRP数据可视化

Fig. 9 HRRP data visualizations of Yak-42 within different angular domains




图10 奖状在不同方位角域内的HRRP数据可视化

Fig. 10 HRRP data visualizations of Cessna Citation within different angular domains

表 7 传统识别方法结合/不结合所提数据扩充策略在每类10个实测HRRP训练样本情况下的识别性能比较

Tab. 7 Comparison of the recognition performance of traditional recognition methods with/without the proposed data expansion strategy in the case of 10 measured HRRP training samples per class

是否使用所提数据扩充策略	传统方法	识别准确率
否	SVM	54.88%
	CNN	57.28%
	PN+微调	74.21%
	DAN	77.42%
	DANN	78.65%
是	SVM	57.94%
	CNN	63.06%
	PN+微调	78.33%
	DAN	85.78%
	DANN	86.41%

DAN, DANN和本文所提方法在每类使用10个实测HRRP样本训练情况下的特征T-SNE可视化结果。图12中使用不同的颜色来区分不同的数据域，蓝色代表实测域、红色代表仿真域；并使用不同的标记符号表示不同的类别。

从图12(a)可以看出，因为S2R使用了大量仿真数据以全监督的方式学习，仿真域特征有着良好的可分性，但由于仿真数据域实测数据存在域差异，利用仿真数据学习的模型不适用于实测域数据特征提取，故其实测域特征存在大量类间混淆，在特征可视化结果上集中在同一区域；且仿真域特征分布与实测域特征分布具有明显的域差异也能验证上述分析。如图12(b)和图12(c)所示，DAN以及DANN方法通过域适应策略，仿真域特征分布和实测域特征分布之间的域差异有了较为明显的减少，

但是由于实测域只有少量训练样本，这两种传统域适应方法难以通过有限的实测域训练数据实现仿真域与实测域特征真实分布的准确对齐，仿真域知识迁移有限，因而应用到大量实测测试数据时仿真域和实测域特征对齐效果仍有限，进而影响识别性能的进一步提升。另外，图12(b)、图12(c)与图12(a)相比，仿真域特征分布的类内紧凑性和类间分离性变差，这是因为域适应约束对基于交叉熵损失的仿真域和实测域特征可分性学习产生了影响。所提方法特征对齐效果如图12(d)所示，可以看到通过在数据域对小样本实测数据进行扩充以及在特征域对仿真域特征和实测域特征进行域级整体对齐与类级对齐，可有效缩小仿真域与实测域的特征差异，从而提升了实测域特征的类内紧凑性和类间分离性。因此，所提方法能够良好地对齐仿真域和实测域特征分布，从而有效迁移仿真域的知识到实测域，提升小样本雷达HRRP目标识别性能。

(3) 消融实验

为了更加直观地分析所提出方法的不同模块对识别性能的影响，表8展示了每类10个实测训练样本情况下的消融实验结果，其中S2R指使用仿真域训练的模型在实测域测试集直接做测试的方法，可以作为同时使用大量仿真数据和少量目标域实测数据训练的基线对比方法。

表8的消融实验结果表明，所设计的每个模块均能提高性能，各个模块协同组合达到最佳性能。实验(a)指的是使用扩充后的实测域数据和仿真数据一同训练的结果，与S2R相比，数据扩充策略可以有效扩充实测域HRRP样本，缓解小样本带来的信息缺少的问题(准确率从54.33%提高到76.19%)。实验(b)和实验(c)表明了域对齐以及类对齐模块的有效性，较仅利用数据扩充策略，增加域对齐和类




图 11 安-26在不同方位角域内的HRRP数据可视化

Fig. 11 HRRP data visualizations of An-26 within different azimuth domains




图 12 每类10个实测训练样本情况下不同方法仿真域特征与实测测试数据的特征分布可视化

Fig. 12 Feature visualizations of simulated HRRPs and measured test HRRPs for different methods in the condition of 10 HRRP training samples per class

对齐模块性能提升分别为10.28%和5.87%，域对齐提升效果更为显著。这是因为在不进行域对齐的条件下，仿真域和实测域特征域差异过大，此时直接类对齐难度过大、对齐程度有限，效果并不显著；而域对齐仅进行仿真域和实测域特征的整体分布对齐，难度较小、易准确对齐，且由于同类特征自动聚合的固有特性，在域对齐的同时即使无类对齐约束也会一定程度上自动形成跨域特征类对齐的效果。因此，整体来看域对齐角类对齐在小样本识别方面性能更优。但是在使用域对齐的前提下，类对齐能进一步提升目标域识别性能，这表明了域对齐与类对齐的协同效果，二者结合更有效，如实验(g)所示。实验(d)、实验(e)和实验(f)进一步说明了数据扩充和域对齐模块以及类对齐模块的有效性，同时可以看到在不进行数据扩充的情况下，域对齐和类对齐效果与实验(b)、实验(c)有着和前述相似结论。此外，对比实验(b)和实验(d)、实验(c)和实验(e)、实验(f)和实验(g)，实验表明在数据稀缺的情况下，域对齐和类对齐模块的对齐效果会明显下降，这表明了数据扩充策略对域对齐模块和类对齐模块的基础作用，各模块相互配合能更好提升识别性能。实验(g)即为本章所提方法，对比其他实验

表 8 每类10个实测训练样本情况下的消融实验结果
Tab. 8 Ablation experiment results in the condition of 10 HRRP training samples per class

模块	数据扩充	域对齐	类对齐	准确率/%
S2R	-	-	-	54.33
(a)	✓			76.19
(b)	✓	✓		86.47
(c)	✓		✓	82.06
(d)		✓		78.14
(e)			✓	67.02
(f)		✓	✓	79.51
(g)	✓	✓	✓	90.22

注：表内加粗数值表示最优指标数值。

结果，可以得出单一的某个模块均不能实现良好的目标域识别，各个模块相互协同，才能实现性能的最大提升，有效解决小样本条件下的仿真域与实测域特征对齐的难题，从而实现仿真数据辅助的知识迁移学习，达到最佳识别性能。

(4) 加噪实验

为了验证所提方法对于实际更复杂场景的鲁棒性，通过对3类飞机数据集进行加噪的方式以验证所提方法在不同信噪比条件下的稳定性。

3类飞机数据集仿真实测HRRP数据的原始信噪比为30 dB,在此基础上加入高斯白噪声,进行信噪比为20 dB, 10 dB以及5 dB的对比实验,仿真HRRP数据的信噪比与实测HRRP数据的信噪比保持一致。图13展示了不同实测训练样本数条件下3类飞机目标HRRP的识别性能随信噪比的变化,其中选用了4种具有代表性的方法,分别为传统域适应方法DANN、传统小样本方法PN+微调与MAML以及本文所提方法。图13结果表明,随着信噪比从30 dB降至5 dB,4种代表方法在每类目标1, 5, 10个实测训练样本下的识别精度均逐步衰减,直观体现噪声对输入数据的干扰随强度增强而加剧。另外,训练样本越少的场景对噪声越敏感,在训练的实测数据样本非常少时,噪声易诱导模型学习虚假特征或过拟合噪声,因此每类目标1,5个实测训练样本的识别率精度降幅大于每类10个实测训练样本。所提方法在所有信噪比与小样本设置下均保持显著优势,随着信噪比的降低,其识别率的下降程度明显低于其他方法,且下降程度受实测训练样本数量的影响非常小,而其他方法在实测训练样本越少时的下降程度越明显,因此所提方法的抗噪能力要显著优于其他传统小样本/域适应方法,验证了其在复杂噪声环境下更强的特征鲁棒性与泛化能力。总体而言,噪声强度升高导致识别精度普降,小样本场景噪声敏感性随训练样本量较少而增加,而所提方法在复杂噪声场景下仍保持领先性能。

(5) 算法复杂度分析

为分析所提方法在实际工程应用中的可实现性及其效率,本节从训练和测试两方面分别估算所提方法的算法复杂度和存储需求,并在训练和测试效率上与其他相关方法进行对比。

首先对所提方法在训练阶段的算法复杂度和存

储需求分析。在训练算法复杂度方面,对于数据扩充模块,由于仅是对每个仿真HRRP样本进行单层线性变换,其计算复杂度(量级: 10^4 FLOPs)远远小于后续多层特征提取以及由深层网络构成的GAN域对齐模块;对于特征提取模块,所提方法采用3层1D-CNN加两层全连接层的结构,处理单批次(以实验中采取的仿真、实测域共64个HRRP样本参与该轮次模型学习为例)计算复杂度约为 1.8×10^9 FLOPs;域对齐模块基于GAN实现,生成器与判别器分别为3层与2层全连接网络,通过交替优化进行对抗训练,单批次计算复杂度约为 2.7×10^8 FLOPs;类对齐模块主要为跨域多原型对比损失以及跨域样例对比损失计算,计算复杂度也相对较低(量级: 10^5 FLOPs)。因此,完成单批次训练的总计算复杂度约为 2.1×10^9 FLOPs。在训练存储需求方面,主要包括模型参数存储和训练过程动态存储开销。模型参数存储方面,模型参数总计约 2.2×10^5 ,以float32格式存储仅需约0.88 MB。动态存储开销方面,主要来源于3部分,其一在使用Adam优化器时需保存参数对应的1阶和2阶动量,约1.76 MB;其二训练时需缓存中间特征用于损失计算,单批次特征存储约需0.16 MB;其三为训练数据本身的存储,约需324 MB。因此,所提方法训练存储总需求约为327 MB。

其次,在测试阶段,主要分析所提方法对于单个HRRP测试样本所需要的算力和存储需求。算法复杂度方面,主要为特征提取模块的前向传播、测试样本特征经过生成器的非线性映射以及测试样本特征与各类多原型之间的距离计算,约 2.8×10^7 FLOPs。存储需求方面,测试时需加载训练好的模型参数,约需0.92 MB的固定存储开销,无须缓存优化器状态或大量中间数据。




图 13 不同实测训练样本数条件下3类飞机目标HRRP的识别性能随信噪比的变化

Fig. 13 The variation of HRRP recognition performance of three types of aircraft targets with the signal-to-noise ratio under different measured training sample numbers

因此,所提方法在训练与测试阶段的算力需求和存储需求在现有硬件配置下都很容易满足(如 RTX 1060 Ti),具备实际可行性。在实际部署可行的基础上,表9、表10进一步给出了所提方法与相关方法在训练阶段单批次计算复杂度与训练时间、测试阶段单个测试HRRP样本计算复杂度与测试推理时间的比较。

从表9可以看出,在训练阶段所提方法训练计算复杂度和训练时间需求高于大部分小样本识别方法,低于基于元学习MAML的小样本识别方法,这主要由于所提方法结合了数据扩充、域对齐、类对齐3种策略实现小样本性能提升,所增加的计算复杂度主要源于数据扩充策略的线性变换以及域对齐、类对齐损失的协同优化;从表10可以看出,在测试阶段所提方法所需推理时间更长,但整体量级与其他相关方法持平,推理效率无显著降低,所增加的计算复杂度主要源于测试样本特征经过生成器的非线性映射以及测试样本特征与各类多原型之间的距离计算(其他原型网络方法测试阶段仅需计算测试样本与各类单原型间的距离)。所提方法虽然整体效率稍有降低,但这一小成本开销带来了显著的小样本识别性能提升(如每类10个实测HRRP训练样本时,所提方法的识别准确率较性能次优的元学习方法MAML高10.27%)。因此,综合考量可实现性、训练/测试效率和识别性能,所提方法更具优越性,是实际应用部署可重点考虑的新方法。

表 9 不同方法单批次训练计算复杂度和训练时间对比

Tab. 9 Comparison of computational complexity and training time of single-batch training by different methods

方法	训练计算复杂度(FLOPs)	单批次训练时间(ms)
PN+微调	1.5×10^9	18.9
PNML	1.4×10^9	17.6
MAML	2.4×10^9	30.7
DAN	1.9×10^9	21.3
DANN	2.0×10^9	22.5
所提方法	2.1×10^9	26.9

3.4 地面车辆目标雷达HRRP识别结果与分析

为验证所提方法在含杂波、目标遮挡等复杂场景下的鲁棒性,以及面对目标类别更多情景下的普适性,下面给出所提方法和利用仿真数据辅助识别的相关方法在由SAMPLE数据集转换成的HRRP数据上的识别结果及分析。

(1) 标准操作条件

表11展示了不同方法在由标准操作条件下SAMPLE数据集转换成的HRRP数据上的小样本识别性能对比,所提方法在标准操作条件不同实测训练样本数量(每类1,5,10个实测训练样本)下均显著优于PN+微调的小样本识别方法和DAN、DANN等域适应方法。具体而言,在标准操作条件下,所提方法在每类10个实测HRRP训练样本情况下的识别率达到82.74%,远超性能次优的DANN的识别率76.39%;同样,在每类5个实测HRRP训练样本情况下的识别率达到77.46%,每类1个实测HRRP训练样本情况下的识别率达到69.52%,均明显高于对比方法。

为了更直观地验证所提方法的识别效果、仿真-实测域特征对齐情况以及特征可分性,图14给出了标准操作条件下对比方法和所提方法在每类10个实测训练HRRP样本情况下对10类地面车辆目标仿真训练HRRP数据和实测测试HRRP样本所提特征的t-SNE可视化。图14的10种不同颜色代表地面车辆目标的10种不同型号类别,不同颜色的圆

表 10 不同方法单个测试HRRP样本计算复杂度和推理时间对比

Tab. 10 Comparison of computational complexity and inference time for a single test HRRP sample by different methods

方法	测试计算复杂度(FLOPs)	推理时间(ms)
PN+微调	1.5×10^7	0.197
PNML	1.5×10^7	0.201
MAML	1.5×10^7	0.204
DAN	2.3×10^7	0.296
DANN	2.3×10^7	0.298
所提方法	2.8×10^7	0.359

表 11 不同方法在由标准操作条件下SAMPLE数据集转换成的HRRP数据上的识别性能对比(20次实验平均结果)

Tab. 11 Comparison of recognition performance of different methods on HRRP data converted from SAMPLE under the standard operating condition (average results of 20 experiments)

方法	1shot	5shot	10shot
PN+微调	60.10%±1.94%	67.89%±1.45%	71.65%±1.12%
DAN	58.14%±1.26%	69.96%±0.97%	75.23%±0.83%
DANN	58.81%±1.17%	70.24%±0.90%	76.39%±0.78%
所提方法	69.52%±0.81%	77.46%±0.52%	82.74%±0.39%

注:表内加粗数值表示最优指标数值。

形表示不同种类的源域训练特征，与圆形同色的黑框菱形表示与源域训练特征相同种类的目标域测试特征。

由图14可知，传统原型网络PN+微调的方式源域训练特征与目标域测试特征对齐效果不佳，且类间出现大量混淆，模型过拟合、泛化性较差；传统域适应方法DAN, DANN所提取不同域特征对齐效果仍较差、所提实测域特征可分性仍然有限，造成识别性能不佳；所提方法源域训练特征与同类别目

标域实测特征的特征分布更为相似，较对比方法的对齐效果更好，且提取的特征类间混叠现象明显减少，特征可分性显著提升。表11的实验结果与图14的特征可视化结果共同表明了所提方法在更多目标类别情况下仍具有鲁棒的小样本识别性能。

(2) 含杂波/目标遮挡条件

表12展示了不同方法在由含杂波/目标有遮挡的SAMPLE数据集转换成的HRRP数据上的小样本识别性能对比结果。在含杂波的场景下，所提方法




图 14 每类10个实测HRRP训练样本情况下不同方法在仿真训练HRRP和实测测试HRRP数据上的特征可视化。不同颜色的圆形表示不同类别的源域训练特征，与圆形同色的黑框菱形表示对应类目标域测试特征

Fig. 14 Visualization of the features of different methods on the simulated training HRRP and the measured test HRRP data under the condition of 10 measured HRRP training samples per class

表 12 不同方法在含杂波、目标有遮挡条件下SAMPLE数据集转换成的HRRP数据上的识别性能对比(20次实验平均结果)

Tab. 12 Comparison of recognition performance of different methods on HRRP data converted from SAMPLE under extended operating conditions (average results of 20 experiments)

场景条件	方法	1shot	5shot	10shot
含杂波	PN+微调	57.86%±2.02%	64.02%±1.58%	69.63%±1.24%
	DAN	55.91%±1.59%	65.25%±1.12%	73.04%±0.96%
	DANN	56.48%±1.43%	66.83%±1.04%	74.57%±0.83%
	所提方法	67.36%±0.94%	74.20%±0.61%	80.68%±0.45%
目标有遮挡	PN+微调	51.79%±2.16%	57.92%±1.75%	62.23%±1.46%
	DAN	49.64%±1.72%	60.36%±1.27%	67.42%±1.09%
	DANN	49.37%±1.59%	61.71%±1.13%	69.35%±0.91%
	所提方法	63.83%±1.08%	71.95%±0.79%	78.49%±0.57%

注：表内加粗数值表示最优指标数值。

保持了最高识别率,显著领先于对比方法。例如,在每类10个实测训练样本条件下所提方法的识别率达到了80.68%,而对比方法的识别率均低于75%,同时所提方法在含杂波场景下较标准操作条件下的识别性能下降较少,证明了所提方法在含杂波场景下的鲁棒性;在目标有遮挡的场景下,所提方法的优势更为突出,如,在每类10个实测训练样本条件下识别率达到了78.49%,而其他方法的识别率均低于70%,较对比方法均有较大提升,这证明其能有效抵抗强散射中心被小部分遮蔽所造成的信息损失。综上所述,实验表明,所提方法在面对复杂真实应用场景(含杂波、目标有遮挡)时具有泛化性和鲁棒性,以及在目标类别更多差异更细微的条件下

具有普适性,证明了其在复杂场景中的应用潜力。

图15进一步给出了含杂波/目标有遮挡情况下所提方法在每类10个实测HRRP训练样本学习识别模型后所提仿真HRRP特征和实测测试HRRP特征的t-SNE可视化,图15(a)为含杂波场景,图15(b)为目标有遮挡场景。对比图14(d)标准操作条件下所提方法所提特征的t-SNE可视化图,可以看到由于遮挡或杂波的影响,特征空间中的特征可分性有所变差(如蓝色类别),但仿真域与实测域各类别特征分布上仍然具有较好对齐效果,且类内特征具有紧凑性、类间特征仍具有分离性,进一步说明在含杂波、目标有遮挡的情况下,所提仿真数据辅助的小样本识别方法仍能具备较好的鲁棒性和泛化性。




图 15 含杂波/目标有遮挡条件下所提方法在实测HRRP数据上的特征可视化(每类10个实测训练样本)。不同颜色的圆形表示不同类别的源域训练特征,与圆形同色的黑框菱形表示对应类目标域测试特征

Fig. 15 Feature visualization of the proposed method (10 measured training HRRPs per class) on measured HRRP data under conditions with clutter or target occlusion

4 结语

在军事目标监测预警等实际场景中,非合作目标雷达HRRP训练样本常因雷达系统限制、目标姿态快速变化、观测环境复杂等因素,呈现姿态不完备、数量稀缺的小样本特性,很容易导致识别模型学习过拟合、实战化识别性能显著下降,难以满足精准的目标感知需求。本文针对小样本情况下雷达HRRP目标识别模型学习过拟合、识别泛化性显著下降的问题,提出了仿真数据辅助的雷达HRRP小样本目标识别方法。利用同类目标的电磁仿真数据,在数据、特征双层面迁移仿真数据知识,辅助实测域小样本目标识别任务,提升模型泛化性能。在数据层面,基于HRRP回波特性先验认知,在小角域内考虑实测数据和对应角域内仿真数据的均值、方差特性差异,对仿真数据进行均值、方差差异补偿实现实测域数据扩充;特征层面,基于GAN和PN,分别约束仿真域与实测域特征分布的域级整体对齐以及类级语义对齐。通过上述两个策

略协同迁移仿真域的知识,提升了小样本条件下的特征学习准确性以及模型泛化性。基于3类飞机目标实测HRRP数据和仿真HRRP数据的实验表明,所提方法较现有传统HRRP识别方法、小样本识别方法,在少量实测训练样本情况下识别性能显著提升。基于含噪飞机目标数据集、含杂波/目标遮挡10类地面车辆目标仿真HRRP数据和实测HRRP数据的实验表明,所提方法在面对更复杂的应用场景时仍具有明显的小样本识别优势。

利益冲突 所有作者均声明不存在利益冲突

Conflict of Interests The authors declare that there is no conflict of interests

参考文献

- [1] LI Liya, LIU Hongwei, JIU Bo, *et al.* Polarization radar HRRP recognition based on kernel methods[C]. The 6th International Symposium on Neural Networks on Advances in Neural Networks, Wuhan, China, 2009: 304–311. doi:

- [10.1007/978-3-642-01510-6_35](https://doi.org/10.1007/978-3-642-01510-6_35).
- [2] DU Lan, WANG Penghui, LIU Hongwei, *et al.* Radar HRRP target recognition based on dynamic multi-task hidden Markov model[C]. 2011 IEEE RadarCon (RADAR), Kansas City, USA, 2011: 253–255. doi: [10.1109/RADAR.2011.5960538](https://doi.org/10.1109/RADAR.2011.5960538).
 - [3] PAN Mian, DU Lan, WANG Penghui, *et al.* Noise-robust modification method for Gaussian-based models with application to radar HRRP recognition[J]. *IEEE Geoscience and Remote Sensing Letters*, 2013, 10(3): 558–562. doi: [10.1109/LGRS.2012.2213234](https://doi.org/10.1109/LGRS.2012.2213234).
 - [4] CHEN Bo, LIU Hongwei, and BAO Zheng. PCA and kernel PCA for radar high range resolution profiles recognition[C]. IEEE International Radar Conference, Arlington, USA, 2005: 528–533. doi: [10.1109/RADAR.2005.1435883](https://doi.org/10.1109/RADAR.2005.1435883).
 - [5] ZHANG Xianda, SHI Yu, and BAO Zheng. A new feature vector using selected bispectra for signal classification with application in radar target recognition[J]. *IEEE Transactions on Signal Processing*, 2001, 49(9): 1875–1885. doi: [10.1109/78.942617](https://doi.org/10.1109/78.942617).
 - [6] PEI Bingnan and BAO Zheng. Multi-aspect radar target recognition method based on scattering centers and HMMs classifiers[J]. *IEEE Transactions on Aerospace and Electronic Systems*, 2005, 41(3): 1067–1074. doi: [10.1109/TAES.2005.1541451](https://doi.org/10.1109/TAES.2005.1541451).
 - [7] DU Lan, LIU Hongwei, BAO Zheng, *et al.* Radar automatic target recognition using complex high-resolution range profiles[J]. *IET Radar, Sonar & Navigation*, 2007, 1(1): 18–26. doi: [10.1049/iet-rsn:20050119](https://doi.org/10.1049/iet-rsn:20050119).
 - [8] LIU Hongwei, FENG Bo, CHEN Bo, *et al.* Radar high-resolution range profiles target recognition based on stable dictionary learning[J]. *IET Radar, Sonar & Navigation*, 2016, 10(2): 228–237. doi: [10.1049/iet-rsn.2015.0007](https://doi.org/10.1049/iet-rsn.2015.0007).
 - [9] FENG Bo, DU Lan, LIU Hongwei, *et al.* Radar HRRP target recognition based on K-SVD algorithm[C]. 2011 IEEE CIE International Conference on Radar, Chengdu, China, 2011: 642–645. doi: [10.1109/CIE-Radar.2011.6159622](https://doi.org/10.1109/CIE-Radar.2011.6159622).
 - [10] DU Lan, LIU Hongwei, BAO Zheng, *et al.* A two-distribution compounded statistical model for radar HRRP target recognition[J]. *IEEE Transactions on Signal Processing*, 2006, 54(6): 2226–2238. doi: [10.1109/TSP.2006.873534](https://doi.org/10.1109/TSP.2006.873534).
 - [11] DU Lan, LIU Hongwei, and BAO Zheng. Radar HRRP statistical recognition: Parametric model and model selection[J]. *IEEE Transactions on Signal Processing*, 2008, 56(5): 1931–1944. doi: [10.1109/TSP.2007.912283](https://doi.org/10.1109/TSP.2007.912283).
 - [12] BARAT C and DUCOTTET C. String representations and distances in deep Convolutional Neural Networks for image classification[J]. *Pattern Recognition*, 2016, 54: 104–115. doi: [10.1016/j.patcog.2016.01.007](https://doi.org/10.1016/j.patcog.2016.01.007).
 - [13] KRIZHEVSKY A, SUTSKEVER I, and HINTON G E. ImageNet classification with deep convolutional neural networks[C]. The 26th International Conference on Neural Information Processing Systems, Lake Tahoe, USA, 2012: 1106–1114.
 - [14] ZHU Xiaoxiang, MONTAZERI S, ALI M, *et al.* Deep learning meets SAR: Concepts, models, pitfalls, and perspectives[J]. *IEEE Geoscience and Remote Sensing Magazine*, 2021, 9(4): 143–172. doi: [10.1109/MGRS.2020.3046356](https://doi.org/10.1109/MGRS.2020.3046356).
 - [15] LUNDÉN J and KOIVUNEN V. Deep learning for HRRP-based target recognition in multistatic radar systems[C]. 2016 IEEE Radar Conference, Philadelphia, USA, 2016: 1–6. doi: [10.1109/RADAR.2016.7485271](https://doi.org/10.1109/RADAR.2016.7485271).
 - [16] JITHESH V, SAGAYARAJ M J, and SRINIVASA K G. LSTM recurrent neural networks for high resolution range profile based radar target classification[C]. The 3rd International Conference on Computational Intelligence & Communication Technology, Ghaziabad, India, 2017: 1–6. doi: [10.1109/CIACT.2017.7977298](https://doi.org/10.1109/CIACT.2017.7977298).
 - [17] GUO Dandan, CHEN Bo, CHEN Wenchao, *et al.* Variational temporal deep generative model for radar HRRP target recognition[J]. *IEEE Transactions on Signal Processing*, 2020, 68: 5795–5809. doi: [10.1109/TSP.2020.3027470](https://doi.org/10.1109/TSP.2020.3027470).
 - [18] JIANG Mengjuan, FAN Jiaqing, HE Jiangzhen, *et al.* Contrastive prototype network with prototype augmentation for few-shot classification[J]. *Information Sciences*, 2025, 686: 121372. doi: [10.1016/j.ins.2024.121372](https://doi.org/10.1016/j.ins.2024.121372).
 - [19] 宋益恒, 王彦华, 李阳, 等. 基于深度生成网络的雷达HRRP生成技术[J]. 信号处理, 2019, 35(6): 1118–1122. doi: [10.16798/j.issn.1003-0530.2019.06.025](https://doi.org/10.16798/j.issn.1003-0530.2019.06.025).
SONG Yiheng, WANG Yanhua, LI Yang, *et al.* Radar HRRP generation using deep generative networks[J]. *Journal of Signal Processing*, 2019, 35(6): 1118–1122. doi: [10.16798/j.issn.1003-0530.2019.06.025](https://doi.org/10.16798/j.issn.1003-0530.2019.06.025).
 - [20] GAO Xunzhang and PENG Xuan. Robust sequential high-resolution range profile recognition based on the infinite conditional restricted Boltzmann machine[J]. *IET Radar, Sonar & Navigation*, 2020, 14(1): 71–80. doi: [10.1049/iet-rsn.2019.0012](https://doi.org/10.1049/iet-rsn.2019.0012).
 - [21] 李昱琛, 索继东. 基于FEKO软件的高分辨距离像建模仿真[J]. 弹箭与制导学报, 2020, 40(4): 10–13, 19. doi: [10.15892/j.cnki.djzdx.2020.04.003](https://doi.org/10.15892/j.cnki.djzdx.2020.04.003).
LI Yuchen and SUO Jidong. Modeling and simulation of high resolution range profile based on FEKO software[J]. *Missiles and Guidance*, 2020, 40(4): 10–13, 19. doi: [10.15892/j.cnki.djzdx.2020.04.003](https://doi.org/10.15892/j.cnki.djzdx.2020.04.003).
 - [22] REN Zuyu, JIANG Weidong, and ZHANG Xinyu. Few-shot HRRP target recognition method based on Gaussian deep

- belief network and model-agnostic meta-learning[C]. 2022 7th International Conference on Signal and Image Processing, Suzhou, China, 2022: 260–264. doi: [10.1109/ICSIP55141.2022.9887225](https://doi.org/10.1109/ICSIP55141.2022.9887225).
- [23] LI Jixi, LI Dongying, JIANG Yong, *et al.* Few-shot radar HRRP recognition based on improved prototypical network[C]. IEEE International Geoscience and Remote Sensing Symposium, Pasadena, USA, 2023: 5277–5280. doi: [10.1109/IGARSS52108.2023.10282950](https://doi.org/10.1109/IGARSS52108.2023.10282950).
- [24] LONG Mingsheng, CAO Yue, WANG Jianmin, *et al.* Learning transferable features with deep adaptation networks[C]. The 32nd International Conference on Machine Learning, Lille, France, 2015: 97–105.
- [25] CHEN Zhuo, ZHAO Lingjun, HE Qishan, *et al.* Pixel-level and feature-level domain adaptation for heterogeneous SAR target recognition[J]. *IEEE Geoscience and Remote Sensing Letters*, 2022, 19: 4515205. doi: [10.1109/LGRS.2022.3214750](https://doi.org/10.1109/LGRS.2022.3214750).
- [26] ZHOU Qiang, WANG Yanhua, ZHANG Xin, *et al.* Domain-adaptive HRRP generation using two-stage denoising diffusion probability model[J]. *IEEE Geoscience and Remote Sensing Letters*, 2024, 21: 3504305. doi: [10.1109/LGRS.2024.3379275](https://doi.org/10.1109/LGRS.2024.3379275).
- [27] LI Shuai, LI Wentao, HUANG Pengjun, *et al.* MTBC: Masked vision transformer and Brownian distance covariance classifier for cross-domain few-shot HRRP recognition[J]. *IEEE Sensors Journal*, 2025, 25(9): 16440–16454. doi: [10.1109/JSEN.2025.3550584](https://doi.org/10.1109/JSEN.2025.3550584).
- [28] 王鹏辉. 基于统计建模的雷达高分辨距离像目标识别方法研究[D]. [博士论文], 西安电子科技大学, 2012.
- WANG Penghui. Study of radar high resolution range profile target recognition based on statistical modeling[D]. [Ph.D. dissertation], Xidian University, 2012.
- [29] 杜兰. 雷达高分辨距离像目标识别方法研究[D]. [博士论文], 西安电子科技大学, 2007. doi: [10.7666/d.Y1137516](https://doi.org/10.7666/d.Y1137516).
- DU Lan. Study on radar HRRP target recognition[D]. [Ph.D. dissertation], Xidian University, 2007. doi: [10.7666/d.Y1137516](https://doi.org/10.7666/d.Y1137516).
- [30] CHEN Jian, DU Lan, GUO Guanbo, *et al.* Target-attentional CNN for radar automatic target recognition with HRRP[J]. *Signal Processing*, 2022, 196: 108497. doi: [10.1016/j.sigpro.2022.108497](https://doi.org/10.1016/j.sigpro.2022.108497).
- [31] GANIN Y and LEMPITSKY V S. Unsupervised domain adaptation by backpropagation[C]. The 32nd International Conference on Machine Learning, Lille, France, 2015: 1180–1189.
- [32] KONG Yingying, ZHANG Yuxuan, PENG Xiangyang, *et al.* Few-shot high-resolution range profile ship target recognition based on task-specific meta-learning with mixed training and meta embedding[J]. *Remote Sensing*, 2023, 15(22): 5301. doi: [10.3390/rs15225301](https://doi.org/10.3390/rs15225301).
- [33] 潘勉. 雷达高分辨距离像目标识别技术研究[D]. [博士论文], 西安电子科技大学, 2013.
- PAN Mian. Study of radar target recognition technology based on high range resolution profile[D]. [Ph.D. dissertation], Xidian University, 2013.

作者简介

陈 健, 博士, 副教授, 主要研究方向为雷达目标识别、雷达信号处理、机器学习等。

於 刚, 硕士生, 主要研究方向为雷达自动目标识别。

杜 兰, 博士, 教授, 主要研究方向为雷达目标检测识别、雷达信号处理、机器学习等。

董文强, 硕士, 主要研究方向为雷达自动目标识别。

郭昱辰, 博士, 讲师, 主要研究方向为SAR目标检测识别。

(责任编辑: 于青)