

结合相似度预测和阈值自动求解的开集条件下毫米波雷达点云步态识别方法

杜 兰* 李逸明 薛世鲲 石 钰 陈 健 李真芳

(西安电子科技大学雷达信号处理全国重点实验室 西安 710071)

摘 要: 现有的雷达步态识别方法多局限于闭集设置, 即假设测试阶段的所有身份类别均已包含在模板库中, 不适用于库内已知身份类别和库外未知身份类别共存的真实开放识别环境。针对非完备身份类别模板库条件下的步态识别问题, 该文提出一种结合相似度预测和阈值自动求解的开集条件下毫米波雷达点云步态识别方法。在点云特征提取的基础上, 结合对潜在未知类相似度得分分布的先验认知, 设计了一种伪开放环境训练策略来学习相似度预测网络, 提升相似度得分空间中已知类别与未知类别的鉴别性; 最后, 阈值自动求解模块通过极值理论对相似度得分的极值分布进行概率拟合, 并通过最小虚警与漏检准则实现未知类拒判阈值的准确求解。基于实测毫米波雷达点云数据的实验结果表明了所提方法在开集条件下具有良好的识别稳健性。

关键词: 毫米波雷达; 步态识别; 开集识别; 相似度预测; 极值理论

中图分类号: TN957

文献标识码: A

文章编号: 1009-5896(2025)09-0001-14

DOI: 10.11999/JEIT241034

1 引言

步态识别是一种新兴的生物特征识别技术, 基于人体行走时的姿态来识别身份^[1]。与人脸、指纹、虹膜等其他生物特征相比, 步态识别无需被识别对象的配合、不易伪装, 且能够在较远距离下获取稳定的特征。凭借这些独特优势, 步态识别在智慧安防、刑侦监控等多个领域获得了广泛应用^[2]。步态信息获取通常依赖于光学相机^[3]和雷达传感器^[4]。相较于光学相机, 雷达具备全天时、全天候的工作能力, 且因不依赖可见光图像而能够有效保护隐私。正因如此, 基于雷达的步态识别方法近年来受到越来越多的关注。

毫米波雷达是一种工作于毫米波频段(30~300 GHz)的雷达^[5]。与低频雷达相比, 毫米波雷达拥有更高的发射频率、更大的信号带宽以及更多的天线阵元, 这些特性赋予了其更强的分辨能力, 使其能够生成包含丰富目标信息的点云数据。在步态识别任务中, 人体行走的点云数据不仅捕捉了人体外形信息, 还记录了行走的动态信息。与仅包含运动信息的时频谱图相比^[6], 点云数据提供了更完整的步态信息, 对行走视角变化的适应性也更强。基

于这些优势, 已有学者开始研究从毫米波雷达点云中提取步态特征进行识别^[7-9]。

深度学习技术的快速发展为毫米波雷达点云步态识别提供了新的思路, 并取得了令人瞩目的性能提升。然而, 大多数现有方法采用闭集假设, 即假定待测样本的身份均已包含在模板库中。而步态识别往往面向真实开放环境, 需识别非合作目标。在这类任务中, 许多身份(如未知入侵者)难以预先收录, 因而难以建立完整的模板库。当出现未包含在模板库中的未知身份时, 闭集模型会将这些样本误判为已知身份, 显著降低识别系统的可靠性。

为了解决已知类与未知类共存的真实开放环境下的目标识别问题, 开集识别(Open-Set Recognition, OSR)技术应运而生^[10], 并受到越来越多的关注。与传统的闭集识别相比, 开集识别不仅能准确识别库内已知类目标, 还具备识别潜在未知类目标的能力。因此, OSR在毫米波雷达步态识别领域也得到了应用, 已有一些研究取得了初步成果, 但多数方法直接借鉴了光学图像目标识别领域的思路。如, 文献^[11]提出了基于已知类边界分布拟合的毫米波雷达开集步态识别方法, 该方法设计了深层判别表征网络(Deep Discriminative Representation Network, DDRN)网络用于提取更具有鉴别性的语义特征, 并基于极值理论(Extreme Value Theory, EVT)^[12]对已知类训练样本的边界样本进行概率拟合, 并依次计算得到最佳的概率拒判阈值。文献^[13]提出了细粒度鉴别的雷达步态开集识别方法, 该方法的识别网络包含一个编码解码模块和一个未知类拒判模块。编码解码模块在准确识别已知类目标的基

收稿日期: 2024-11-20; 改回日期: 2025-04-30; 网络出版: 2025-05-16

*通信作者: 杜兰 dulan@mail.xidian.edu.cn

基金项目: 国家自然科学基金(U21B2039, U24B20137, 62201433), 中央高校基本科研业务费专项资金(QTZX23067)

Foundation Items: The National Natural Science Foundation of China (U21B2039, U24B20137, 62201433), The Fundamental Research Funds for the Central Universities (QTZX23067)

础上能够对已知类训练样本具有较好的重构效果。未知类拒判模块在重构误差空间与特征空间对已知类分布进行概率拟合,通过人工设置阈值的策略实现异常样本的拒判。文献[14]提出了基于类中心度量的开集步态识别方法,该方法首先添加了角度边距损失以在特征空间中增强类间可分性与类内紧凑性,然后挑选已知类各类中心样本的特征作为类原型,并利用单类支持向量机构建已知类闭集决策界面,通过人工设置阈值来拒判与各已知类均不相似的潜在未知类样本。然而,这些方法的性能在很大程度上依赖于拒判阈值的设定。人工设置的拒判阈值难以准确找到最佳值,影响了模型在实际应用中识别已知类和鉴别未知类的整体性能,从而限制了步态识别方法的应用潜力。

针对现有开集识别方法中未知类拒判阈值设置不准确的问题,本文提出结合相似度预测和阈值自动求解的开集条件下毫米波雷达点云步态识别方法。本文基于对已知类和未知类在特征匹配度上的差异先验认知,设计了相似度预测网络。本网络本质上是一个2元分类器,通过伪开放环境训练策略的约束,显著提升了相似度得分空间中已知类与库外未知类的鉴别性。在此基础上,为了自动确定拒判库外未知身份类别的阈值,进一步设计了阈值自动求解模块。本模块基于极值理论对相似度得分空间中的极值分布进行概率拟合,构建了有效的拒判阈值求解模型,从而实现了未知类的自动拒判。所提方法避免了人工阈值设置的不确定性,提升了开集识别模型在复杂环境中的实际应用性能。

2 步态识别模型任务描述及方法介绍

2.1 步态识别模型任务描述

图1展示了传统步态识别模型的训练和测试流程。与光学图像目标识别不同,步态识别在实际应

用中通常被视为检索任务^[6]。在这种任务框架下,给定一个待识别的查询样本,识别系统通过计算待识别样本与预先构建的步态模板库中样本的特征相似度,选择相似度最高的模板样本所对应的身份作为识别结果。基于这种检索方式,只需将感兴趣身份的步态模板样本加入模板库,无需重新训练模型,即可识别该身份。相比于传统方法在新身份出现时需重新训练模型,基于检索的步态识别方法在灵活性上更具优势。

在训练阶段,通过拉近同类样本特征间的距离,推远异类样本特征间的距离,使特征提取网络学习同类特征匹配的能力;在测试阶段,给定已构建的包含感兴趣类别的步态模板库和一个查询样本(待识别样本),首先使用训练好的特征提取网络提取查询样本与模板库中所有样本的特征,接着计算查询样本特征与模板库样本特征之间的相似度。最终,将与查询样本相似度最高的模板库样本所对应的类别作为查询样本的识别结果。

从上述流程可以看出,在检索任务框架下,点云特征提取网络的训练样本的身份类别可以与模板库中的身份类别不一致^[6]。然而,闭集步态识别模型只能识别模板库中已有的类别。当查询样本的类别不包含在模板库中时,闭集模型会强制将该未知类别样本误判为与其特征最相似的某一已知类别,从而导致在开放环境下的稳健性较差。因此,研究开集条件下毫米波雷达点云步态识别方法具有重要的实际应用价值。

2.2 方法介绍

图2展示了所提的结合相似度预测与阈值自动求解的开集条件下毫米波雷达点云步态识别方法。整体方法分为4个模块:点云特征提取网络训练、相似度预测网络训练、阈值自动求解以及开集测试。在网络训练过程中,本文采用串行训练方式:




图1 检索任务框架下闭集步态识别模型的训练和测试流程




图2 结合相似度预测和阈值自动求解的开集条件下的毫米波雷达点云步态识别方法示意图

首先训练点云特征提取网络, 保证稳定的特征提取能力; 然后基于该网络提取的特征训练相似度预测网络, 进一步优化已知/未知类别的区分能力。具体地, 点云特征提取网络^[15]通过3元对比损失提升特征的类内紧凑性与类间分离性, 确保网络具备稳健的特征表达能力。相似度预测网络基于对已知类和未知类相似度得分分布的先验认知, 通过得分约束实现相似度得分空间中已知类和未知类的有效区分。网络训练完成后, 阈值自动求解模块采用极值理论对相似度得分分布进行建模, 通过最小虚警与漏检准则实现拒判阈值的自动求解。所提方法通过相似度预测网络进一步放大已知类与未知类在相似度得分空间的分布差异, 为决策边界的准确划分奠定了基础; 同时, 阈值自动求解模块为拒判阈值求解提供了理论支持, 增强了开集条件下算法的适应性与识别准确性。下面对各模块进行详细介绍。

2.2.1 点云特征提取网络训练模块

人体行走时生成的毫米波雷达点云数据不仅反映了人体的外形轮廓信息, 也反映了行走的运动信息。不同人在行走时对应的毫米波雷达点云数据在外形

和运动特征上具有较大差异, 步态识别模型可以从点云数据中提取空间和时间特征来实现对不同人的识别。为了充分利用毫米波点云包含的步态信息, 本文采用文献^[15]所提的细粒度空时特征提取网络从点云中提取步态特征, 整体网络架构如图3所示。为了充分提取步态空间特征, 本文提出双流点云特征提取模块和概率引导的身体部位划分模块。其中, 双流点云特征提取模块基于空间-RCS支路和速度支路实现对毫米波雷达点云中包含的3维空间坐标、多普勒速度以及RCS信息的精细利用; 概率引导的人体区域划分模块基于点云在高度维的概率分布, 将稀疏毫米波雷达点云精细划分为不同身体部位。为了充分提取步态时间特征, 本文提出局部-全局时序特征提取模块, 该模块基于多尺度时序卷积来获取不同时间粒度下的局部步态特征, 并基于注意力加权策略自适应地聚合局部时序特征以获取全局时序特征。更详细的网络结构介绍请参考我们之前的工作^[15]。

网络的输入为多帧点云数据 $P = \{P_1, P_2, \dots, P_T\}$, 其中 T 代表输入帧数, $P_i = \{p_1^i, p_2^i, \dots, p_N^i\}$ 表示第




图3 文献[15]所提细粒度空时特征提取网络架构

i 帧的点云数据, 共包含 N 个点。每个点 $\mathbf{p}_j^i \in \mathbb{R}^5$ 均包含5维属性: 3维空间坐标 x_j^i, y_j^i, z_j^i 、多普勒速度 v_j^i 以及散射强度 RCS_j^i , 每帧点云均可看成2维矩阵形式的数据 $\mathbf{P}_i \in \mathbb{R}^{N \times 5}$ 。为了消除点云的绝对距离对模型学习的影响, 对点云数据的3维坐标采用中心归一化。同时, 对RCS值和多普勒速度进行最大值归一化, 以降低数量级上的差异。为了方便后续身体部位的划分, 将每帧点云数据按 Z 轴高度从高至低排序, 排序后 $\mathbf{P}_i$ 的第1行为第 i 帧中高度最高的点, 最后一行则为高度最低的点, 此时 $\mathbf{P}_i$ 在行维度上即与人体的高度相关。将排序后的每帧点云数据 $\mathbf{P}_i$ 输入双流点云特征提取模块提取高维逐点特征 $\mathbf{F}_i \in \mathbb{R}^{N \times C}$, 其中 C 代表输出的通道数。接着将 $\mathbf{F}_i$ 输入概率引导的人体区域划分模块, 依据人体点云在高度上的概率分布将 $\mathbf{F}_i$ 划分为 K 个身体部位, 得到各个身体部位对应的特征 $\{\mathbf{F}_i^k \in \mathbb{R}^C | k = 1, 2, \dots, K\}$ 。每个身体部位共有 T 帧特征, 组合得到 $\mathbf{B}_k = \{\mathbf{F}_i^k \in \mathbb{R}^C | i = 1, 2, \dots, T\}$ 。将 $\mathbf{B}_k$ 输入局部-全局时序特征提取模块提取各个部位的时空特征 $\mathbf{B}' = \{\mathbf{B}_k' | k = 1, 2, \dots, K\} \in \mathbb{R}^{K \times C'}$, 其中 $\mathbf{B}_k' \in \mathbb{R}^{C'}$ 代表第 k 个部位对应的时空特征, C' 代表输出通道数。最后将 $\mathbf{B}'$ 输入全连接层映射并展平即可得到最终输出点云深层步态特征 $\mathbf{f}_o \in \mathbb{R}^{C_o}$, C_o 代表输出通道数。

经过点云特征提取网络后, 可得到各个样本对应的步态特征。为了使得训练好的点云特征提取网络具备在检索任务下的识别能力, 采用度量学习中常用的3元组损失函数优化网络。该损失函数旨在最小化同类特征之间的差异并最大化异类特征之间的差异, 对于一个批次的训练样本, 可以由下式计算其3元组损失

$$\mathcal{L}_{\text{triplet}} = \sum_{i=1}^{\text{all anchors}} \sum_{a=1}^Q \sum_{\substack{p=1 \\ p \neq a}}^Q \sum_{j=1}^P \sum_{\substack{n=1 \\ j \neq i}}^Q [\max(m + D_p - D_n, 0)] \quad (1)$$

其中, P 代表一批样本内类别的个数, Q 代表每个类别的样本个数, D 代表欧式距离。将批数据中的每个样本依次作为锚点样本(anchor sample), 并将剩余样本中与其类别相同的样本定义为正样本(positive sample), 与其类别不同的样本定义为负样本(negative sample)。则 $D_p = D(\mathbf{f}_o^a, \mathbf{f}_o^p)$ 代表锚

点样本特征 $\mathbf{f}_o^a$ 与某一正样本特征 $\mathbf{f}_o^p$ 之间的欧式距离, $D_n = D(\mathbf{f}_o^a, \mathbf{f}_o^n)$ 代表锚点样本特征 $\mathbf{f}_o^a$ 与某一负样本特征 $\mathbf{f}_o^n$ 之间的欧式距离, m 用于控制 D_p 与 D_n 之间的距离间隔。对于每个锚点样本, 遍历其所有正负样本3元组计算3元损失。通过最小化上述损失, 可以在度量空间上拉近同类样本特征距离, 推远异类样本特征距离, 使得模型学习到度量样本特征之间匹配程度的能力。

2.2.2 相似度预测网络训练模块

图4(a)展示了查询样本(待识别样本)与模板库样本之间最近Top-1欧式距离分布直方图。其中, 蓝色表示模板库中出现过的身份类别(已知类)与模板库样本之间的最近欧式距离, 红色表示模板库中未出现过的身份类别(未知类)与模板库样本之间的最近欧式距离。从中可以看出, 对于模板库中的已知身份类别, 特征提取网络能够通过有效的特征匹配输出更接近模板库的特征距离, 而对于模板库未包含的身份类别, 其特征距离则相对较远。尽管闭集步态识别方法可以通过人工设置基于欧式距离的拒判阈值来鉴别未知类样本, 但在最近欧式距离空间中, 未知类与已知类的分布仍存在部分重叠, 这增加了二者混淆的风险, 使得合理设置或求解拒判阈值变得更加困难。

充分考虑到已知类和未知类在与模板库样本进行距离度量时存在的分布差异, 相似度预测模块设计了伪开放环境网络训练策略, 以增强相似度得分空间中已知类与未知类的区分性。具体而言, 如果查询样本的身份类别存储于模板库中, 查询样本(已知类)特征需要与对应样本特征尽可能相似。如果查询样本的身份类别没有存储于模板库中, 查询样本(未知类)特征需要与模板库中所有样本特征均不相似。

给定步态点云数据, 相似度预测模块随机划分出部分身份类别作为相似度预测网络的训练数据 $\mathbf{P}^{k+u}$ 。为了模拟真实开放环境中可能遇到的未知身份类别, 该模块挑选其中 P_1 个身份类别作为伪已知类数据 $\mathbf{P}^k$, 而剩下 P_2 个身份类别作为伪未知类数据 $\mathbf{P}^u$, 其中, 伪已知类数据和伪未知类数据的类别互不相交 ($\mathbf{C}^k \cap \mathbf{C}^u = \emptyset$)。对于伪已知类数据 $\mathbf{P}^k$, 相似度预测模块将其划分为伪已知类模板库 $\mathbf{P}_{\text{gallery}}^k$ 和伪已知类查询样本 $\mathbf{P}_{\text{probe}}^k$, 而伪未知类数




图4 最近欧式距离分布示意图与相似度预测网络结构图

据 $\mathbf{P}^u$ 全部作为伪未知类查询样本 $\mathbf{P}_{\text{probe}}^u$ 。在每轮迭代训练中，计算 $\mathbf{P}_{\text{probe}}^{k+u} = \{\mathbf{P}_{\text{probe}}^k, \mathbf{P}_{\text{probe}}^u\}$ 中每个查询样本与伪已知类模板库 $\mathbf{P}_{\text{gallery}}^k$ 样本之间的特征欧氏距离，并选取最近 Top-k 距离向量作为相似度预测网络的输入。

图4(b)给出相似度预测网络的结构图，其包含多个全连接层和一个 Sigmoid 激活函数。Top-k 距离向量经过相似度预测网络后得到预测相似度得分 $p \in [0, 1]$ 。结合图4(a)中已知类与未知类相似度得分的先验认知，相似度预测网络训练的真值标签设定如下：如果输入距离向量来自伪已知类查询样本 $\mathbf{P}_{\text{probe}}^k$ 时，其真值标签设为1；如果输入距离向量来自伪未知类查询样本 $\mathbf{P}_{\text{probe}}^u$ 时，其真值标签设为0。相似度预测网络通过交叉熵损失函数进行训练，以此约束模型在已知类和未知类的鉴别性

$$\mathcal{L}_{\text{sim}} = -y_i \ln_e(p_i) - (1 - y_i) \ln_e(1 - p_i) \quad (2)$$

其中， $p_i \in [0, 1]$ 为第 i 个查询样本的预测相似度得分， y_i 为该查询样本的相似度预测标签(取值为0或1)。伪开放环境网络训练策略在训练阶段模拟步态识别模型的匹配过程，通过式(2)约束使相似度预测网络在准确匹配模板库中已知类查询样本的同时，降低模板库外未知类查询样本的相似度得分，从而在相似度得分空间中增强已知类与未知类的区分性。

2.2.3 阈值自动求解模块

阈值自动求解模块旨在通过极值理论对伪查询样本 $\mathbf{P}_{\text{probe}}^{k+u}$ 相似度得分的极值分布进行概率拟合，以确定更准确的拒判阈值。如图5所示，点云特征提取网络与相似度预测网络训练完成后，该模块对伪已知类查询样本 $\mathbf{P}_{\text{probe}}^k$ 与伪未知类查询样本 $\mathbf{P}_{\text{probe}}^u$ 的相似度得分从小到大进行排序，随后对伪已知类查询样本 $\mathbf{P}_{\text{probe}}^k$ 的极大值分布与伪未知类查询样本 $\mathbf{P}_{\text{probe}}^u$ 的极大值分布进行概率分布拟合，得到对应的概率密度函数与累计分布函数，并基于最小虚警与漏检准则自动求解最优阈值。

极值理论^[12]是统计学的一个分支，用于处理随机变量的极端分布。假设 $\{X_1, X_2, \dots, X_n\}$ 是一组独立同分布的随机变量序列，其概率分布函数为 $F(z)$ 。定义该随机变量的最大值 M_n 为

$$M_n = \max \{X_1, X_2, \dots, X_n\} \quad (3)$$

根据概率分布定理可知

$$\Pr(M_n \leq x) = \Pr(X_1 \leq x, \dots, X_n \leq x) = F^n(x) \quad (4)$$

根据 Fisher-Tippett-Gnedenko 定理，当 $n \rightarrow \infty$ 时，存在两组序列 $\{a_n\}, \{b_n\}$ 和一个非递减分布函数 D 满足

$$\Pr\left(\frac{M_n - b_n}{a_n} \leq x\right) = F^n(a_n x + b_n) \rightarrow D(x) \quad (5)$$

其中， $D(x)$ 为广义极值分布，通常为 Frechet, Weibull 或 Gumbel 分布，分布函数定义为

$$D(x) = \exp \left\{ - \left(1 + \xi \frac{x - \mu}{\sigma} \right)^{-1/\xi} \right\} \quad (6)$$

其中， $\mu \in \mathbb{R}$ ， $\sigma \in \mathbb{R}^+$ 和 $\xi \in \mathbb{R}$ 分别表示位置参数、尺度参数和形状参数。

使用广义极值分布建模随机变量极值分布时，需要先从 Frechet, Weibull 或 Gumbel 分布中选取一个分布，再选取多个子样本进行参数估计，在实际应用中较为繁琐。为了简化对随机变量极值分布的建模，广义帕累托分布 (Generalized Pareto Distribution, GPD)^[16] 被提出，该分布用以建模随机变量在超过阈值 τ 的条件下，超过某一数值的概率

$$P(X > x + \tau | X > \tau) = 1 - G(x) \quad (7)$$

其中， $G(x)$ 即为广义帕累托分布，分布函数定义为

$$G(x) = 1 - \left(1 + \xi \frac{x}{\sigma} \right)_+^{-1/\xi}, x > 0 \quad (8)$$

其中， $x_+ = \max(x, 0)$ ，可以使用极大似然估计算法来估计 GPD 的参数。在开集识别领域中，极值

理论通常被用来建模已知类或未知类极端值的概率分布^[17,18]。

图6进一步给出真实已知类和未知类在相似度得分空间的分布关系。与图4距离空间相比,通过伪开放环境网络训练策略,相似度预测网络在相似度得分空间中能够更有效地鉴别真实已知类和未知类。同时,伪已知类和未知类分布能够良好地模拟真实已知类和未知类分布,因此训练阶段确定的拒判阈值能够良好泛化到真实开放识别环境。经验性地,最佳相似度拒判阈值通常位于已知类和未知类得分分布的重叠区域内^[18]。该阈值在减少未知类误报和已知类漏判之间实现了良好的平衡。由于设置拒判阈值的主要判别信息隐藏在已知类和未知类得分分布的尾部,同时相似度预测网络可以对其进行近似描述,因此准确拟合匹配和不匹配重构误差的尾部对于计算精确的拒判阈值至关重要。为了更精确地拟合拒判阈值所在的重叠区域,该模块使用广义帕累托分布来拟合分布。具体地,对于每个分布,首先选取其极值样本,再利用极大似然算法估计极值样本对应的广义帕累托分布函数 $G(x)$ 的参数。其中,选取模拟已知类分布的极小值样本拟合分布 G^k ;选取模拟未知类分布的极大值样本拟合分布 G^u 。需要注意的是,GPD仅用于拟合极大值,因此在

拟合 G^k 之前,该模块对其进行反向变换: $G^k = -G^k$ 。根据式(7),最优阈值可以通过求解式(9)来得到

$$\begin{aligned}\tau^* &= \min[P(S^u > \tau | S^u > th^u) \\ &\quad + P(P^k < \tau | P^k < th^k)] \\ &= \min[P(S^u > \tau - th^u + th^u | S^u > th^u) \\ &\quad + P(P^k < -(-th^k - \tau - th^k) | P^k < th^k)] \\ &= \min[P(S^u > \tau - th^u + th^u | S^u > th^u) \\ &\quad + P(-P^k > th^k - \tau - th^k | -P^k > -th^k)] \\ &= \min[1 - G^u(\tau - th^u) + 1 - G^k(th^k - \tau)] \quad (9)\end{aligned}$$

其中, th^k 和 th^u 分别表示已知类得分分布的极小值阈值和未知类得分分布的极大值阈值。 τ^* 表示位于 $[th^k, th^u]$ 之间的最优阈值。从式(9)可以看出,随着 τ 增加,未知类虚警率 $1 - G^u(\tau - th^u)$ 降低但已知类漏检率 $1 - G^k(th^k - \tau)$ 会提升。为了找到最小化虚警与漏检的最优阈值,该模块采用网格搜索策略进行阈值求解。网格搜索可以遍历参数范围 $[th^k, th^u]$ 内所有候选点,避免遗漏全局最优解。同时网格点计算相互独立,支持GPU并行加速。本文将搜索步长设为 $1e-4$ 以兼顾搜索精度与搜索效率。

2.2.4 开集测试

图2展示了所提方法测试阶段。首先,将待测点云数据和所有模板库样本输入点云特征提取网络




图5 阈值自动求解流程




图6 已知类和未知类样本的相似度得分分布

得到对应步态特征 $\mathbf{F}_P \in \mathbb{R}^{C_0}$ 和 $\mathbf{F}_G \in \mathbb{R}^{N_G \times C_0}$ ，其中 $\mathbf{F}_P$ 代表查询样本特征， $\mathbf{F}_G$ 代表模板库样本特征。接着计算查询样本与所有模板库样本特征之间的欧式距离，得到 $\mathbf{d} \in \mathbb{R}^{N_G}$ ；并选取最近的 Top- k 欧氏距离 $\mathbf{d}_{\text{Top-}k} \in \mathbb{R}^k$ 输入相似度预测网络，得到该查询样本预测的相似度得分 p 。如果相似度得分 p 小于阈值自动求解模块得到的拒判阈值 τ ，则该样本被判为未知类；如果相似度得分 $p \geq \tau$ ，则将距离最近的模板库样本对应的类别作为识别结果。

3 实验与分析

3.1 实验数据与设置

目前，公开的多人毫米波雷达点云步态数据集较少。为了验证所提方法的有效性，本文使用文献[15]所采集的数据集进行实验。该数据集包含90名受试者在3种不同穿着条件下(正常穿着、挎包、穿大衣)，沿10个视角行走的步态点云数据。对于每个受试者，该数据集共包含10组数据：6组正常行走数据、2组挎包数据、2组穿大衣数据。因此，每个受试者共包含100组数据，整个步态数据集共包含9 000组数据。

在本文实验中，将90人的数据集随机划分出50人的数据作为训练集，剩余40人的数据作为测试集。根据所提方法的需要，进一步将50人的训练数据划分出30人的数据用以训练点云特征提取网络，剩余20人作为相似度预测网络训练的数据，其中10个身份类别数据作为伪未知类数据，剩余10个身份类别数据作为伪已知类数据。对于训练阶段的伪已知类数据和测试阶段的真实已知类数据，将前4组正常穿着数据(NM01-NM04)作为模板库样本，将剩余2组正常穿着数据(NM05-NM06)、2组挎包数据(BG01-BG02)以及2组穿大衣数据(CT01-CT02)作为查询样本，其中每组数据均包含10个行走视角的样本。因此，在训练阶段，伪已知类查询样本共有600个，伪模板库样本共有400个；伪未知类的查询样本共有1 000个。在步态识别实验中，采用多视角的实验设置，即模板库中包含所有视角的样本，不将查询样本对应的视角去除。

针对开集识别问题，Scheirer等人[10]引入了开放度(Openness)的概念

$$\text{Openness} = 1 - \sqrt{\frac{2 \times |C_{\text{known}}|}{|C_{\text{known}}| + |C_{\text{test}}|}} \quad (10)$$

其中， $|C_{\text{known}}|$ 代表已知类别的个数， $|C_{\text{test}}|$ 代表测试类别的个数。若开放度为0，则测试类别与已知类别完全相同，开集识别问题退化为闭集识别问题。随着开放度的增加，测试中未知类别的占比越大，开集识别任务就越困难。在本文实验中，将40人的

测试数据按不同比例随机划分为已知类数据和未知类数据，进而验证所提方法在不同开放度下的性能。

点云特征提取网络的参数设置与训练流程与文献[15]保持一致。相似度预测网络采用4层全连接构建，每层全连接均包含一个全连接层和ReLU非线性激活函数，每层全连接的输出维度为64, 64, 32和1。训练阶段，对每个训练查询样本选取其前 $k = 64$ 个欧式距离输入网络。采用SGDM优化器优化网络参数，学习率设置为0.000 1，动量系数设置为0.9，L2权重衰减因子设置为0.000 1。整体模型训练5 000个周期。在阈值自动求解模块，对于伪已知类的相似度得分分布，选取其前20%极小值样本拟合极值分布；对于伪未知类的相似度得分分布，选取其前20%极大值样本拟合极值分布。

3.2 评价指标

在开集识别领域中，通常采用查准率(Precision)、查全率(Recall)、F1分数(F1-score)和准确率(Accuracy)来评判开集识别性能

$$\text{Precision}_i = \frac{\text{TP}_i}{\text{TP}_i + \text{FP}_i}, \text{Precision} = \frac{\sum_{i=1}^K \text{Precision}_i}{K} \quad (11)$$

$$\text{Recall}_i = \frac{\text{TP}_i}{\text{TP}_i + \text{FN}_i}, \text{Recall} = \frac{\sum_{i=1}^K \text{Recall}_i}{K} \quad (12)$$

$$\text{F1-score}_i = \frac{2 \times \text{Precision}_i \times \text{Recall}_i}{\text{Precision}_i + \text{Recall}_i},$$

$$\text{F1-score} = \frac{\sum_{i=1}^K \text{F1-score}_i}{K} \quad (13)$$

$$\text{Acc} = \frac{\text{TP} + \text{TN}}{\text{TN} + \text{TP} + \text{FP} + \text{FN}} \quad (14)$$

其中， $K = |C_{\text{known}}|$ 代表测试集中已知类别的个数， TP_i 代表第 i 个已知类中识别正确的样本个数， FP_i 代表其他已知类或未知类错误识别第 i 个已知类的样本个数， FN_i 代表第 i 个已知类中错误识别为其他已知类或未知类的样本个数， TN 代表正确拒判的未知类样本个数。查准率 Precision 反映了识别为已知类的结果中识别正确的比例，查全率 Recall 反映了真实已知类目标中被正确识别的比例。F1-score 是查准率 Precision 和查全率 Recall 的调和平均值。准确率 Acc 反映了步态识别模型对测试数据集的整体识别指标。

3.3 实验与分析

3.3.1 对比实验

针对目前基于检索模型的开集步态识别方法较

为匮乏的问题,本文从已有的基于分类模型的开集识别方法中挑选了适合检索模型结构的开集策略作为对比方法。具体来说,这些方法在训练阶段无需利用真实的已知类样本优化模型,而是通过在测试阶段对待识别样本和已知类样本特征的比对来实现识别。因此,其原理和思想可以迁移到检索任务中的开集步态识别任务中。本文对这些算法进行了改进,使之能够适应本实验的设定,以更好地评估在检索场景下开集步态识别的有效性和表现。

(1)基于最大后验概率的方法:该方法在各个文献中常被当作基准对比方法,在本实验中,计算待识别样本与模板库中每个已知类中心的距离,并利用Softmax函数计算得到该样本属于各个已知类的概率。若最大类中心概率小于0.5,则将该样本判为未知类。

(2)基于分类向量修正的方法:文献[10]所提方法,在本实验中,先计算出模板库中每个已知类的类中心和极值分布,并根据OpenMax算法得到待识别样本属于未知类的概率,最终取最大概率类别作为识别结果。

(3)基于最近距离比的方法:文献[19]所提方法,在本实验中,先计算待识别样本与模板库样本中已知类的最近距离比,若距离比大于拒判阈值,则该样本判为未知类。

(4)一类SVM方法:文献[14]所提方法,在本实验中,首先挑选模板库中每个已知类的类中心样本,用于训练一类SVM,从而构建已知类的闭合决策边界。如果待识别样本位于已知类决策边界之外,则将其判定为未知类。

(5)类归属概率方法:文献[11]所提方法,在本实验中,首先计算模板库中每个已知类的边界样本并进行极值建模,然后利用类归属概率算法得到待识别样本不属于各已知类别的概率。如果待识别样本属于任何模板库已知类别的概率均小于0.5,则将样本判为未知类。

为了评估各个方法在不同开放度条件下的稳健

性,分别在开放度为52.86%(5类已知类,35类未知类)、36.75%(10类已知类,30类未知类)、26.15%(15类已知类,25类未知类)、18.35%(20类已知类,20类未知类)、12.29%(25类已知类,15类未知类)、7.42%(30类已知类,10类未知类)的条件下进行实验。每个开放度共进行5次实验,每次实验随机选取已知类和未知类身份类别,取平均结果作为最终识别性能。实验结果如表1所示。

OpenMax方法^[10]和最近距离比方法^[19]通过度量待识别样本与测试模板库样本的相似度来区分未知目标,而一类SVM方法^[14]和类归属概率方法^[11]则通过构建各已知类别的闭合决策边界来区分未知目标。得益于已知类决策边界的良好建模,一类SVM方法^[14]和类归属概率方法^[11]相比OpenMax方法^[10]和最近距离比方法^[19]展现出更强的性能优势和鲁棒性。具体而言,随着开放度从7.42%增加至52.86%,OpenMax方法^[10]的F1分数从83.18%下降至49.35%,而类归属概率方法^[11]的F1分数仅从85.83%下降至73.93%。与前两类方法相比,本文方法通过相似度预测网络进一步增强了已知类与未知类在相似度预测空间中的分布差异,并通过合理设定阈值有效区分了两类。因此,本文方法在各开放度下的F1分数均优于对比方法,充分证明了其在开放场景变化下的稳健。

为了进一步分析各方法对于已知类和未知类的混淆情况,本文绘制了各个方法在开放度为18.35%条件下的混淆矩阵,将20类已知类视为1类进行分析(如图7所示)。其中,方法(b)使用OpenMax算法修正待识别样本的预测向量,虽然能够保持已知类的高识别准确率,但在区分难分未知类时存在局限。方法(c)使用最近距离比,能够有效拒判大部分未知目标,但也会误拒一些已知目标。方法(d)和方法(e)则通过按类建模已知类的决策边界,成功区分出大量未知目标。在已知类识别准确率上,方法(e)略优于方法(d),因为方法(e)使用边界样本来建模决策边界,而方法(d)使用类中心样本。相较于这些

表1 不同开集步态识别方法在不同开放度条件下的F1分数(%)

开集方法	开放度(%)					
	7.42	12.29	18.35	26.15	36.75	52.86
基于最大后验概率的方法	85.99±0.71	82.61±0.49	73.39±0.83	61.77±1.85	43.93±2.56	25.85±3.52
OpenMax方法 ^[10]	83.18±1.23	79.07±1.21	75.37±1.08	69.95±1.64	61.66±1.79	49.35±2.45
最近距离比方法 ^[19]	79.08±1.31	79.76±0.99	81.57±4.38	81.42±3.65	75.21±3.35	69.16±4.11
一类SVM方法 ^[14]	84.87±2.85	82.78±1.12	80.73±1.83	78.74±3.09	77.45±3.88	74.38±4.13
类归属概率方法 ^[11]	85.83±1.77	83.35±2.38	82.69±2.09	81.67±3.78	78.86±3.83	73.93±3.73
本文方法	88.87±0.54	88.61±0.69	88.41±1.62	86.94±1.19	83.50±2.15	78.84±2.72




图 7 不同开集步态识别方法的混淆矩阵

方法，本文所提方法既能准确地识别已知类，也准确拒判未知类，在开放环境下的识别稳健性更好。

3.3.2 模型分析

(1)消融实验：为了进一步分析本文所提相似度预测模块和阈值自动求解模块对识别结果的影响，分别将各个模块去除进行消融实验。实验中基线方法(Baseline)为基于最大概率的方法。去除相似度预测模块的方法采用最近类中心概率作为拒判依据，并通过自动阈值求解模块计算阈值。去除阈值自动求解模块的方法采用相似度预测网络预测的相似度作为拒判依据，并设定相似度阈值为0.5。在不同开放度条件下统计各方法的F1得分，消融实验结果如表2所示。

从实验结果可以看出，本文所提的相似度预测模块和阈值自动求解模块均能提升识别效果，且两种模块组合可以取得最好的识别效果，验证了各个模块的有效性和互补性。与基线模型相比，添加相似度预测模块在各个开放度下分别提升了0.7%，11.15%，38.42%的F1得分。可以看出，使用相似度预测模块能够提升大开放度下的识别性能，增强了方法的稳健性。虽然使用手工设定的阈值在低开放度下能够取得一定的识别效果，但其在较大开放度下的性能较差(43.93%)。与此相比，阈值自动求解模块计算出的阈值在大开放度下的泛化效果更好，提升了22.88%的F1得分。此外，在相似度预测模块基础上添加阈值自动求解模块可以进一步提升识别效果，验证了阈值自动求解模块的通用性。

(2)对相似度预测策略的分析：本方法基于查询样本与多个模板库样本之间的欧式距离，利用相似度预测网络预测查询样本类别存在于模板库中的相似度作为拒判依据。为了验证相似度预测策略的有效性，将相似度预测替换为其他拒判依据，并使用同样的阈值求解模块求解拒判阈值实现开集识别。表3展示了基于不同拒判依据的方法在不同开放度条件下的F1得分。

从实验结果可以看出，与使用最大类中心概率相比，使用欧式距离作为拒判依据取得的开集识别效果更好。具体而言，基于最大类中心概率的方法在开放度为36.75%的条件下仅能取得66.8%的F1得

表 2 所提模块的消融实验(%)

	相似度预测 模块	阈值自动 求解模块	7.42% 开放度	18.35% 开放度	36.75% 开放度
Baseline	×	×	85.99	73.39	43.93
所提 模块	√	×	86.69	84.54	82.35
	×	√	76.26	74.19	66.81
	√	√	88.87	88.41	83.50

表 3 基于不同拒判依据的方法对应开集识别F1分数(%)

拒判依据	7.42%开放度	18.35%开放度	36.75%开放度
最大类中心概率	76.26	74.19	66.81
最近类中心距离	85.59	80.44	74.45
最近样本欧式距离	88.56	85.57	82.51
本文所提相似度	88.87	88.41	83.50

分,而基于欧式距离的方法在各个开放度下均有较大的性能提升。这可能是由于点云特征提取网络训练时采用的是样本之间的欧式距离计算损失,而不是经过Softmax层输出的概率,欧式距离可以更好反映样本之间的相似性。在基于欧式距离的方法中,使用最近类中心距离的方法易受模板库样本个数的影响,在大开放度条件下,模板库中已知类样本个数较少,导致这两种方法的性能较差。与此相比,使用最近样本距离的方法对模板库样本个数不敏感,在较大开放度下也能取得较好的识别效果。

虽然基于最近样本欧式距离的方法取得了一定的效果,但其仅考虑了查询样本与模板库样本之间的最近距离,并没有考虑查询样本与多个模板样本的关系。相比之下,本文所提的相似度预测策略基于查询样本与多个模板样本的欧式距离,利用深度网络挖掘查询样本与模板库样本的相似性,在各个开放度下取得了最好的开集识别效果。

图8展示了测试中已知类和未知类样本在各个度量空间上的分布。从图8(a)中可以看出,已知类的最大类中心概率通常较大,而未知类的最大类中心概率通常较小,但两者分布之间有较大程度的重叠,因此基于最大类中心的方法容易在测试中混淆已知类和未知类样本,导致其开集识别性能较差。图8(b)–图8(d)展示了欧式空间内的已知类和未知

类分布,可以看出,已知类的欧式距离通常较小,而未知类的欧式距离通常较大。与最大类中心概率分布相比,欧式距离分布重叠程度更小,因此其识别效果也更好。从图8可以看出,已知类样本经相似度预测网络输出的相似度接近于0,而未知类样本经相似度预测网络输出的相似度接近于1。与各个欧式距离分布相比,本文所提相似度分布重叠度最小,因此在测试中更容易区分已知类和未知类样本。

(3)点云特征提取网络分析实验:为了验证点云特征提取网络对开集识别性能的影响,在7.42%,18.35%和36.75% 3个开放度下,实验了不同点云特征提取网络的开集识别效果。每个开放度共进行5次实验,统计5次实验结果的平均值作为最终识别性能,如表4所示。

(a)SRPNet模型:文献[9]所提模型,该模型利用PointNet网络提取每帧点云空间特征,利用LSTM网络提取多帧时序特征。

(b)HDNet模型:文献[20]所提模型,该模型利用AdaptNet网络提取每帧点云空间特征,提出动态采样算法采样关键帧特征,并利用Transformer网络提取时序特征。该方法基于分类任务构建,本文将最后全连接层输出替换为步态特征向量,并使用三元组损失替换原有交叉熵损失,以在本文数据集上训练和验证。




图8 不同拒判依据下的已知类和未知类分布

表4 不同点云特征提取网络对开集识别性能的影响(%)

不同模型	7.42%开放度	18.35%开放度	36.75%开放度
SRPNet ^[9]	33.92	32.37	16.62
HDNet ^[20]	38.10	34.26	21.98
PcGaitPart ^[21]	81.54	67.36	38.02
PcCSTL ^[22]	84.27	71.10	41.03
本文模型	85.99	73.39	43.93

(c)PcGaitPart模型：文献[21]所提模型，该模型提出局部卷积模块，用以提取不同身体部位的空间特征。同时，提出微动捕获模块和时序池化模块，用以提取多帧时序特征。

(d)PcCSTL模型：文献[22]所提模型，该模型提出时间尺度模块，分别提取逐帧、短时以及长时特征，并提出自适应时间聚合模块，用以融合多帧时序特征。同时，提出空间显著性模块，对各个身体部位的特征进行增强或削弱。

表4展示了不同点云特征提取网络对开集识别性能的影响。在实验中，本文在训练好的特征提取器基础上，使用最大概率方法区分已知目标与未知目标。与现有步态识别模型相比，我们提出的模型在各开放度下表现出更高的F1分数。具体而言，SRPNet和HDNet分别采用LSTM和Transformer模型提取时序特征，这些模型更关注于提取长时间内的步态特征，缺乏对短时间内微动特征的提取。此外，SRPNet和HDNet均将人体点云视为一个整体处理，未充分考虑各个身体部位的独特特征。PcGaitPart和PcCSTL对特征沿高度维均匀切分，并没有考虑毫米波雷达点云的空间分布特点。与此相比，本文所提点云特征提取网络充分考虑了人体点云在高度维的概率分布，基于各个区域的分布概率对特征沿高度维非均匀切分，以此获得更准确的身体部位特征。其次，PcGaitPart和PcCSTL方法提取的时序特征不够丰富。PcGaitPart虽然考虑了短时间的微动特征，但其时序特征仅为单一时间粒度，缺乏不同时间粒度的特征。PcCSTL提取了多个时间粒度的时序特征，其识别效果相较于PcGaitPart更好。与此相比，本文所提点云特征提取网络不仅提取了多个时间粒度的时序特征，还利用注意力加权机制自适应地聚合了不同帧以及不同时间粒度的特征。得益于本文模型所提取的更稳健的点云步态特征，本文方法在开集条件下取得了显著的性能优势。

(4)参数分析实验：相似度预测网络基于查询样本与模板库样本间的Top- k 距离预测相似度得分。为研究 k 值大小对开集识别效果的影响，在18.35%开放度条件下，实验不同 k 值下的开集识别

效果。每个 k 值共进行5次实验，统计5次实验结果的平均值作为最终识别性能，如表5所示。

从实验结果可以看出，当 k 值为64时，开集识别的F1分数和准确率最高。这可能是由于当 k 值过小时，输入相似度预测网络的信息较少，不能充分表征查询样本与模板样本的关联，导致预测的查询样本相似度可能不准确。当 k 值过大时，已知类查询样本对应的Top- k 距离可能包含很多非匹配距离，进而影响其相似度预测。在实际应用中，需要考虑模板库中样本的个数，合理设置 k 值的大小。

在阈值自动求解过程中，需要选取模拟已知类和模拟未知类的极值样本拟合极值分布，极值分布拟合的好坏直接影响求解出拒判阈值的好坏。为了研究选取的极值样本比例对开集识别效果的影响，在18.35%开放度条件下，实验了不同选取比例下的开集识别效果。每个选取比例下进行5次实验，统计5次实验结果的平均值作为最终识别性能，如表6所示。

从实验结果可以看出，当选取的极值样本比例为20%时，开集识别的F1分数和准确率最高。这可能是由于当选取的样本比例过少时，极大似然估计算法难以准确地估计的分布参数；当选取的样本比例过大时，那些不属于极值的样本也被用于拟合分布，导致拟合出的极值分布也不准确。在实际应用中，需要综合考虑模拟已知类和未知类的样本个数以及分布特点，选取合适比例的极值样本拟合对应分布。

在阈值自动求解过程中，搜索步长对阈值求解精度具有一定影响。为研究不同搜索步长对搜索精度的影响，在18.35%开放度条件下，实验了不同搜索步长下的模型识别率。每个搜索步长设定下进行5次实验并统计5次实验结果的平均值作为最终识别性能，如表7所示。本实验硬件条件采用NVIDIA GeForce RTX 3090 GPU(24GB GDDR6X显存，CUDA 11.6。

实验结果表明，随着搜索步长的减小，搜索时长逐渐增加，但模型的F1分数逐渐上升至稳定。得益于相似度预测网络扩大了已知/未知类的分布

表5 不同 k 值条件下模型的开集识别性能(%)

k	查准率	查全率	F1分数	准确率
16	93.65	80.78	86.00	90.15
32	95.02	80.03	86.30	90.56
64	92.45	87.92	88.41	91.59
96	88.69	85.24	85.71	88.16
128	94.06	74.67	82.31	87.87

表 6 不同极值样本选取比例条件下模型的开集识别性能(%)

选取比例(%)	查准率	查全率	F1分数	准确率
5	93.55	83.66	87.63	91.05
10	93.30	84.03	87.72	91.07
20	92.45	87.29	88.41	91.59
30	93.90	83.34	87.62	91.09
40	94.09	82.71	87.35	90.97
50	94.49	81.99	87.11	90.86

表 7 不同网格搜索步长对搜索时长和搜索精度的影响。

搜索步长	搜索时长(s)	F1分数
1e-5	3.872 243	88.41
1e-4	0.633 015	88.41
1e-3	0.064 913	88.25
1e-2	0.008 936	87.94
5e-1	0.000 677	86.75

差异,即使搜索步长设为 $1e-2$,模型的F1分数仍保持在87%以上。为平衡搜索时长与精度,本文将搜索步长设为 $1e-4$ 。

4 结论

在前期复杂协变量稳健的特征提取网络工作^[15]的基础上,本文进一步研究了类别开放条件下的毫米波雷达点云步态识别方法。提出方法继承了前期点云特征提取网络的稳健识别能力,通过相似度预测网络提升了已知类与未知样本在相似度得分空间中的鉴别性,并进一步结合阈值自动求解模块缓解了人工设置拒判阈值不准确导致的识别性能低下的问题。实测毫米波雷达点云步态数据的实验结果表明,所提方法在类别开放条件下能够有效实现对已知与未知目标的准确区分。

参 考 文 献

- [1] SARKAR S, PHILLIPS P J, LIU Z, *et al.* The HumanID gait challenge problem: Data sets, performance, and analysis[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2005, 27(2): 162–177. doi: [10.1109/TPAMI.2005.39](#).
- [2] SEPAS-MOGHADDAM A and ETEMAD A. Deep gait recognition: A survey[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2023, 45(1): 264–284. doi: [10.1109/TPAMI.2022.3151865](#).
- [3] KALE A, SUNDARESAN A, RAJAGOPALAN A N, *et al.* Identification of humans using gait[J]. *IEEE Transactions on Image Processing*, 2004, 13(9): 1163–1173. doi: [10.1109/TIP.2004.832865](#).
- [4] VANDERSMISSEN B, KNUDDE N, JALALVAND A, *et al.* Indoor person identification using a low-power FMCW radar[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2018, 56(7): 3941–3952. doi: [10.1109/TGRS.2018.2816812](#).
- [5] RICHARDS M A. Fundamentals of Radar Signal Processing[M]. New York: Mcgraw-hill, 2005.
- [6] 杜兰, 陈晓阳, 石钰, 等. MMRGait-1.0: 多视角多穿着条件下的雷达时频谱图步态识别数据集[J]. 雷达学报, 2023, 12(4): 892–905. doi: [10.12000/JR22227](#).
- [7] DU Lan, CHEN Xiaoyang, SHI Yu, *et al.* MMRGait-1.0: A radar time-frequency spectrogram dataset for gait recognition under multi-view and multi-wearing conditions[J]. *Journal of Radars*, 2023, 12(4): 892–905. doi: [10.12000/JR22227](#).
- [8] ZHAO Peijun, LU C X, WANG Jianan, *et al.* mID: Tracking and identifying people with millimeter wave radar[C]. 2019 15th International Conference on Distributed Computing in Sensor Systems (DCOSS), Santorini, Greece, 2019: 33–40. doi: [10.1109/DCOSS.2019.00028](#).
- [9] MENG Zhen, FU Song, YAN Jie, *et al.* Gait recognition for co-existing multiple people using millimeter wave sensing[C]. The 34th AAAI Conference on Artificial Intelligence, New York, USA, 2020: 849–856. doi: [10.1609/aaai.v34i01.5430](#).
- [10] CHENG Yuwei and LIU Yimin. Person reidentification based on automotive radar point clouds[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2022, 60: 5101913. doi: [10.1109/TGRS.2021.3073664](#).
- [11] SCHEIRER W J, DE REZENDE ROCHA A, SAPKOTA A, *et al.* Toward open set recognition[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2013, 35(7): 1757–1772. doi: [10.1109/TPAMI.2012.256](#).
- [12] NI Zhongfei and HUANG Binke. Open-set human identification based on gait radar micro-Doppler signatures[J]. *IEEE Sensors Journal*, 2021, 21(6): 8226–8233. doi: [10.1109/JSEN.2021.3052613](#).
- [13] FISHER R A and TIPPETT L H C. Limiting forms of the frequency distribution of the largest or smallest member of a sample[J]. *Mathematical Proceedings of the Cambridge Philosophical Society*, 1928, 24(2): 180–190. doi: [10.1017/S0305004100015681](#).
- [14] YANG Yang, GE Yanyan, LI Beichen, *et al.* Multiscenario open-set gait recognition based on radar micro-Doppler signatures[J]. *IEEE Transactions on Instrumentation and Measurement*, 2022, 71: 2519813. doi: [10.1109/TIM.2022.3214271](#).
- [15] MOON J, JUNG J, KANG E, *et al.* Open set user identification using gait pattern analysis based on ensemble deep neural network[J]. *IEEE Sensors Journal*, 2022, 22(17): 16975–16984. doi: [10.1109/JSEN.2022.3188527](#).

- [15] XUE Shikun, DU Lan, SHI Yu, *et al.* Fine-grained spatial-temporal gait recognition network based on millimeter-wave radar point cloud[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2024, 62: 5101316. doi: [10.1109/TGRS.2023.3345829](https://doi.org/10.1109/TGRS.2023.3345829).
- [16] BALKEMA A A and DE HAAN L. Residual life time at great age[J]. *The Annals of Probability*, 1974, 2(5): 792–804. doi: [10.1214/aop/1176996548](https://doi.org/10.1214/aop/1176996548).
- [17] ZHANG He and PATEL V M. Sparse representation-based open set recognition[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2017, 39(8): 1690–1696. doi: [10.1109/TPAMI.2016.2613924](https://doi.org/10.1109/TPAMI.2016.2613924).
- [18] LI Yiming, DU Lan, CHEN Jian, *et al.* An open set recognition for SAR targets based on encoding-conditional decoding network with reject threshold adaptation[J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2024: 1–16. doi: [10.1109/JSTARS.2024.3416175](https://doi.org/10.1109/JSTARS.2024.3416175).
- [19] MENDES JÚNIOR P R, DE SOUZA R M, DE O WERNECK R, *et al.* Nearest neighbors distance ratio open-set classifier[J]. *Machine Learning*, 2017, 106(3): 359–386. doi: [10.1007/s10994-016-5610-8](https://doi.org/10.1007/s10994-016-5610-8).
- [20] HUANG Yanyan, WANG Yong, SHI Kun, *et al.* HDNet: Hierarchical dynamic network for gait recognition using millimeter-wave radar[C]. 2023–2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Rhodes Island, Greece, 2023: 1–5. doi: [10.1109/ICASSP49357.2023.10096835](https://doi.org/10.1109/ICASSP49357.2023.10096835).
- [21] FAN Chao, PENG Yunjie, CAO Chunshui, *et al.* GaitPart: Temporal part-based model for gait recognition[C]. The 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seattle, USA, 2020: 14213–14221. doi: [10.1109/CVPR42600.2020.01423](https://doi.org/10.1109/CVPR42600.2020.01423).
- [22] HUANG Xiaohu, ZHU Duowang, WANG Hao, *et al.* Context-sensitive temporal feature learning for gait recognition[C]. The 2021 IEEE/CVF International Conference on Computer Vision, Montreal, Canada, 2021: 12889–12898. doi: [10.1109/ICCV48922.2021.01267](https://doi.org/10.1109/ICCV48922.2021.01267).
- 杜 兰: 女, 博士, 教授, 博士生导师, 研究方向为雷达目标识别、雷达信号处理、机器学习。
李逸明: 男, 博士生, 研究方向为SAR图像目标识别与开放世界学习。
薛世鲲: 男, 硕士生, 研究方向为毫米波雷达步态识别与机器学习。
石 钰: 男, 博士生, 研究方向为雷达目标检测识别与多模态学习。
陈 健: 男, 博士, 副教授, 硕士生导师, 研究方向为雷达目标检测识别与机器学习。
李真芳: 男, 博士, 教授, 博士生导师, 研究方向为干涉/极化合成孔径雷达信号处理与系统设计。

责任编辑: 余 蓉

Millimeter-wave Radar Point Cloud Gait Recognition Method Under Open-set Conditions Based on Similarity Prediction and Automatic Threshold Estimation

DU Lan LI Yiming XUE Shikun SHI Yu CHEN Jian LI Zhenfang

(National Key Laboratory of Radar Signal Processing, Xidian University, Xi'an 710071, China)

Abstract:

Objective Radar-based gait recognition systems are typically developed under closed-set assumptions, limiting their applicability in real-world scenarios where unknown individuals frequently occur. This constraint presents challenges in security-critical settings such as surveillance and access control, where both accurate recognition of known individuals and reliable exclusion of unknown identities are essential. Existing methods often lack effective mechanisms to differentiate between known and unknown classes, leading to elevated false acceptance rates and security risks. To overcome this limitation, this study proposes an open-set recognition framework that integrates a similarity prediction network with an adaptive thresholding method based on Extreme Value Theory (EVT). The framework models the score distributions of known and unknown classes to enable robust identification of unfamiliar identities without requiring samples from unknown classes during training. The proposed method enhances the robustness and applicability of millimeter-wave radar-based gait recognition under open-set conditions, supporting its deployment in operational environments.

Methods The proposed method comprises four key modules: point cloud feature extraction network training, similarity prediction network training, automatic threshold estimation, and open-set testing. A sequential training strategy is adopted to ensure robust learning. First, the point cloud feature extraction network is

trained with a triplet loss function that encourages intra-class compactness and inter-class separability by pulling same-class samples closer and pushing different-class samples apart. This enables the network to learn stable and discriminative representations, even under variations in viewpoint or clothing. The extracted features are then input into a similarity prediction network trained to model the score distributions of known and unknown identities. By incorporating score-based constraints, the network learns a decision space in which known and unknown classes are more effectively separated. Following network optimization, an EVT-based thresholding module is employed. This module dynamically models the tail distributions of similarity scores and automatically determines a class-agnostic threshold by minimizing the joint false acceptance and false rejection rates. This adaptive and theoretically grounded strategy enhances the separation between known and unknown classes in the similarity space. Together, these modules improve the stability and accuracy of radar-based gait recognition under open-set conditions, supporting reliable operation in real-world scenarios where unfamiliar individuals may appear.

Results and Discussions The proposed method improves distributional separation between known and unknown classes in the similarity score space through the similarity prediction network and distinguishes them effectively using adaptive thresholding. Experimental results show that the method consistently yields higher F1 scores across all openness levels compared with baseline approaches, indicating strong robustness to open-set variations (Table 1). Specifically, the method achieves an 87% recognition rate for known classes and a 96% rejection rate for unknown classes, outperforming all comparison methods (Fig. 7). Ablation experiments confirm that incorporating the similarity prediction module enhances recognition performance under high openness. Manually set thresholds, while effective under low openness, show substantial performance degradation under large openness (F1 score: 43.93%). In contrast, the proposed automatic thresholding module demonstrates superior generalization, improving the F1 score by 22.88% under large openness conditions (Table 2). Further analysis shows that the method significantly increases the score distribution gap between known and unknown classes, contributing to improved recognition reliability (Fig. 8). Comparative evaluations (Table 3) confirm that the method achieves superior open-set recognition performance. In addition, the employed point cloud feature extraction network captures temporal features at multiple time scales and uses an attention-based mechanism to adaptively aggregate information across frames and temporal resolutions. This contributes to more robust gait representations and further improves open-set recognition performance compared with other feature extraction networks (Table 4).

Conclusions Building on previous work on robust feature extraction under complex covariate conditions, this study extends millimeter-wave radar point cloud gait recognition to open-set scenarios. The proposed method preserves the recognition strength of the original feature extraction network and enhances class discriminability by integrating a similarity prediction network. To address the limitations of manually defined rejection thresholds, an automatic threshold determination module based on EVT is introduced. Extensive experiments using measured millimeter-wave radar point cloud gait data confirm that the method reliably distinguishes between known and unknown individuals, demonstrating its effectiveness and robustness under open-set conditions.

Key words: Millimeter-wave radar; Gait recognition; Open-set recognition; Similarity prediction; Extreme Value Theory (EVT)