

基于线性动态模型的雷达高分辨距离像小样本目标识别方法

王鹏辉* 刘宏伟 杜 兰 潘 勉 张学峰
(西安电子科技大学雷达信号处理国家重点实验室 西安 710071)

摘 要: 为了解决雷达高分辨距离像识别系统对训练样本需求量过大的问题, 该文提出一种基于线性动态模型的小样本目标识别方法。首先分析了距离像频谱的统计特性, 然后从其广义平稳性出发, 使用线性动态模型对距离像频谱幅度建模, 并用期望最大化算法估计模型参数。实测数据的实验结果表明: 即使在很少的训练样本条件下, 该方法仍能获得较高的正确识别率和良好的拒判性能。

关键词: 雷达目标识别; 高分辨距离像; 广义平稳-不相关散射; 线性动态模型

中图分类号: TN957.51

文献标识码: A

文章编号: 1009-5896(2012)02-0305-07

DOI: 10.3724/SP.J.1146.2011.00680

Linear Dynamic Model Based Radar HRRP Target Recognition under Small Training Set Conditions

Wang Peng-hui Liu Hong-wei Du Lan Pan Mian Zhang Xue-feng
(National Key Lab of Radar Signal Processing, Xidian University, Xi'an 710071, China)

Abstract: To relax the heavy requirement of training sample size in the radar High Resolution Range Profile (HRRP) target recognition, a linear dynamic model based recognition method is proposed. Firstly, the statistical characteristic of HRRP's frequency spectrum is analyzed and considered to be a Wide Sense Stationary (WSS) process. Then a linear dynamic model is employed to model the amplitude of frequency spectrum and an Expectation Maximization (EM) algorithm is adopted to estimate the model parameters. Finally, experimental results based on measured data show that the proposed method can obtain satisfactory recognition accuracy and rejection performance even with a very few training samples.

Key words: Radar target recognition; High Resolution Range Profile (HRRP); Wide Sense Stationary-Unrelated Scattering (WSS-US); Linear dynamic model

1 引言

高分辨距离像(以下简称距离像)是用宽带雷达信号获取的目标散射点回波在雷达视线方向投影的矢量和。它包含了目标的尺寸, 散射点分布等重要结构信息, 且易于获取和处理, 因此被广泛的用于雷达自动目标识别领域^[1-3]。

通常, 目标的尺寸远大于宽带雷达信号的波长, 回波中的目标信号占据了较多的距离单元, 所以目标的距离像具有较高的维度。为了克服传统方法在使用高维距离像数据进行目标识别时存在的“维数灾难”^[4], 需要在训练识别系统时提供大量的距离像训练样本。对于己方合作目标来说, 录取大量的训练样本并不困难。然而, 对于先进的敌方非合作目标(如隐形战机, 高速无人机等), 雷达很难持续检

测和跟踪, 也难以获得足够多的距离像数据。而这类目标的威胁程度最大, 是识别的重点。因此, 如何能够在保持识别性能的前提下, 尽量降低识别系统对训练样本数的需求, 是雷达目标识别领域亟需解决的难题。

目前已有不少文献进行相关研究, 这些工作大致可分为两类: (1)采用低自由度的统计模型对距离像建模。文献[5]采用的自适应高斯分类器(AGC)模型自由参数少, 对训练样本数的需求较小。但该模型对距离像统计特性的描述较简单, 识别性能一般。文献[6]使用因子分析(FA)模型对距离像建模, 该模型考虑了距离单元之间的相关性, 识别性能有明显提高。但相比于 AGC 模型, FA 模型有更多的自由度, 它并未从根本上解决识别系统对训练样本数需求过大的问题; (2)从距离像中提取低维度的特征。文献[7]通过线性判别分析, 将距离像投影到低维空间, 并在该空间内进行识别。文献[8]利用超分辨率法, 从距离像中提取强散射中心的反射强度和位置信息作为判别特征。这类方法大大降低了特征维度, 放松了识别系统对训练样本数的需求。然而, 降维

2011-07-03 收到, 2011-11-17 改回

国家自然科学基金(60901067, 61001212), 新世纪优秀人才支持计划项目(NCET-09-0630), 长江学者和创新团队发展计划项目(IRT0954)和中央高校基本科研业务费专项资金联合资助课题

*通信作者: 王鹏辉 wangpenghui@mail.xidian.edu.cn

过程中将会丢失目标判别信息,使得识别性能受到限制。

本文在分析了距离像频谱统计特性的基础上,使用线性动态模型对距离像频谱幅度建模,并采用期望最大化算法估计模型参数。基于实测数据的实验结果表明本文方法能够在小样本条件下仍保持较好的识别和拒判性能。

2 高分辨距离像频谱统计特性分析

高分辨雷达通常工作在微波波段,因此目标及其部件的尺寸远大于雷达信号波长。此时,目标的电磁特性可用散射中心模型^[6]来描述。根据该模型,目标的高分辨距离像可以表示为

$$\mathbf{x} = e^{j\varphi} [x_1, x_2, \dots, x_d]^T \quad (1)$$

其中上标 T 表示转置操作符, φ 为距离像初相, x_l ($l=1, 2, \dots, d$) 为第 l 个距离单元的复回波。距离像 $\mathbf{x}$ 的频谱 $\mathbf{y}$ 可以表示为

$$\mathbf{y} = \text{fft}(\mathbf{x}) = e^{j\varphi} [y_1, y_2, \dots, y_d]^T \quad (2)$$

其中 $\text{fft}(\cdot)$ 表示快速傅里叶变换,第 f 个频点处的频谱分量 $y_f = \sum_{l=1}^d x_l e^{-j2\pi fl/d}$ ($f=1, 2, \dots, d$)。文献[9-11]中研究了距离像频谱作为识别特征的可行性,并取得了很好的识别效果。使用频谱特征进行目标识别,具有以下优点:(1)快速傅里叶变换是一个信息保持变换,距离像从时域变换到频域的过程中没有信息损失;(2)频谱幅度具有平移不变性,识别过程中不需要平移对齐操作^[6],既降低了识别系统的复杂度,也避免了对齐算法引入的误差;(3)频谱具有很好的统计特性(如下文中将要介绍的广义平稳性),合理利用这些统计特性作为判别信息,有助于改善识别

性能。下面为了检验不同目标距离像频谱的可分性,本文在图1中给出了3类目标的实测距离像和相应频谱的幅度(数据介绍见第5部分),从图中可以明显看出,不同目标的频谱和距离像一样具有很强的可分性。

雷达领域常用“广义平稳-不相关散射”模型对宽带雷达目标回波建模^[5,12]。该模型假设目标距离像各距离单元的回波之间统计独立,且服从均值为零的复高斯分布。通过数学推导可知,距离像频谱中的所有频率分量服从均值为零的复高斯分布,且任意两个频率分量的相关函数只与它们的频率差有关,即距离像频谱是一个广义平稳过程^[12]。不同目标的结构不同,其频谱所服从的广义平稳过程的统计特性也各不相同,因此,本文使用频谱统计特性的差异作为区分不同目标的判别信息。在此之前,为了克服频谱的初相敏感性^[6],本文丢掉频谱的相位信息,只考虑频谱幅度 $\mathbf{z} = |\mathbf{y}|$,其中 $|\cdot|$ 表示取模操作符。容易证明,频谱幅度(以下简称频幅) $\mathbf{z}$ 仍然服从广义平稳过程^[11]。

3 线性动态模型

线性动态模型,也称作状态空间模型,常用于广义平稳过程建模,并已成功应用于模式识别领域^[13,14]。给定距离像的频幅 $\mathbf{z}$,线性动态模型由下面的观测方程和状态方程构成:

$$\mathbf{z}_f = \mathbf{C}\mathbf{u}_f + \mu + v_f, \quad \mathbf{u}_f = \mathbf{A}\mathbf{u}_{f-1} + \mathbf{w}_f \quad (3)$$

其中 $\mathbf{z}_f$ ($f=1, 2, \dots, d$) 表示频幅 $\mathbf{z}$ 中的第 f 个元素; $1 \times m$ 维的矩阵 $\mathbf{C}$ 称为观测矩阵 ($m \ll d$); $m \times 1$ 维的向量 $\mathbf{u}_f$ 是 $\mathbf{z}_f$ 对应的隐状态; μ 是频幅 $\mathbf{z}$ 的均值;




图1 3类目标的实测距离像及其对应频谱的幅度

$v_f \sim G(v_f | 0, \sigma^2)$ 是观测噪声, $G(v_f | 0, \sigma^2)$ 表示 v_f 服从均值为 0, 方差为 σ^2 的高斯分布; $m \times m$ 维的矩阵 $\mathbf{A}$ 称为状态转移矩阵; $m \times 1$ 维的向量 $\mathbf{w}_f \sim G(\mathbf{w}_f | \mathbf{0}, \mathbf{Q})$ 是状态噪声, 且 $\mathbf{w}_f$ 与 v_f 相互独立; 初始状态 $\mathbf{u}_0 \sim G(\mathbf{u}_0 | \boldsymbol{\mu}_0, \mathbf{R})$ 。为了限定模型的自由度, 提高模型参数的估计精度, 这里约束 $\mathbf{Q}$ 和 $\mathbf{R}$ 为对角阵。所有的模型参数都不随频率 f 的变化而改变。从式 (3) 中可以看出, 线性动态模型利用一个隐的马尔科夫状态序列 $\mathbf{U} = \{\mathbf{u}_0, \mathbf{u}_1, \dots, \mathbf{u}_d\}$ 来间接地描述频幅随频率的演化, 亦即频幅的广义平稳性。相比于直接对广义平稳性建模的自回归等模型, 线性动态模型的识别性能更优, 且具有一定的抗噪能力^[13]。

下面讨论模型参数估计问题。线性动态模型的对数似然函数 $L(\boldsymbol{\Theta})$ 可以表示为

$$L(\boldsymbol{\Theta}) = -\frac{1}{2} \sum_{f=1}^d (\mathbf{u}_f - \mathbf{A}\mathbf{u}_{f-1})^T \mathbf{Q}^{-1} (\mathbf{u}_f - \mathbf{A}\mathbf{u}_{f-1}) - \frac{d}{2} \ln |\mathbf{Q}| - \frac{1}{2} \sum_{f=1}^d \frac{(z_f - \mu - \mathbf{C}\mathbf{u}_f)^2}{\sigma^2} - \frac{d}{2} \ln |\sigma^2| - \frac{1}{2} (\mathbf{u}_0 - \boldsymbol{\mu}_0)^T \mathbf{R}^{-1} (\mathbf{u}_0 - \boldsymbol{\mu}_0) - \frac{1}{2} \ln |\mathbf{R}| - \frac{d(m+1)+1}{2} \ln(2\pi) \quad (4)$$

其中 $\boldsymbol{\Theta} = \{\mathbf{A}, \mathbf{C}, \mathbf{Q}, \mathbf{R}, \boldsymbol{\mu}_0, \sigma^2, \mu\}$ 表示模型参数的集合。由于 $L(\boldsymbol{\Theta})$ 中所有的隐状态 $\mathbf{u}_f$ 未知, 因此难以直接估计模型参数。本文采用期望最大化(EM)算法^[14]估计模型参数。EM 算法通过迭代地最大化期望对数似然函数 $Q(\boldsymbol{\Theta})$ 来得到模型参数的最大似然估计。 $Q(\boldsymbol{\Theta})$ 定义为

$$Q(\boldsymbol{\Theta}) = E(L(\boldsymbol{\Theta}) | \mathbf{z}) = -\frac{1}{2} \sum_{f=1}^d \text{Tr}[E(\mathbf{u}_f \mathbf{u}_f^T | \mathbf{z}) \mathbf{Q}^{-1}] + E(\mathbf{u}_{f-1} \mathbf{u}_{f-1}^T | \mathbf{z}) \mathbf{A}^T \mathbf{Q}^{-1} \mathbf{A} - 2E(\mathbf{u}_{f-1} \mathbf{u}_f^T | \mathbf{z}) \cdot \mathbf{Q}^{-1} \mathbf{A} - \frac{d}{2} \ln |\mathbf{Q}| - \frac{1}{2\sigma^2} \sum_{f=1}^d \{\text{Tr}[E(\mathbf{u}_f \mathbf{u}_f^T | \mathbf{z}) \mathbf{C}^T \mathbf{C}] - 2E(\mathbf{u}_f^T | \mathbf{z}) \cdot \mathbf{C}^T (z_f - \mu) + (z_f - \mu)^2\} - \frac{d}{2} \ln |\sigma^2| - \frac{1}{2} \{\text{Tr}[E(\mathbf{u}_0 \mathbf{u}_0^T | \mathbf{z}) \mathbf{R}^{-1}] - 2E(\mathbf{u}_0 | \mathbf{z}) \boldsymbol{\mu}_0^T \mathbf{R}^{-1}\} + \boldsymbol{\mu}_0^T \mathbf{R}^{-1} \boldsymbol{\mu}_0 - \frac{1}{2} \ln |\mathbf{R}| - \frac{d(m+1)+1}{2} \ln(2\pi) \quad (5)$$

其中 $E(\cdot | \cdot)$ 和 $\text{Tr}(\cdot)$ 分别表示条件期望和矩阵求迹操作符。下面给出 EM 算法的主要步骤:

算法 1 利用 EM 算法估计线性动态模型参数

第 1 步 令迭代次数符号 $\tau = 1$, 设定收敛门限 ε ($0 < \varepsilon < 1$), 随机初始化模型参数;

第 2 步 给定第 τ 次迭代得到的模型参数 $\tilde{\boldsymbol{\Theta}}(\tau) = \{\tilde{\mathbf{A}}(\tau), \tilde{\mathbf{C}}(\tau), \tilde{\mathbf{Q}}(\tau), \tilde{\mathbf{R}}(\tau), \tilde{\boldsymbol{\mu}}_0(\tau), \tilde{\sigma}^2(\tau), \tilde{\mu}(\tau)\}$ 和频幅

序列 $\tilde{\mathbf{z}}_1^\kappa = \{z_1, z_2, \dots, z_\kappa\}$ ($0 < \kappa \leq d$, $\mathbf{z} = \tilde{\mathbf{z}}_1^d$), 首先定义以下 $\mathbf{u}_f$ 的条件统计量:

$$\left. \begin{aligned} \mathbf{u}_{f|\kappa} &= E(\mathbf{u}_f | \tilde{\mathbf{z}}_1^\kappa), \quad \mathbf{W}_{f|\kappa} = E[\mathbf{u}_f \mathbf{u}_f^T | \tilde{\mathbf{z}}_1^\kappa] \\ \boldsymbol{\Sigma}_{f|\kappa} &= E[(\mathbf{u}_f - \mathbf{u}_{f|\kappa})(\mathbf{u}_f - \mathbf{u}_{f|\kappa})^T | \tilde{\mathbf{z}}_1^\kappa] \\ \boldsymbol{\Sigma}_{f,f-1|\kappa} &= E[(\mathbf{u}_f - \mathbf{u}_{f|\kappa})(\mathbf{u}_{f-1} - \mathbf{u}_{f-1|\kappa})^T | \tilde{\mathbf{z}}_1^\kappa] \\ \mathbf{W}_{f,f-1|\kappa} &= E[\mathbf{u}_f \mathbf{u}_{f-1}^T | \tilde{\mathbf{z}}_1^\kappa] \end{aligned} \right\} \quad (6)$$

然后利用 Kalman 前向滤波算法^[14], 有

$$\left. \begin{aligned} \mathbf{u}_{f|f-1} &= \tilde{\mathbf{A}}(\tau) \mathbf{u}_{f-1|f-1} \\ \boldsymbol{\Sigma}_{f|f-1} &= \tilde{\mathbf{A}}(\tau) \boldsymbol{\Sigma}_{f-1|f-1} \tilde{\mathbf{A}}(\tau)^T + \tilde{\mathbf{Q}}(\tau) \\ \boldsymbol{\Sigma}_{f|f} &= \boldsymbol{\Sigma}_{f|f-1} - \mathbf{K}_f \tilde{\mathbf{C}}(\tau) \boldsymbol{\Sigma}_{f|f-1} \\ \mathbf{K}_f &= \boldsymbol{\Sigma}_{f|f-1} \tilde{\mathbf{C}}(\tau)^T [\tilde{\mathbf{C}}(\tau) \boldsymbol{\Sigma}_{f|f-1} \tilde{\mathbf{C}}(\tau)^T + \tilde{\sigma}^2(\tau)]^{-1} \\ \mathbf{u}_{f|f} &= \mathbf{u}_{f|f-1} + \mathbf{K}_f [z_f - \tilde{\mu}(\tau) - \tilde{\mathbf{C}}(\tau) \mathbf{u}_{f|f-1}] \end{aligned} \right\} \quad (7)$$

接着利用 RTS 后向平滑算法^[14], 有

$$\left. \begin{aligned} \boldsymbol{\Sigma}_{d,d-1|d} &= [\mathbf{I}_m - \mathbf{K}_d \tilde{\mathbf{C}}(\tau)] \tilde{\mathbf{A}}(\tau) \boldsymbol{\Sigma}_{d-1|d-1} \\ \mathbf{J}_{f-1} &= \boldsymbol{\Sigma}_{f-1|f-1} \tilde{\mathbf{A}}(\tau)^T (\boldsymbol{\Sigma}_{f|f-1})^{-1} \\ \mathbf{u}_{f-1|d} &= \mathbf{u}_{f-1|f-1} + \mathbf{J}_{f-1} [\mathbf{u}_{f|d} - \tilde{\mathbf{A}}(\tau) \mathbf{u}_{f-1|f-1}] \\ \boldsymbol{\Sigma}_{f-1|d} &= \boldsymbol{\Sigma}_{f-1|f-1} + \mathbf{J}_{f-1} [\boldsymbol{\Sigma}_{f|d} - \boldsymbol{\Sigma}_{f|f-1}] \mathbf{J}_{f-1}^T \\ \boldsymbol{\Sigma}_{f-1,f-2|d} &= \boldsymbol{\Sigma}_{f-1|f-1} \mathbf{J}_{f-2}^T + \mathbf{J}_{f-1} [\boldsymbol{\Sigma}_{f,f-1|d} - \tilde{\mathbf{A}}(\tau) \mathbf{u}_{f-1|f-1}] \mathbf{J}_{f-2}^T \\ \mathbf{W}_{f|d} &= \boldsymbol{\Sigma}_{f|d} + \mathbf{u}_{f|d} (\mathbf{u}_{f|d})^T \\ \mathbf{W}_{f,f-1|d} &= \boldsymbol{\Sigma}_{f,f-1|d} + \mathbf{u}_{f|d} (\mathbf{u}_{f-1|d})^T \end{aligned} \right\} \quad (8)$$

其中 $\mathbf{I}_m$ 为 m 阶单位阵。

第 3 步 把第 2 步估计得到的所有状态对应的 $\mathbf{u}_{f|d}$, $\mathbf{W}_{f|d}$ 和 $\mathbf{W}_{f,f-1|d}$ 代入式(5)中, 将 $Q(\boldsymbol{\Theta})$ 关于所有参数分别求导, 并令导数为零, 得到第 $\tau+1$ 次迭代时模型参数的最大似然估计:

$$\left. \begin{aligned} \tilde{\mu}(\tau+1) &= \frac{1}{d} \sum_{f=1}^d z_f, \quad \tilde{\boldsymbol{\mu}}_0(\tau+1) = \mathbf{u}_{0|d} \\ \tilde{\mathbf{A}}(\tau+1) &= \left(\sum_{f=1}^d \mathbf{W}_{f,f-1|d} \right) \left(\sum_{f=1}^d \mathbf{W}_{f-1|d} \right)^{-1} \\ \tilde{\mathbf{R}}(\tau+1) &= \text{diag}(\mathbf{W}_{1|d} - \mathbf{u}_{0|d} \mathbf{u}_{0|d}^T) \\ \tilde{\mathbf{C}}(\tau+1) &= \left[\sum_{f=1}^d (z_f - \tilde{\mu}(\tau+1)) \mathbf{u}_{f|d}^T \right] \left(\sum_{f=1}^d \mathbf{W}_{f|d} \right)^{-1} \\ \tilde{\mathbf{Q}}(\tau+1) &= \frac{1}{d} \text{diag} \left(\sum_{f=1}^d \mathbf{W}_{f|d} - \tilde{\mathbf{A}}(\tau+1) \sum_{f=1}^d \mathbf{W}_{f,f-1|d}^T \right) \\ \tilde{\sigma}^2(\tau+1) &= \frac{1}{d} \sum_{f=1}^d [(z_f - \tilde{\mu}(\tau+1))^2 - \tilde{\mathbf{C}}(\tau+1) \mathbf{u}_{f|d} (z_f - \tilde{\mu}(\tau+1))] \end{aligned} \right\} \quad (9)$$

其中 $\text{diag}(\cdot)$ 表示将矩阵非对角元素置零操作符。

第4步 若 $|Q(\tilde{\Theta}(\tau+1)) - Q(\tilde{\Theta}(\tau))|/|Q(\tilde{\Theta}(\tau))| > \varepsilon$, 则更新迭代次数标记, 即令 $\tau^{\text{new}} = \tau^{\text{old}} + 1$ 同时返回第2步, 进入下一次迭代; 否则, 认为算法收敛, 令 $\tilde{\Theta} = \tilde{\Theta}(\tau+1)$, 算法终止。

线性动态模型的自由度为 $m^2 + 4m + 2$ ($m \ll d$), 远小于 AGC 模型和 FA 模型的自由度 (AGC: $2d$; FA: $2d + (2d - o - 1)o/2$, o 为 FA 模型的隐状态维度); 同时, 从算法1中可以看出, 只需利用单个频幅样本就能估计所有的模型参数。这些性质极大地降低了识别系统对训练样本数的需求。此外, 算法1可以很容易推广到有多个训练样本的情况, 从而提高对线性动态模型参数的估计精度。

4 基于线性动态模型的雷达高分辨距离像识别步骤

下面给出基于线性动态模型的雷达距离像目标识别系统训练阶段和测试阶段的步骤:

(1) 训练阶段

第1步 将第 c 类目标 ($c = 1, 2, \dots, C$) 的训练样本均匀分为 K_c 帧, 每一帧包含 N 个距离像训练样本, 对各帧训练样本进行能量归一^[6];

第2步 提取各帧训练样本的频谱幅度作为识别特征, 记为 $\mathbf{Z}_{kc} = \{z_1^{kc}, z_2^{kc}, \dots, z_N^{kc}\}$ 。其中 z_n^{kc} ($k = 1, 2, \dots, K_c, n = 1, 2, \dots, N$) 表示第 c 类目标第 k 帧中的第 n 个距离像样本对应的频幅特征;

第3步 使用线性动态模型分别对第 c 类目标的各帧训练样本 $\mathbf{Z}_{kc}$ 建模, 并用算法1估计各帧训练样本对应的模型参数 $\tilde{\Theta}_{kc} = \{\tilde{\mathbf{A}}_{kc}, \tilde{\mathbf{C}}_{kc}, \tilde{\mathbf{Q}}_{kc}, \tilde{\mathbf{R}}_{kc}, \tilde{\mu}_{0kc}, \tilde{\sigma}_{kc}^2, \tilde{\mu}_{kc}\}$, 将其存入识别系统模板库;

(2) 测试阶段

第1步 对于给定的距离像测试样本 $\mathbf{x}'$, 计算其能量归一后的频谱幅度 $\mathbf{z}' = [z'_1, z'_2, \dots, z'_d]$;

第2步 利用 Kalman 前向滤波算法计算 $\mathbf{z}'$ 相应于模板库中所有目标各帧模型参数 $\tilde{\Theta}_{kc}$ 的条件均值 $\mathbf{u}_{f|f-1}^{kc}$ 和条件协方差阵 $\Sigma_{f|f-1}^{kc}$, 并将其代入式(10)中^[14]计算 $\mathbf{z}'$ 相应于各类目标的条件似然值 $p(\mathbf{z}' | c) = \max[p(\mathbf{z}' | c, k)]$ ($c = 1, 2, \dots, C, k = 1, 2, \dots, K_c$)。

$$p(\mathbf{z}' | c, k) = \prod_{f=1}^d \frac{1}{(2\pi)^{1/2} (\tilde{\mathbf{C}}_{kc} \Sigma_{f|f-1}^{kc} \tilde{\mathbf{C}}_{kc}^T + \tilde{\sigma}_{kc}^2)^{1/2}} \cdot \exp \left[-\frac{(z'_f - \tilde{\mu}_{kc} - \tilde{\mathbf{C}}_{kc} \mathbf{u}_{f|f-1}^{kc})^2}{2(\tilde{\mathbf{C}}_{kc} \Sigma_{f|f-1}^{kc} \tilde{\mathbf{C}}_{kc}^T + \tilde{\sigma}_{kc}^2)} \right] \quad (10)$$

第3步 使用 Bayes 分类器对测试样本 $\mathbf{z}'$ 分类, 其原理是将 $\mathbf{z}'$ 判为具有最大后验概率的一类目标 $\hat{c}(\mathbf{z}')$, 即

$$\hat{c}(\mathbf{z}') = \arg \max_c [p(c | \mathbf{z}')] \quad (11)$$

其中 $p(c | \mathbf{z}')$ 表示 $\mathbf{z}'$ 属于第 c 类目标的后验概率, $\arg \max_c [p(c | \mathbf{z}')]$ 表示取值最大的 $p(c | \mathbf{z}')$ 所对应的 c 值。根据 Bayes 公式可知: $p(c | \mathbf{z}') \propto p(c)p(\mathbf{z}' | c)$ 。在没有先验信息的条件下, 通常假设各类目标具有等先验概率^[6], 即 $p(1) = p(2) = \dots = p(C) = 1/C$, 因此式(11)等价于:

$$\hat{c}(\mathbf{z}') = \arg \max_c [p(\mathbf{z}' | c)] \quad (12)$$

图2给出了整个识别系统的算法流程。

5 实验结果和讨论

5.1 数据及实验设置介绍

本节的识别实验使用某 ISAR 雷达实测的飞机数据。雷达和飞机的参数如表1所示, 3类飞机的航迹在地面上的投影如图3所示。为了检验识别方法的推广性能, 本文将距离像数据分段, 并分别在不同的数据段内选取训练样本和测试样本。其中除了雅克-42的第5段数据包含10000次距离像回波外, 其余各段数据都含有25000次回波。需要指出的是, 各次距离像回波均为256维的向量。

表1 ISAR 实验雷达和飞机参数

雷达参数	中心频率		5520 MHz
	带宽		400 MHz
飞机类别	机长(m)	翼展(m)	机高(m)
安-26(螺旋桨)	23.80	29.20	8.58
奖状(喷气式)	14.40	15.90	4.57
雅克-42(喷气式)	36.38	34.88	9.83




图2 识别系统算法流程图




图3 3类目标飞行航迹

所有实验采用相同的均匀分帧方法，即设定帧长 $N = 1000$ 。另外，由于3类飞机数据均在“上视”场景中录取，具有很高的信杂噪比，所以实验部分不考虑噪声和杂波的影响。

5.2 隐状态维数对识别性能的影响

本节实验使用线性动态模型对3类目标各帧频幅样本建模，并研究隐状态维数对识别性能的影响。为了便于同其它识别方法比较，这里训练和测试样本的选取与文献[6]保持一致，即选取安-26的第5, 6段，奖状的第6, 7段和雅克-42的第2, 5段距离像数据作为训练样本，其它各段距离像数据作为测试样本。最终安-26/奖状/雅克-42的训练样本分别划分为50/50/35帧。设定收敛门限 $\varepsilon = 10^{-4}$ ，利用算法1估计各帧样本对应的模型参数。考虑到算法1中随机初始化模型参数可能对识别结果产生影响，这里将各隐状态维数下的识别实验都重复5次，并将各次实验的识别结果取平均。图4给出了基于状态空间模型的平均正确识别率随隐状态维数的变化曲线。




图4 基于线性动态模型的平均正确识别率随隐状态维数的变化曲线

从图中可以看到，当隐状态维数 $m = 1$ 时，平均正确识别率较低，只有65.2%。这属于模式识别领域的“欠匹配”问题^[4]，即此时模型过于简单，不足以准确反映频幅随频率的动态演化特性。随着隐状态维数 m 的增加，线性动态模型对频幅的广义平稳性描述地愈加准确，因此平均正确识别率逐渐提

高。当 $m = 3$ 时，平均正确识别率已经达到91.4%。之后，随着隐状态维数继续增加，平均正确识别率基本趋于稳定。值得注意的是当 $m > 8$ 时，模型的识别性能有所下降。这是因为过于复杂的模型结构限制了线性动态模型的推广性能，即“过匹配”问题^[4]。总的来说，在隐状态维数 m 大于1之后，其对识别结果的影响不大，只是会增加估计模型参数时的计算量。为了平衡识别精度与计算复杂度之间的关系，在本文所有后续实验中如无特别声明，都设定 $m = 4$ 。

表2给出使用全部训练样本时，AGC模型^[5]，FA模型^[6]和线性动态模型的识别结果。这里AGC模型和FA模型仍使用实距离像作为识别特征^[5,6]。从表2中可以看到，线性动态模型的平均识别性能介于FA模型与AGC模型之间。该结果验证了本文识别方法的可行性。

表2 3类模型对不同飞机的识别结果

模型	AGC 模型	FA 模型 (隐维度 20)	线性动态模型 (隐维度 4)
安-26	0.7536	0.9123	0.9659
奖状	0.8958	0.9405	0.8202
雅克-42	0.9888	0.9917	0.9628
平均识别率	0.8794	0.9482	0.9163

5.3 识别方法稳健性测试

在实际应用中，识别方法是否稳健非常重要。如果某种识别方法只是在特定的训练和测试样本条件下才能获得较好的识别结果，则该方法并不实用。为了检验识别方法的稳健性，本文根据训练和测试样本选取方法的不同，设置以下3种实验场景：

场景1：选取3类飞机的第1, 2段数据作为训练样本，其余各段为测试样本；

场景2：选取3类飞机的第3, 4段数据作为训练样本，其余各段为测试样本；

场景3：训练和测试样本的选取同5.2节实验一致。

在这3种场景下,分别比较了线性动态模型在 m 取值2,4,6,8时的识别性能。同5.2节实验一样,不同 m 取值下的识别实验都重复5次。最终的平均识别结果如表3所示:

表3 线性动态模型在不同实验场景和隐状态维数下的识别结果

隐状态维度	场景1	场景2	场景3
$m = 2$	0.8910	0.8955	0.9017
$m = 4$	0.9056	0.9090	0.9163
$m = 6$	0.9073	0.9134	0.9172
$m = 8$	0.9107	0.9151	0.9188

从表3中可以看到,当 m 取值相同时,线性动态模型在3种场景中的识别结果变化不大,且最高和最低识别率相差不超过1.3%。这说明本文方法对训练和测试样本的选取非常稳健。另外,从图3中可以看到,场景3中选取的训练样本对应的目标姿态比较完备,基本上覆盖了其测试样本所对应的目标姿态,因而识别率较高。与之相比,场景1,场景2中的训练样本对应的目标姿态未能包含全部测试样本的目标姿态,所以识别率略低。随后的实验都采用场景3中的训练样本和测试样本。

5.4 训练样本集大小对识别性能的影响

一个有效的识别系统应当能在较少的训练样本条件下,仍保持良好的识别性能。为了检验训练样本集大小对不同方法识别性能的影响,本文进行以下实验:从各帧中随机挑选相同数量的样本构成训练样本集,分别利用AGC模型,FA模型和线性动态模型进行识别。令 E 表示挑选的训练样本总数,这里研究 E 取值从大到小变化时,3类模型识别结果的变化情况。其中,对于 E 的不同取值,3类模型的识别实验都重复10次,最终结果如表4所示。

从表4中可以看到,由于AGC模型自由度较少,其识别结果对训练样本数的变化不太敏感。但AGC模型较简单,不能准确描述距离像的统计特性,所以其识别性能一般。FA模型在AGC模型的基础上,进一步考虑了不同维度之间的相关性,因此在大训练样本集条件下($E \geq 27000$)识别性能有明显提高。但由于增加了较多自由度,FA模型参数的估计精度随训练样本数的减少而下降,因而其识别性能也随之恶化。当 $E < 6750$ 时,训练样本数已不足以估计模型参数,FA模型甚至失去了识别能力。与AGC模型和FA模型相比,线性动态模型能够准确描述频幅的广义平稳性,识别性能较好;同时,该模型的自由度最少,即使在很少的训练样本条件下(如 $E = 675$)仍能准确估计模型参数,所以其

识别性能基本不随训练样本数的减少而发生明显改变。因而在小样本条件下,线性动态模型的识别性能远优于AGC模型和FA模型。这极大地降低了识别系统对训练样本数的需求,节省了建库成本。

5.5 训练样本集大小对拒判性能的影响

除了正确识别率,拒判能力是衡量识别方法性能优劣的另外一个指标。当观测到的目标不属于模板库中的任何一类时,及时对该库外目标做出拒判是很重要的。在本节的拒判实验中,使用电磁仿真软件XPATCH生成车辆类目标的18000次距离像作为库外样本。这里借助接收机工作特性(ROC)曲线来直观地表示各类模型的拒判性能。为此,首先引入两个评价拒判性能的指标:

(1)检测概率 P_d ,即库内测试样本(安-26/奖状/雅克-42的测试样本)被正确识别的概率;

(2)虚警概率 P_f ,即库外样本被错判为库内样本的概率。

给定检测门限 γ ,检测概率 P_d 和虚警概率 P_f 分别按下式计算:

$$P_d = M_1/N_1, P_f = M_2/N_2 \quad (13)$$

其中 M_1 为条件似然值(见式(10))大于 γ 的库内测试样本数, M_2 为条件似然值大于 γ 的库外测试样本数, N_1 和 N_2 分别为库内测试样本总数和库外测试样本总数。通过改变检测门限 γ 的大小,可以画出以 P_d 和 P_f 为坐标轴的ROC曲线。在给定虚警概率 P_f 的条件下,模型的检测概率 P_d 越高,其拒判性能越好。

图5(a)中给出了使用全部训练样本时3类模型各自的ROC曲线。可以看到,在任意给定的虚警概率 P_f 处,线性动态模型总能获得最高的检测概率值。这说明线性动态模型的拒判性能最好。此时,FA模型的拒判能力介于线性动态模型与AGC模型之间。为了检验在较少训练样本条件下3类模型的拒判性能,图5(b)中给出了 $E=6750$ 时3类模型的ROC曲线。与图5(a)相比,AGC模型和线性动态模型的ROC曲线几乎没有变化,而FA模型的ROC曲线变化明显,训练样本数的减少使得FA模型的拒判性能恶化。可见,线性动态模型的拒判性能非常稳定,几乎不随训练样本数的减少而下降,且始终优于其它两类模型。

6 结论

针对雷达高分辨距离像目标识别中训练样本不足的问题,本文提出了一种小样本条件下的识别新方法。该方法认为距离像频谱幅度服从广义平稳过程,使用低自由度的线性动态模型对其建模。实验

表 4 不同训练样本数条件下 3 类模型识别结果(平均值±标准差)

训练样本数(E)	AGC 模型	FA 模型	线性动态模型
67500	0.8444 ± 0.0057	0.9045 ± 0.0117	0.9151 ± 0.0059
27000	0.8381 ± 0.0073	0.8669 ± 0.0195	0.9137 ± 0.0065
13500	0.8206 ± 0.0110	0.7953 ± 0.0218	0.9112 ± 0.0082
6750	0.8053 ± 0.0185	0.6594 ± 0.0549	0.9096 ± 0.0073
2700	0.7831 ± 0.0353	—	0.9080 ± 0.0102
1350	0.7628 ± 0.0376	—	0.9053 ± 0.0116
675	0.6747 ± 0.0368	—	0.9022 ± 0.0089




图 5 3 类模型在不同训练样本集大小下的 ROC 曲线

结果表明,新方法的识别性能对模型隐状态维数的变化和训练样本的选取非常稳健。同时,与 AGC 模型和 FA 模型相比,本文方法的识别和拒判性能在小样本条件下均有显著优势。

参 考 文 献

- [1] 朱劭昊, 周建江, 吴杰. 基于半参数化概率密度估计的雷达目标识别[J]. 电子与信息学报, 2010, 32(9): 2161–2166.
- [2] Zhu Jie-hao, Zhou Jian-jiang, and Wu Jie. Radar target recognition based on semi-parametric density estimation[J]. *Journal of Electronics & Information Technology*, 2010, 32(9): 2161–2166.
- [3] Du L, Wang P, and Liu H, *et al.* Bayesian spatiotemporal multitask learning for radar HRRP target recognition[J]. *IEEE Transactions on Signal Processing*, 2011, 59(7): 3182–3196.
- [4] Shi L, Wang P, and Liu H, *et al.* Radar HRRP statistical recognition with local factor analysis by automatic Bayesian Ying-Yang harmony learning[J]. *IEEE Transactions on Signal Processing*, 2011, 59(2): 610–617.
- [5] Duda R O, Hart P E, and Stork D G. *Pattern Classification*[M]. New York: John Wiley and Sons, Inc, 2001: 172–174.
- [6] Jacobs S P and O'Sullivan J A. Automatic target recognition using sequences of high resolution radar range profiles[J]. *IEEE Transactions on Aerospace Electronic Systems*, 2000, 36(2): 364–380.
- [7] Du L, Liu H, and Bao Z. Radar HRRP statistical recognition: parametric model and model selection[J]. *IEEE Transactions on Signal Processing*, 2008, 56(5): 1931–1944.
- [8] Zyweck A and Bogner R E. Radar target classification of commercial aircraft[J]. *IEEE Transactions on Aerospace Electronic Systems*, 1996, 32(2): 598–606.
- [9] Pei B and Bao Z. Multi-aspect radar target recognition method based on scattering centers and HMMs classifiers[J]. *IEEE Transactions on Aerospace Electronic Systems*, 2005, 41(3): 1067–1074.
- [10] Wong S K. Non-cooperative target recognition in the frequency domain[J]. *IEEE Proceedings Radar, Sonar & Navigation*, 2004, 151(2): 77–84.
- [11] Guo Zun-hua and Li Shao-hong. One-dimensional frequency-domain feature for aircraft recognition from radar range profiles[J]. *IEEE Transactions on Aerospace Electronic Systems*, 2010, 46(4): 1880–1892.
- [12] Wang P, Dai F, and Pan M, *et al.* Radar HRRP target recognition in frequency domain based on autoregressive model[C]. *IEEE Radar Conference*, Kansas City, USA, 2011: 714–717.
- [13] Van Trees H L. *Detection, Estimation, and Modulation Theory, Part III*[M]. New York: John Wiley and Sons, Inc, 2001: 415–419.
- [14] Digalakis V, Rohllick J, and Ostendorf M. ML estimation of a stochastic linear system with the EM algorithm and its application to speech recognition[J]. *IEEE Transactions on Speech Audio Processing*, 1993, 1(4): 431–442.
- [15] Shumway R H and Stoffer D S. An approach to time series smoothing and forecasting using the EM algorithm[J]. *Journal of Time Series Analysis*, 1982, 3(4): 253–264.

王鹏辉：男，1984 年生，博士生，研究方向为雷达目标识别。

刘宏伟：男，1971 年生，教授，博士生导师，雷达信号处理国家重点实验室主任，研究方向为自适应信号处理、雷达信号处理、雷达目标识别等。

杜 兰：女，1980 年生，教授，博士生导师，研究方向为统计信号处理、机器学习理论在雷达目标识别中的应用。